

최적화 수학

3. Convex Optimization

① 함수 $f(x) = x^2 - 2x + 3$ 의 최솟값을 구하세요.

② 함수 $g(x) = 3x^4 - 4x^3 - 12x^2 + 1$ 의 최솟값을 구하세요.

* Convex function, convex set

↳ 아래로 볼록한 함수

주어진 두 벡터 $x_1, x_2 \in \mathbb{R}^n$ 에 대하여 다음과 같습니다.


- (a) 임의의 실수 θ 에 대하여, $y = \theta x_1 + (1 - \theta)x_2$ 를 만족하는 벡터 y 의 집합을 두 벡터 x_1, x_2 를 지나는 직선^{line}이라고 합니다.
- (b) $0 \leq \theta \leq 1$ 에 대하여, $y = \theta x_1 + (1 - \theta)x_2$ 를 만족하는 벡터 y 의 집합을 두 벡터 x_1, x_2 를 끝점으로 하는 선분^{line segment}이라고 합니다.

다음을 만족하는 집합 A 를 **아핀집합**이라고 합니다.

모든 $x_1, x_2 \in A$ 와 임의의 실수 θ 에 대하여, $\theta x_1 + (1 - \theta)x_2 \in A$

다음을 만족하는 집합 C 를 **볼록집합**이라고 합니다.

모든 $x_1, x_2 \in C$ 와 실수 $0 \leq \theta \leq 1$ 에 대하여, $\theta x_1 + (1 - \theta)x_2 \in C$



$\therefore x$ 는 x_1 와 x_2 의 사이의 모든 점을

$\theta, 1-\theta$ 비율로 나타낼 수 있음

$$\therefore x = \theta x_1 + (1 - \theta)x_2 \quad (0 \leq \theta \leq 1)$$

$$= \lambda_1 x_1 + \lambda_2 x_2 \quad \begin{pmatrix} \lambda_1, \lambda_2 \geq 0 \\ \lambda_1 + \lambda_2 = 1 \end{pmatrix}$$

행렬 $A \in \mathbb{R}^{m \times n}$ 과 벡터 $b \in \mathbb{R}^m$ 에 대하여 해집합 C 를 다음과 같이 정의합니다.

$$C = \{x \in \mathbb{R}^n \mid Ax = b\}$$

해집합 C 가 아핀집합임을 보이세요.

n 차원 실수 공간 $\mathbb{R}^n$ 에서 벡터 $a \in \mathbb{R}^n$ 과 실수 b 에 대하여 반평면 C 를 다음과 같이 정의합니다.

$$C = \{x \in \mathbb{R}^n \mid a^T x \leq b\}$$

반평면 C 가 볼록집합임을 보이세요.

n 차원 실수 공간 $\mathbb{R}^n$ 에서 중심이 $\mathbf{x}_c \in \mathbb{R}^n$, 반지름이 $r > 0$ 인 공 $B(\mathbf{x}_c, r)$ 은 다음과 같이 정의됩니다.

$$B(\mathbf{x}_c, r) = \{ \mathbf{x} \in \mathbb{R}^n \mid \| \mathbf{x} - \mathbf{x}_c \|_2 \leq r \}$$

공 $B(\mathbf{x}_c, r)$ 이 볼록집합임을 보이세요.

정의 3-4

볼록함수

Convex function (아래로 볼록)

실수 공간 $\mathbb{R}^n$ 에서 정의된 함수 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 이 다음을 만족할 때, 함수 f 를 **볼록함수**라고 합니다.


(a) 함수 f 의 정의역 $\text{dom} f$ 가 볼록집합입니다.

(b) 임의의 $x, y \in \text{dom} f$ 와 실수 $0 \leq \theta \leq 1$ 에 대하여 다음이 성립합니다.

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$$

선분 위의 모든 점.

조건



Convex function : 0/2
 Concave function : 3/1
 $\Rightarrow -f$ is convex function

n 차원 실수 공간 $\mathbb{R}^n$ 에서 정의된 노름함수^{norm function} $f(\boldsymbol{x}) = \|\boldsymbol{x}\|$ 가 볼록함수임을 보이세요.

2. Convex function

$f(x) = ax + b \Rightarrow \text{Convex, Concave 함수임.}$

$$f(x) = e^{ax}$$

$$f(x) = x^p, x \geq 0, p > 1$$

$$f(x) = |x|^p, p > 1$$

$$f(x) = x \ln x$$

$$f(\mathbf{x}) = \mathbf{a}^T \mathbf{x} + \mathbf{b}$$

$$f(\mathbf{x}) = \sqrt[p]{\sum (x_i)^p} = \|\mathbf{x}\|_p$$

실수 공간 $\mathbb{R}^n$ 에서 정의된 함수 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 이 한 번 미분가능하다고 가정합니다. 그러면 다음 두 조건은 서로 필요충분조건입니다.

(a) 함수 f 는 볼록함수입니다.


(b) 정의역 $\text{dom } f$ 는 볼록집합이고, 임의의 $x, y \in \text{dom } f$ 에 대하여 다음이 성립합니다.

$$\text{Convex} \iff f(y) \geq f(x) + \nabla f(x)^T (y-x) \iff x\text{-의 평면기울기} \geq x\text{-의 순간기울기}$$

$\Rightarrow f'(x)$ 가 증가함수

$$\text{Sol)} f(y) \geq f(x) + f'(x)(y-x)$$

$$\frac{f(y)-f(x)}{y-x} \geq f'(x)$$




$\Leftrightarrow$ 1st order : 1번 미분.

$$f(y) \geq f(x) + \nabla f(x)^T (y-x)$$

$\Leftrightarrow$ 2nd order : 2번 미분.

$$\nabla^2 f(x) \geq 0.$$

다변수 함수에서 Hessian Matrix.



ମିତ୍ର ମିତ୍ର ଓ ମିତ୍ର ମିତ୍ର

ମିତ୍ର ମିତ୍ର

ମିତ୍ର ମିତ୍ର = ମିତ୍ର ମିତ୍ର

실수 공간 $\mathbb{R}^n$ 에서 정의된 함수 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 이 두 번 미분가능하다고 합시다. 그러면 다음 두 조건은 서로 필요충분조건입니다.

(a) 함수 f 는 볼록함수입니다.

(b) 정의역 $\text{dom} f$ 는 볼록집합이고, 임의의 $x \in \text{dom} f$ 에 대하여 $\nabla^2 f(x)$ 는 양의 준정부호 행렬입니다.

① $f(x)$ 가 볼록함수이면

$$\frac{f(y) - f(x)}{y-x} \geq f'(x) \quad \text{for}$$

$$\therefore f''(x) \geq 0.$$

② $\nabla^2 f(x) \geq 0 \Leftrightarrow \text{Convex.}$

$$f(y) \geq f(x) + f'(x)(y-x) + \frac{f''(x)}{2}(y-x)^2.$$

둘라 양수.

예제 3-5

이계 조건

→ $f'' \geq 0$ 이면 볼록함수.

실수 공간 $\mathbb{R}$ 에서 정의된 다음 함수들이 볼록함수임을 보이세요.

(a) $f(x) = 10x^{100} + 5x^{20} + 3$

(b) $g(x) = x \log x$ (단, $x \in \mathbb{R}^+$)

2a) $f''(x) \geq 0$ 임을 증명.

$$f'(x) = 10 \times 100 x^{99} + 5 \times 20 x^{19}$$

$$f''(x) = 10 \times 100 \times 99 \cdot x^{98} + 5 \times 20 \times 19 \cdot x^{18} - g'(x) = \frac{1}{x} \quad (x > 0).$$

$$g'(x) = \log x + \frac{x}{x} = \log x + 1.$$

$$\therefore f''(x) \geq 0.$$

$$\therefore g''(x) \geq 0.$$

볼록함수

2차원 실수 공간 $\mathbb{R}^2$ 에서 정의된 다음 함수들이 볼록함수임을 보이세요.

(a) $f(x, y) = \frac{x^2}{y}$ (단, $y > 0, x \in \mathbb{R}$)

sol) $\nabla^2 f \geq 0$ 판정. $\Rightarrow \det \nabla^2 f \geq 0, \text{tr } A \geq 0$

$\star$ Hessian Matrix.

= Gradient Jacobian.

$$\nabla f = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix} = \begin{pmatrix} \frac{2x}{y} \\ -\frac{x^2}{y^2} \end{pmatrix}$$

$$\nabla^2 f = \begin{pmatrix} \frac{2}{y} & -\frac{2x}{y^2} \\ -\frac{2x}{y^2} & \frac{2x^2}{y^3} \end{pmatrix}$$

$$\det A_k = \frac{4x^2}{y^4} - \frac{4x^2}{y^4} = 0$$

(λ_1, λ_2)

$$\text{tr } A = \frac{2}{y} + \frac{2x^2}{y^3}$$

($\lambda_1 + \lambda_2$)

$$> \frac{2}{y} \left(1 + \frac{x^2}{y^2}\right) > 0.$$

$$\det \nabla^2 f \geq 0$$

of 3 Convex.

$\frac{2}{y} > 0$

(b) $g(x, y) = \log(e^x + e^y)$

sol) $\nabla^2 g \Leftarrow \nabla g$ Jacobian.

$$\nabla g = \begin{pmatrix} \frac{\partial g}{\partial x} \\ \frac{\partial g}{\partial y} \end{pmatrix} = \begin{pmatrix} \frac{e^x}{e^x + e^y} \\ \frac{e^y}{e^x + e^y} \end{pmatrix} \quad \nabla^2 g = \begin{pmatrix} \frac{\partial^2 g}{\partial^2 x} & \frac{\partial^2 g}{\partial x \partial y} \\ \frac{\partial^2 g}{\partial x \partial y} & \frac{\partial^2 g}{\partial^2 y} \end{pmatrix}$$

$$\nabla^2 g = \begin{pmatrix} e^x(e^x + e^y)^{-1} - e^x(e^x + e^y)^{-2}e^x & -e^x(e^x + e^y)^{-2}e^y \\ -e^x(e^x + e^y)^{-2}e^y & e^y(e^x + e^y)^{-1} - e^y(e^x + e^y)^{-2}e^y \end{pmatrix}$$

$$= \frac{1}{(e^x + e^y)^2} \begin{pmatrix} e^x e^y & -e^x e^y \\ -e^x e^y & e^x e^y \end{pmatrix}$$

$$= \frac{e^x e^y}{(e^x + e^y)^2} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$$

$\leftarrow A$ 와 동일.

$$\det A, \text{tr } A.$$

$$\det A = 0, \text{tr } A = 2.$$

$$\lambda_1 = \lambda_2, \lambda_1 + \lambda_2.$$

$$\therefore \lambda^2 - 2\lambda + 0 = 0 \quad \lambda(\lambda - 2) = 0.$$

$$f(x) = \frac{1}{2} x^T A x - B^T x + C$$

$$\nabla f(x) = Ax - B$$

$$\nabla^2 f(x) = A$$



$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \quad \begin{array}{l} \det A > 0 \\ \text{tr } A > 0 \end{array} \quad \text{이때, } \nabla^2 f \geq 0 \text{ 이다}$$

$\nabla^2 f(x) \geq 0$ 이면 Convex func

$\therefore \nabla f(x) = 0$ 인 점이 minimize

Jensen's inequality

$$\underbrace{f(\theta x + (1 - \theta)y)} \leq \theta f(x) + (1 - \theta)f(y), \quad 0 \leq \theta \leq 1$$

$$f(\lambda_1 x_1 + \lambda_2 x_2 + \lambda_3 x_3 + \dots + \lambda_n x_n) \leq \lambda_1 f(x_1) + \lambda_2 f(x_2) + \dots + \lambda_n f(x_n)$$

등식이 같다.

예제 3-7

산술기하 부등식

$x \in \mathbb{R}^+$ 에서 정의된 함수 $f(x) = -\log x$ 와 젠센의 부등식 을 이용해, 다음 산술기하 부등식을 증명하세요.

임의의 양수 a, b 에 대하여, $\frac{a+b}{2} \geq \sqrt{ab}$ (단, 등호는 $a=b$ 일 때 성립)

$$f'(x) = -\frac{1}{x}$$

$$\text{Sol) } f(\lambda_1 a + \lambda_2 b) \leq \lambda_1 f(a) + \lambda_2 f(b) \Rightarrow \text{젠센 부등식.}$$

$\lambda_1, \lambda_2 = \frac{1}{2}$ 이라 할 때:

$$f''(x) = \frac{1}{x^2}$$

$$f\left(\frac{a}{2} + \frac{b}{2}\right) \leq \frac{f(a)}{2} + \frac{f(b)}{2}$$

$$f''(x) \geq 0 \text{ 이므로}$$

$$-\log\left(\frac{a+b}{2}\right) \leq -\frac{1}{2}\log a - \frac{1}{2}\log b.$$

$f(x)$ 는 Convex :

$$\log\left(\frac{a+b}{2}\right) \geq \frac{1}{2}(\log a + \log b)$$

$$\geq \frac{1}{2}\log ab$$

$$\geq \log \sqrt{ab}$$

$$\therefore \frac{a+b}{2} \geq \sqrt{ab}.$$

$$f(a+b+c+\dots) \leq \frac{f(a)+f(b)+f(c)+\dots}{n} \Rightarrow \sqrt[n]{abc\dots}$$

$\Rightarrow$ 평균의 불변성

실수 공간 $\mathbb{R}^n$ 에서 정의된 함수 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 에 대하여, **공액함수** $f^*: \mathbb{R}^n \rightarrow \mathbb{R}$ 은 다음과 같이 정의됩니다.

$$f^*(\mathbf{y}) = \sup_{\mathbf{x} \in \text{dom } f} \{\mathbf{y}^T \mathbf{x} - f(\mathbf{x})\} \quad \mathbf{3}$$

실수 공간 $\mathbb{R}$ 에서 정의된 간단한 일차함수 $f(x) = ax + b$ 에 대하여, 공액함수 f^* 를 구하세요(단, a, b 는 실수).

양의 실수 공간 $\mathbb{R}^+$ 에서 정의된 함수 $f(x) = -\log x$ 에 대하여, 공액함수 f^* 를 구하세요.

대칭인 $n \times n$ 양의 정부호 행렬 Q 에 대해 실수 공간 $\mathbb{R}^n$ 에서 정의된 함수 $f(x) = \frac{1}{2}x^T Qx$ 의 공액함수 f^* 를 구하세요.

실수 공간 $\mathbb{R}^n$ 에서 정의된 볼록함수 $f_0, f_1, \dots, f_m$ 과 벡터 $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p$, 스칼라 $b_1, b_2, \dots, b_p$ 에 대하여, **블록 최적화 문제**는 다음과 같이 정의됩니다.

$$\begin{aligned} & \text{minimize} && f_0(\mathbf{x}) \\ & \text{subject to} && f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & && \mathbf{a}_i^T \mathbf{x} = b_i, \quad i = 1, \dots, p \end{aligned} \tag{3.2}$$

$d(\mathbf{x})$ 를 최소화.

$$\begin{cases} g(\mathbf{x}) \geq 0 \\ h_i(\mathbf{x}) \leq 0 \end{cases} \Rightarrow \begin{cases} h_i(\mathbf{x}) \leq 0 & h_i \text{ i convex} \\ g(\mathbf{x}) \leq 0 & \mathbf{a}_i^T \mathbf{x} + b_i = 0 \end{cases}$$

볼록 최적화 문제 (3.2)의 제약조건을 만족하는 x 의 집합을 다음과 같은 X 라고 합시다.

$$X = \{x \mid f_i(x) \leq 0 \ (i = 1, \dots, m), \ a_i^T x = b_i \ (i = 1, \dots, p)\}$$

이때 다음 두 조건은 필요충분조건입니다.

- (a) x 는 볼록 최적화 문제 (3.2)의 해입니다.
- (b) $x \in X$ 이고 임의의 $y \in X$ 에 대하여 다음이 성립합니다.

$$\star \nabla f_0(x)^T (y - x) \geq 0$$

convex

정리 1

$\Leftrightarrow$ ② first order

$$f(y) - f(x) \geq \nabla f(x)^T (y - x)$$

$\Leftarrow$ ③ second order.

$f(y)$ (모든 y 에 대해)

볼록 최적화 문제 (3.3)에 대하여 다음 두 조건은 필요충분조건입니다.

(a) x 는 볼록 최적화 문제 (3.3)의 해입니다.

(b) 최적화 문제 (3.3)의 목적함수 $f(x)$ 에 대하여, x 는 $\nabla f(x) = 0$ 의 해입니다.

$$\nabla f(x)^T \cdot (y - x) \geq 0$$

$$\Leftrightarrow \underbrace{|\nabla f(x)|}_{>0} \cdot \underbrace{|y - x|}_{>0} \underbrace{\cos \theta}_{-1 \leq \cos \theta \leq 1} \geq 0.$$

$$\hookrightarrow \because \forall y \text{에 만족하려면 } \nabla f(x) = 0.$$

$$ax^2 + bx + c = 0 \quad a \neq 0$$

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

예제 3-11

제약조건이 없는 볼록 최적화 문제의 최적조건

① $f(x)$ 가 convex 인가?

② $\nabla f(x) = 0$ 가 최소화 조건.

다음과 같은 목적함수에 대하여, 제약조건이 없는 최적화 문제 'minimize $f(x)$ '를 풀어보세요.

$$f(x) = \frac{1}{2} x^T A x - b^T x, \text{ (단, } x = (x, y) \in \mathbb{R}^2, A = \begin{bmatrix} 2 & -1 \\ -1 & 5 \end{bmatrix}, b = \begin{bmatrix} 2 \\ -3 \end{bmatrix} \text{)}$$

$$f(x, y) = \frac{1}{2} (x, y) \begin{pmatrix} 2 & -1 \\ -1 & 5 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} - (2 - 3) \begin{pmatrix} x \\ y \end{pmatrix}$$

$$= \frac{1}{2} (2x^2 - 2xy + 5y^2) - (2x - 3y)$$

$$= x^2 - xy + \frac{5}{2}y^2 - 2x + 3y$$

$$\nabla f(x) = \frac{1}{2} (A^T x + A x) - b = A x - b$$

$$\nabla^2 f(x) = A$$

② $\nabla f(x) = 0$. 최적점 찾기

$$A x - b = 0$$

$$\therefore x = A^{-1} \cdot b =$$

$$\begin{pmatrix} 2 & -1 \\ -1 & 5 \end{pmatrix}^{-1} \cdot \begin{pmatrix} 2 \\ -3 \end{pmatrix} =$$

$$\frac{1}{9} \begin{pmatrix} 5 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 2 \\ -3 \end{pmatrix} =$$

$$\frac{1}{9} \begin{pmatrix} 11 \\ -4 \end{pmatrix}$$

① $\nabla^2 f(x) \geq 0$ 인가? $\Rightarrow f(x)$ 는 convex

$$A = \begin{pmatrix} 2 & -1 \\ -1 & 5 \end{pmatrix} \quad \det A = 10 - 1 = 9$$

$$\text{tr } A = 7$$

특성값 모두 양수 $\Rightarrow A \succeq 0$.

최적점

$x \in \mathbb{R}^p$, $A \in \mathbb{R}^{n \times p}$, $b \in \mathbb{R}^n$ 에 대하여, 등식의 제약조건으로 이루어진 볼록 최적화 문제

예) 제약조건이 있을때: 라그랑지 풀기

minimize $f_0(x)$

subject to $Ax = b$

제약조건

$$\nabla f_0(x) = (\nabla g_1(x) + \nabla g_2(x) + \dots + \nabla g_n(x)) \begin{pmatrix} \lambda_1 \\ \lambda_2 \\ \vdots \\ \lambda_n \end{pmatrix} \quad (3.4)$$

에 대하여, 다음 두 조건은 필요충분조건입니다.

(a) x 는 볼록 최적화 문제 (3.4)의 해입니다.

(b) x 는 $Ax = b$ 를 만족하고, 어떤 $\nu \in \mathbb{R}^n$ 에 대하여 $\nabla f_0(x) + A^T \nu = 0$ 를 만족합니다.

$$\nabla f_0(x) = \begin{pmatrix} g_1(x) \\ g_2(x) \\ \vdots \\ g_n(x) \end{pmatrix} : \begin{pmatrix} c \\ a \\ \vdots \\ 0 \end{pmatrix}$$

$$f_0(x) = \text{objective}$$

$$\text{constraints } Ax = b$$

$$Ax - b = 0$$

$$g(x) = \begin{pmatrix} g_1(x) \\ g_2(x) \\ \vdots \\ g_n(x) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

$$\rightarrow \nabla f_0(x) = (\nabla g_1(x) + \nabla g_2(x) - \dots - \nabla g_n(x)) \begin{pmatrix} \lambda_1 \\ \vdots \\ \lambda_n \end{pmatrix}$$

$$= \begin{pmatrix} \nabla g_1(x) \\ \nabla g_2(x) \\ \vdots \\ \nabla g_n(x) \end{pmatrix}^T \cdot \lambda = A^T \cdot \lambda$$

$$\text{Jacobian } g(x) = A.$$

$$\nabla f(x) = Ax - b.$$

$$\nabla g(x) = A$$

실수 공간 $\mathbb{R}^p$ 에서 정의된 벡터 $\mathbf{b}$, $\mathbb{R}^n$ 에서 정의된 벡터 $\mathbf{c}$, $\mathbb{R}^m$ 에서 정의된 벡터 $\mathbf{h}$ 와 행렬 $G \in \mathbb{R}^{m \times n}$, $A \in \mathbb{R}^{p \times n}$ 에 대하여, 다음의 최적화 문제를 **선형계획법**이라고 합니다.⁹

$$\begin{aligned} &\text{minimize } \mathbf{c}^T \mathbf{x} \\ &\text{subject to } (G\mathbf{x})_i \leq h_i, \quad i = 1, \dots, m \\ &\quad \quad \quad A\mathbf{x} = \mathbf{b} \end{aligned} \tag{3.5}$$

실수 공간 $\mathbb{R}^n$ 에서 정의된 벡터 $\mathbf{b}$, $\mathbf{q}$, $\mathbb{R}^m$ 에서 정의된 벡터 $\mathbf{h}$ 와 행렬 $G \in \mathbb{R}^{m \times n}$, $A \in \mathbb{R}^{p \times n}$ 과 대칭행렬 $P \in \mathbb{R}^{n \times n}$ 에 대하여, 다음 최적화 문제를 **이차계획법**이라고 합니다.

$$\begin{aligned} & \text{minimize} && \frac{1}{2} \mathbf{x}^T P \mathbf{x} + \mathbf{q}^T \mathbf{x} \\ & \text{subject to} && (G\mathbf{x})_i \leq h_i, \quad i = 1, \dots, m \\ & && A\mathbf{x} = \mathbf{b} \end{aligned} \tag{3.8}$$

$$f(x+h) = f(x) + \nabla f(x)^T h + \frac{1}{2} h^T \nabla^2 f(x) h + O(h^3)$$

$$f(x) = \frac{1}{2} x^T A x + B^T x + C$$

$$\nabla f(x) = A x + b$$

$$\nabla^2 f(x) = A$$

Convex function, $A \succeq 0$

Convex Opt

$$\nabla f(x) = A x + b = 0$$

$$x = -A^{-1} \cdot b$$

$$f(x, y) = x^2 + y^2$$

$$= \frac{1}{2} x^T A x$$

$$\begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

$$\Leftrightarrow A \succeq 0 \Rightarrow x = -A^{-1} \cdot b$$

제약조건이 없는 최적화 문제 (3.11)의 목적함수 f 에 대하여, 다음 조건을 만족하는 수열 $\{\mathbf{x}_k\}_{k=0}^{\infty}$ 를 통해 최적화 문제 (3.11)을 푸는 방법을 **하강법**이라고 합니다.

(a) $\mathbf{x}_{k+1} = \mathbf{x}_k + t_k \Delta \mathbf{x}_k, k = 0, 1, \dots$ (단, $t_k > 0$)

(b) $f(\mathbf{x}_{k+1}) < f(\mathbf{x}_k)$

Gradient Descent Method

$$h_k = -\nabla f$$

$$x_{k+1} = x_k + t_k \Delta x_k$$

$$\Delta x_k = -\nabla f(x_k)$$

$$h_k f(x_{k+1}) \approx f(x_k + t_k h_k)$$

$$= f(x_k) + t_k \nabla f(x_k)^T h_k + O(t_k^2 |h_k|^2)$$

$$\approx f(x_k) + t_k \nabla f(x_k)^T h_k \leq f(x_k)$$

$$\therefore x_{k+1} = x_k - t_k \cdot \nabla f(x_k)$$

$$\nabla f(x_k)^T h_k < 0$$

$$\hookrightarrow \nabla f(x_k) \cdot h_k$$

$$\hookrightarrow f \text{의 방향 미분}$$

$$\hookrightarrow |\nabla f(x_k)| \cdot |h_k| \cdot \cos \theta$$

$$\frac{\pi}{2} < \theta < \pi$$

$$\theta = \pi \text{ 일 때 최대}$$

$$|h_k| = -\nabla f(x_k)$$

example >

$$f(x) = \frac{1}{2} x^T A x, \quad A = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix}, \quad x = (2, 3), \quad t_k = \frac{1}{2}, \quad x_3 = ?$$

sol)

$$\Rightarrow \nabla f(x) = Ax$$

$$\Rightarrow \nabla^2 f(x) = A = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix}$$

$$\begin{pmatrix} \det A = 8 - 4 = 4 > 0 \\ \text{tr } A = 4 + 2 > 0 \end{pmatrix}$$

$\therefore \lambda_1, \lambda_2 > 0$ (convex)

$$\nabla f(x) = 0$$

$$Ax = 0$$

$$\therefore x = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$g) \quad x_{k+1} = x_k + t_k h_k, \quad t_k = \frac{1}{2}, \quad h_k = -\nabla f(x_k)$$

$$\textcircled{a} \quad x_0 = \begin{pmatrix} 2 \\ 3 \end{pmatrix} \quad \nabla f(x_0) = Ax_0 = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} 2 \\ 3 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$$

$$x_1 = x_0 - \frac{1}{2} \nabla f(x_0) = \begin{pmatrix} 2 \\ 3 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 2 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

$$\textcircled{a} \quad x_1 = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \quad \nabla f(x_1) = Ax_1 = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$$

$$x_2 = x_1 - \frac{1}{2} \nabla f(x_1) = \begin{pmatrix} 1 \\ 2 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 0 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\textcircled{a} \quad x_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad \nabla f(x_2) = Ax_2 = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ 0 \end{pmatrix}$$

$$x_3 = x_2 - \frac{1}{2} \nabla f(x_2) = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 2 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

Given : $\mathbf{x}_0, \epsilon, t_k = t$

Repeat $k = 0, 1, \dots$

1. $\Delta \mathbf{x}_k := -\nabla f(\mathbf{x}_k)$

2. $\mathbf{x}_{k+1} = \mathbf{x}_k + t_k \Delta \mathbf{x}_k$

until $\|\mathbf{x}_{k+1} - \mathbf{x}_k\|_2 < \epsilon$



Minimize $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x}$

$$\mathbf{A} = \begin{bmatrix} 4 & -2 \\ -2 & 2 \end{bmatrix} \quad \mathbf{x}_0 = (2, 3)$$


$$t_k = \frac{1}{4} \quad \mathbf{x}_3 = ??$$

① $f(\mathbf{x})$ 가 convex인지


$\nabla^2 f \geq 0$ 인지 확인

Sol)

$$\mathbf{x}_{n+1} = \mathbf{x}_n - t_k \cdot \nabla f(\mathbf{x}_n)$$



(a) $t_k = 0.0001$ 인 경우



(b) $t_k = 0.25$ 인 경우

Exact line search method $\Rightarrow T$ 를 구하기

정의 3-12

정확한 직선탐색법

적절하게 정의된 하강법에서 생성된 수열 $\{x_k\}_{k=0}^{\infty}$ 를 통해 제약조건이 없는 최적화 문제 (3.11)을 푼다고 가정합시다. 이때 다음과 같이 하강법의 단계 크기 t_k 를 정의하는 방법을 **정확한 직선탐색법**이라고 합니다.

$$t_k = \operatorname{argmin}_{t \geq 0} f(x_{k+1}) = \operatorname{argmin}_{t \geq 0} f(x_k + t \Delta x_k) \quad 14$$

$$* x_{k+1} = x_k + t_k \cdot h_k$$

↓
step 방향

$$f(x_{k+1}) = f(x_k + t \cdot h_k)$$

$$g(t) = f(x_k) + t \cdot \nabla f(x_k)^T \cdot h_k + \frac{1}{2} \cdot t^2 \cdot h_k^T \nabla^2 f(x_k) \cdot h_k$$

convex.

t 최소값을 구하면: $g'(t) = 0$

$$\nabla f(x_k)^T h_k + t \cdot h_k^T \nabla^2 f(x_k) \cdot h_k = 0 \Rightarrow h_k = -\nabla f(x_k)$$

$$\therefore t = \frac{-\nabla f(x_k)^T \cdot h_k}{h_k^T \nabla^2 f(x_k) \cdot h_k} = \frac{|\nabla f(x_k)|^2}{\nabla f^T \cdot \nabla^2 f \cdot \nabla f}$$

$$\begin{aligned} x_{k+1} &= x_k + t \cdot h_k \\ h_k &= -\nabla f(x_k) \\ t &= \frac{|\nabla f|^2}{\nabla f^T \cdot \nabla^2 f \cdot \nabla f} \\ f(x) &= \frac{1}{2} x^T A \cdot x + b^T x \\ \nabla f &= A x + b, \quad \nabla^2 f = A \end{aligned}$$

Minimize $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x}$

$$\mathbf{A} = \begin{bmatrix} 4 & -2 \\ -2 & 2 \end{bmatrix} \quad \mathbf{x}_0 = (2, 3) \quad \mathbf{x}_3 = ??$$

① $\mathbf{x}_0 = \begin{pmatrix} 2 \\ 3 \end{pmatrix} \quad \nabla f(\mathbf{x}_0) = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} 2 \\ 3 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$

argmin $f(\mathbf{x}_0 - t_k \nabla f(\mathbf{x}_0)) = f\left(\begin{pmatrix} 2 \\ 3 \end{pmatrix} - t_k \begin{pmatrix} 2 \\ 2 \end{pmatrix}\right) = f\left(\begin{pmatrix} 2-2t \\ 3-2t \end{pmatrix}\right)$

$f(x, y) = \frac{1}{2} (4x^2 - 4xy + 2y^2)$

$$\begin{aligned} \therefore f\left(\begin{pmatrix} 2-2t \\ 3-2t \end{pmatrix}\right) &= 2(2-2t)^2 - 2(2-2t)(3-2t) + (3-2t)^2 \\ &= 8(t-1)^2 - 4(t-1)(2t-3) + (2t-3)^2 \end{aligned}$$

$$= 4t^2 - 8t + 5 = 4(t^2 - 2t + 1 - 1) + 5 = 4(t-1)^2 + 1$$

Sol)

$$\mathbf{x}_{k+1} = \mathbf{x}_k - t_k \nabla f(\mathbf{x}_k)$$

$\therefore t_k = 1$ (best step)

$$\begin{aligned} \mathbf{x}_1 &= \mathbf{x}_0 - t_k \nabla f(\mathbf{x}_0) \\ &= \begin{pmatrix} 2 \\ 3 \end{pmatrix} - 1 \begin{pmatrix} 2 \\ 2 \end{pmatrix} \\ &= \begin{pmatrix} 0 \\ 1 \end{pmatrix} \end{aligned}$$

$t = 1$ (best step)

$$\textcircled{2} \quad x_1 = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \quad \nabla f(x_1) = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -2 \\ 2 \end{pmatrix}$$

$$\arg\min f(x_1 - \frac{1}{\|\nabla f(x_1)\|} \nabla f(x_1)) = f\left(\begin{pmatrix} 0 \\ 1 \end{pmatrix} - \frac{1}{\sqrt{2}} \begin{pmatrix} -2 \\ 2 \end{pmatrix}\right) = f\left(\begin{pmatrix} 2 \\ 1-2 \end{pmatrix}\right)$$

$$f\left(\begin{pmatrix} 2 \\ 1-2 \end{pmatrix}\right) = 2(2)^2 - 2(2)(1-2) + (1-2)^2$$

$$= 8 + 2 - 4 + 1 = 7$$

$$= 20t^2 - 8t + 1$$

$$= 20\left(t^2 - \frac{2}{5}t + \frac{1}{25} - \frac{1}{25}\right) + 1$$

$$= 20\left(t - \frac{1}{5}\right)^2 + \frac{1}{5}$$

최소값은 $\frac{1}{5}$ 이고 $t = \frac{1}{5}$ 일 때

$$\therefore x_2 = x_1 - \frac{1}{\|\nabla f(x_1)\|} \nabla f(x_1)$$

$$= \begin{pmatrix} 0 \\ 1 \end{pmatrix} - \frac{1}{\sqrt{2}} \begin{pmatrix} -2 \\ 2 \end{pmatrix}$$

$$= \begin{pmatrix} \frac{2}{\sqrt{2}} \\ \frac{2}{\sqrt{2}} \end{pmatrix}$$

Ex 2 Ex 1 | Ex 1 $f(x) = \frac{1}{2} x^T A x$, $A = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix}$ $x_0 = (2, 3)$

① $x_1 = x_0 - t \cdot \nabla f(x_0)$

$\nabla f(x) = Ax = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} 2 \\ 3 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$, $\nabla^2 f(x) = A$.

$t = \frac{|\nabla f|^2}{\nabla f^T \cdot \nabla^2 f \cdot \nabla f} = \frac{(2, 2)^T}{(2, 2) \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} 2 \\ 2 \end{pmatrix}} = \frac{8}{8} = 1$

$\therefore x_1 = \begin{pmatrix} 2 \\ 3 \end{pmatrix} - \begin{pmatrix} 2 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

② $x_2 = x_1 - t \cdot \nabla f(x_1)$

$(0, 1)^T$

최적화 문제 (3.11)의 목적함수 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 이 행렬 $A \in \mathbb{R}^{n \times n}$, 벡터 $b \in \mathbb{R}^{n \times 1}$, $c \in \mathbb{R}$ 에 대하여 이차형식 $f(x) = \frac{1}{2}x^T A x + b^T x + c$ 일 때, 경사하강법을 통해 최적화 문제 (3.11)을 푼다고 가정합시다. 이때 정확한 직선탐색법을 통해 얻는 최적의 단계 크기 t_k 는 다음과 같습니다.

$$t_k = \frac{g_k^T g_k}{g_k^T A g_k}$$

여기서 $g_k = -\nabla f(x_k)$ 입니다.

$$f(x_{k+1}) = f(x_k + t \cdot h_k) = f(x_k) + t \cdot \nabla f(x_k)^T \cdot h_k + \frac{1}{2} t^2 h_k^T \nabla^2 f(x_k) \cdot h_k + O$$

$$g(t) \propto \leftarrow$$

$$g(t) = \nabla f(x_k)^T \cdot h_k + t h_k^T \nabla^2 f(x_k) \cdot h_k = 0$$

$$t = \frac{\nabla f(x_k)^T \cdot \nabla f(x_k)}{\nabla f(x_k)^T \cdot A \cdot \nabla f(x_k)}$$

$$A = \nabla^2 f(x_k)$$

$$A = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix} \quad x_0 = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$$

$$\nabla f(x_0) = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$$

$$\begin{pmatrix} 2 & 2 \end{pmatrix} \begin{pmatrix} 2 \\ 2 \end{pmatrix}$$


$$\frac{\begin{pmatrix} 2 & 2 \end{pmatrix} \begin{pmatrix} 2 \\ 2 \end{pmatrix}}{\begin{pmatrix} 2 & 2 \end{pmatrix} \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} 2 \\ 2 \end{pmatrix}} = 1$$

Backtracking line search method = soft line search

$$f(\mathbf{x}_{k+1}) = f(\mathbf{x}_k + t \Delta \mathbf{x}_k) \approx f(\mathbf{x}_k) + t \nabla f(\mathbf{x}_k)^T \Delta \mathbf{x}_k$$

$\Delta \mathbf{x}_k = -\nabla f(\mathbf{x}_k)$

$$= f(\mathbf{x}_k) - t \|\nabla f\|^2$$



역추적 조건 : $0 \leq t \leq t^*$

Given : Δx , $0 < \alpha < 0.5$, $0 < \beta < 1$

1. $t := 1$

Repeat

2. $t := \beta t$

until $f(x + t \Delta x) < f(x) + \alpha t \nabla f(x)^T \Delta x$

$t \leftarrow \beta t$
until $f(x + t \Delta x) < f(x) + \alpha t \nabla f(x)^T \Delta x$

☆ 1/2에 무조건 넣을 것

~~t~~ (default)
 $\alpha = 0.5$ $\beta = 1$

Minimize $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x}$

$$\mathbf{A} = \begin{bmatrix} 4 & -2 \\ -2 & 2 \end{bmatrix}$$

$$\mathbf{x}_0 = (2, 3)$$

$$t_0 = 1, \alpha = \frac{1}{2}, \beta = \frac{1}{2}$$

$$\mathbf{x}_3 = ??$$

① $\mathbf{x}_0 = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$, $\nabla f(\mathbf{x}_0) = (2, 2)$, $t = 1$

$f(x) = 2x^2 - 4xy + y^2$

② $t = 1$; $\mathbf{x}_1 = \mathbf{x}_0 - t \nabla f(\mathbf{x}_0) = (2, 3) - (2, 2) = (0, 1)$

$\therefore \mathbf{x}_1 = (0, 1)$

$g(t) = f(\mathbf{x}_0) - \frac{0.4}{2} \times t \times 8 = 5 - 3.2t = 1.8 \geq f(\mathbf{x}_1) = 1 \Rightarrow t \geq 0.625$
 $\frac{1}{\|\nabla f\|^2} \nabla f(\mathbf{x}_0)$

③ $\mathbf{x}_1 = (0, 1)$, $\nabla f(\mathbf{x}_1) = (-2, 2)$

$t = 1$; $g(t) = f(\mathbf{x}_1) - \alpha t \|\nabla f(\mathbf{x}_1)\|^2 = 1 - 0.4 \times t \times 8 = -2.2$
 $\frac{1}{\|\nabla f\|^2} \nabla f(\mathbf{x}_1)$

$\mathbf{x}_2 = \mathbf{x}_1 - t \nabla f = (0, 1) - t(-2, 2) = (2t, 1-2t)$

$f(2, 1) = 13 \Rightarrow g(1) = -2.2$

$t = \beta \cdot t$

$\rightarrow g(0.5)$

$$\therefore t = \frac{1}{2} \text{ say } (2t, 1-2t) > \times 2$$

$$f(1,0) = 2 > g\left(\frac{1}{2}\right) = -0.6 \Rightarrow f > g$$

$$\therefore t = \frac{1}{4} \text{ say}$$

$$f\left(\frac{1}{2}, \frac{1}{2}\right) = 0.25 > g\left(\frac{1}{4}\right) = 0.2 \Rightarrow f > g$$


$$\therefore t = \frac{1}{8} \text{ say}$$

$$f\left(\frac{1}{4}, \frac{3}{4}\right) = \frac{5}{16} < g\left(\frac{1}{8}\right) = 0.6 \Rightarrow \text{OK} \therefore t = \frac{1}{8}$$

$f < g = 0.6$

✓
accepted

Linear regression analysis



2차원 평면 $\mathbb{R}^2$ 에서 주어진 점들의 집합 $X = \{(x_i, y_i) \mid i = 1, \dots, N\}$ 의 추세를 가장 잘 설명할 수 있는 직선의 방정식을 찾는 것을 **선형 회귀 분석**이라 합니다. 선형 회귀 분석은 다음과 같은 최적화 문제로 표현할 수 있습니다.


$$\underset{a_0, a_1}{\text{minimize}} \quad f(a_0, a_1) = \frac{1}{N} \sum_{i=1}^N (a_0 + a_1 x_i - y_i)^2 \quad (3.12)$$

선형 회귀 분석에 대한 최적화 문제 (3.12)의 해는 다음과 같습니다.

$$a_1 = \frac{E(XY) - E(X)E(Y)}{V(X)}, \quad a_0 = E(Y) - a_1E(X)$$

다섯 개의 점 $(1, 1)$, $(2, 3)$, $(3, 5)$, $(4, 3)$, $(5, 7)$ 의 추세를 가장 잘 표현하는 직선의 방정식 $y = a_0 + a_1x$ 를 선형 회귀 분석을 통해 찾아보세요.

Multivariate analysis



$$\underset{a_0, a_1, a_2}{\text{minimize}} \quad f(a_0, a_1, a_2) = \frac{1}{N} \sum_{i=1}^N (a_0 + a_1 x_i + a_2 y_i - z_i)^2$$

$$\frac{\partial f}{\partial a_0} = \frac{2}{N} \sum_{i=1}^N (a_0 + a_1 x_i + a_2 y_i - z_i) = 0$$

$$\frac{\partial f}{\partial a_1} = \frac{2}{N} \sum_{i=1}^N (a_0 + a_1 x_i + a_2 y_i - z_i) x_i = 0$$

$$\frac{\partial f}{\partial a_2} = \frac{2}{N} \sum_{i=1}^N (a_0 + a_1 x_i + a_2 y_i - z_i) y_i = 0$$

Given : $N, \mathbf{x}_i = (x_i, y_i) (i = 1, \dots, N)$

$$\mathbf{a}^{(0)} = (a_0^{(0)}, a_1^{(1)}), \epsilon$$

Repeat $k = 1, 2, \dots$ ($\mathbf{a}^{(k)} = (a_0^{(k)}, a_1^{(k)})$, $\Delta \mathbf{a}^{(k)} = (\Delta a_0^{(k)}, \Delta a_1^{(k)})$)

$$1. (\Delta a_0^{(k)}, \Delta a_1^{(k)}) := -\nabla f(a_0^{(k)}, a_1^{(k)})$$

$$= -\left(\frac{2}{N} \sum_{i=1}^N (a_0^{(k)} + a_1^{(k)} x_i - y_i), \frac{2}{N} \sum_{i=1}^N (a_0^{(k)} + a_1^{(k)} x_i - y_i) x_i \right)$$

2. 역추적 직선탐색법에 의해 $t^{(k)}$ 결정

$$3. (a_0^{(k+1)}, a_1^{(k+1)}) = (a_0^{(k)}, a_1^{(k)}) + t^{(k)} (\Delta a_0^{(k)}, \Delta a_1^{(k)})$$

until $\|\mathbf{a}^{(k+1)} - \mathbf{a}^{(k)}\|_2 < \epsilon$

* Gradient Descent + Exact line

$$G(t) = f(x_{k+1}) = f(x_k + t \cdot \nabla f)$$

$$= f(x_k - t \cdot \nabla f)$$

$G(t) \rightarrow 0$ 인점을 찾는 Exact line method


$$g(t) = \nabla f(x_k - t \nabla f) \cdot (-\nabla f) = 0$$

$$-\nabla f(x_{k+1}) \cdot \nabla f(x_k) = 0$$

$$\therefore \nabla f(x_k) \perp \nabla f(x_{k+1})$$

→ 이 방법 : Conjugate gradient method

Exact line method / 2
수직-2단 진행



gradient: $x_{n+1} = x_n - t \cdot \nabla f$ f is ∇f .

Exact: $x_{n+1} = x_n - t \cdot \nabla f$.

$$t = \frac{|\nabla f|^2}{\nabla f^T \cdot \nabla^2 f \cdot \nabla f}$$

Back: $x_{n+1} = \underbrace{x_n - d \cdot t}_{g(t) > f(t)}$

ex) $A = \begin{pmatrix} 4 & -2 \\ 2 & 1 \end{pmatrix}$ $x = (2, 3)$ $f(x) = \frac{1}{2} x^T \cdot A \cdot x$

Ex: $d = \frac{|\nabla f|^2}{\nabla f^T \cdot \nabla^2 f \cdot \nabla f}$ $\nabla f = A \cdot x_n$
 $\nabla^2 f = A$

Back: $f_0 = 1$
 $x_1 = x_0 - 2 |\nabla f|^2$

Conjugate gradient method

$$\mathbf{x}_{k+1} = \mathbf{x}_k + t_k \mathbf{d}_k$$


$$\mathbf{d}_k = -\mathbf{g}_k + \sum \frac{\mathbf{g}_{k+1}^T \mathbf{A} \mathbf{d}_i}{\mathbf{d}_i^T \mathbf{A} \mathbf{d}_i} \mathbf{d}_i$$

$$t_k = -\frac{\mathbf{g}_k^T \mathbf{d}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$

Newton's Method


$$\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{h}_k$$

$$Hf(\mathbf{x}_k)\mathbf{h}_k = -\nabla f(\mathbf{x}_k)$$




(a) Steepest descent

= Exact line method



(b) Newton's method



(c) Conjugate gradient

<https://www.semanticscholar.org/paper/Nonlinear-Conjugate-Gradient-Method-Efremov/3984af3ad7e6411c06c98f609d34e43c726fd7ef>

Question?