

LECTURE 08

다목적 최적화

Multi-Objective Optimization

복수의 상충하는 목표를 동시에 고려하는 최적화 문제의 본질을 이해하고, 파레토 최적해를 도출하기 위한 고전적 방법론과 진화 알고리즘을 학습합니다.

SUGGESTED READING



Multi-Objective Optimization using Evolutionary Algorithms

K. Deb • John Wiley & Sons, Inc., 2001

다목적 최적화 문제 (MOOP)

Multi-Objective Optimization Problems



다중 목적 함수 (Multiple Objectives)

동시에 최소화하거나 최대화해야 하는 두 개 이상의 목적 함수가 포함된 최적화 문제입니다. 단일 목표만을 고려하는 일반 최적화와 달리 복잡도가 높습니다.



트레이드오프 해 집합 (Set of Solutions)

정답은 단일 해가 아닙니다. 상충하는 목표들(Competing Objectives) 사이의 **최적의 트레이드오프**를 정의하는 해들의 집합을 찾는 것이 목표입니다.

REAL-WORLD EXAMPLES



비용(최소화) vs 성능(최대화)



수익(최대화) vs 위험(최소화)



정확도(최대화) vs 복잡도(최소화)

MOOP의 수학적 정식화

General Mathematical Form of Multi-Objective Optimization Problems

목적 함수
Minimize / Maximize

$$f(\mathbf{x}) = [f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_M(\mathbf{x})]^T$$

제약 조건
Subject to

$$g_j(\mathbf{x}) \geq 0, \quad j = 1, 2, \dots, J \quad (\text{부등식 제약})$$
$$h_k(\mathbf{x}) = 0, \quad k = 1, 2, \dots, K \quad (\text{등식 제약})$$

변수 범위
Variable Bounds

$$x_i^{(L)} \leq x_i \leq x_i^{(U)}, \quad i = 1, 2, \dots, n$$

M 목적함수 개수 n 결정변수 개수 J 부등식 제약 개수 K 등식 제약 개수 $\mathbf{x}$ 결정변수 벡터

우월성(Dominance) 개념

단일 목적 최적화와의 비교 및 정의

CONTEXT 해의 우수성 판단 방법

→ 단일 목적 최적화 (Single-Objective)

목적 함수 값이 하나의 스칼라(Scalar)이므로, 단순히 값의 크기를 비교하여 우열을 쉽게 판단할 수 있습니다.

$$f(x_1) < f(x_2) \rightarrow x_1 \text{ is better}$$

≡ 다목적 최적화 (Multi-Objective)

여러 목적 함수가 상충하므로 단순 비교가 불가능합니다. 해의 우수성을 판단하기 위해 '우월성(Dominance)' 개념을 사용합니다.

👑 Dominance Test

언제 해 x_1 이 x_2 를 지배하는가?

해 x_1 이 해 x_2 를 **지배한다(Dominates)**고 하려면, 다음 두 조건을 모두 만족해야 합니다:

✓ 조건 1: 나쁘지 않음

모든 목적함수 i 에 대하여, x_1 이 x_2 보다 나쁘지 않아야 한다.

$$\forall i \in \{1, \dots, M\}, \quad f_i(x_1) \leq f_i(x_2)$$

✓ 조건 2: 적어도 하나는 더 좋음


적어도 하나의 목적함수 j 에 대하여, x_1 이 x_2 보다 확실히 좋아야 한다.

$$\exists j \in \{1, \dots, M\}, \quad f_j(x_1) < f_j(x_2)$$

결론: x_2 는 x_1 에 의해 지배됨 (Dominated)

우월성 테스트 예시

목적 함수 공간에서의 해 간 관계: f1 (최대화) vs f2 (최소화)



Case 1 1 dominates 2



해 1은 해 2보다 **f1이 더 크고(Better)**, **f2는 더 작습니다 (Better)**.
따라서 해 1은 해 2를 완벽하게 지배합니다.

Case 2 5 dominates 1



해 5는 해 1보다 **f1이 더 크고(Better)**, **f2는 더 작습니다 (Better)**.
따라서 해 5가 해 1을 지배합니다.

Case 3 1 vs 4: Neither Dominates



해 4는 f1에서는 1보다 좋지만, f2에서는 1보다 나쁩니다.
어느 한쪽이 모든 면에서 우세하지 않으므로 **상호 비지배 관계**입니다.

파레토 최적해 (Pareto Optimal Solution)

Non-dominated Solution Set & Pareto Front



비지배 해 집합 (Non-dominated Solution Set)

주어진 해들의 집합(Population) 내에서, 다른 어떤 해에 의해서도 **지배되지 않는(Not Dominated)** 해들로 구성된 집합입니다.



파레토 최적 집합 (Pareto-optimal Set)

전체 실행 가능한 **의사결정 공간(Decision Space)** 상에서의 비지배 해 집합을 의미합니다. 이는 우리가 찾고자 하는 최적의 설계 변수들의 조합입니다.



파레토 최적 프론트 (Pareto-optimal Front)

파레토 최적 집합에 속하는 해들을 **목적 함수 공간(Objective Space)**에 매핑했을 때 형성되는 경계면(Boundary)을 말합니다.

INPUT SPACE

의사결정 공간 (Decision Space)

파레토 최적 집합 (Set)



MAPPING $F(X)$

매핑 함수




OUTPUT SPACE

목적 공간 (Objective Space)

파레토 최적 프론트 (Front)

파레토 최적해의 그래픽 이해

의사결정 공간(Decision Space)과 목적 공간(Objective Space)의 매핑 관계



의사결정 공간 (Decision Space)

설계 변수 x 가 정의되는 공간입니다. **파레토 최적 집합(Pareto Optimal Set)**은 이 공간 내의 특정 부분(주로 경계)에 위치한 해들의 집합을 의미합니다.

목적 공간 (Objective Space)

목적 함수 값 $f(x)$ 로 매핑된 공간입니다. **파레토 프론트(Pareto Front)**는 비지배 해들이 형성하는 경계면으로, 최적화의 목표가 되는 지점입니다.

MOO의 두 가지 목표

Goals in Multi-Objective Optimization

- 

파레토 프론트에 대한 근접성 (Convergence)

찾아낸 해 집합이 진정한 **파레토 최적 프론트(Pareto-optimal Front)**에 최대한 가까이 위치하도록 하는 것이 첫 번째 목표입니다. 오차를 최소화하고 최적 성능에 도달하는 것을 의미합니다.
- 

해의 다양성 확보 (Diversity)

파레토 프론트 상에서 해들이 **넓고 고르게 분포**하도록 하는 것이 두 번째 목표입니다. 특정 영역에만 해가 뭉치지 않고, 의사결정자에게 다양한 트레이드오프 선택지를 제공해야 합니다.

OPTIMIZATION SCENARIOS



이상적 목표

높은 근접성 + 높은 다양성



나쁜 다양성

해들이 특정 영역에 편중됨



나쁜 근접성

파레토 프론트와 거리가 멀

— CLASSIC METHODS

고전적 최적화 방법론

Classic Multi-Objective Optimization Methods



가중합 방법

Weighted Sum Method

가중치를 부여하여 단일 목적으로 변환



ϵ -제약 방법

ϵ -Constraint Method

주 목적 외 나머지를 제약조건으로 설정



가중 메트릭 방법

Weighted Metric Method

이상적 해(z^*)와의 거리를 최소화

가중합 방법 (Weighted Sum Method)

다목적 함수를 단일 목적 함수로 스칼라화(Scalarization)하여 해결하는 기법

CONCEPT 기본 원리 및 수식

정의 (Definition)

각 목적 함수에 사용자 지정 가중치(weight)를 부여하여 합산함으로써, 여러 목적을 하나의 통합된 목적 함수로 변환합니다.

Minimize Combined Objective Function:

$$F(x) = \sum_{m=1}^M w_m f_m(x)$$

✓ $w_m \geq 0$ ✓ $\sum w_m = 1$

특징

가중치 벡터 $\mathbf{w} = (w_1, \dots, w_m)$ 는 각 목적 함수의 상대적 중요도를 반영합니다. 가중치를 변경하면 최적해의 위치가 달라집니다.

장점 및 단점



단순성과 효율성

구현이 매우 간단하며, 볼록(Convex) 문제에서는 효율적으로 파레토 최적해를 찾을 수 있습니다.



가중치 설정의 어려움

목적 공간에서 원하는 영역의 해를 얻기 위해 적절한 가중치 값을 예측하기 어렵습니다.

⚠ 치명적 한계: 비볼록(Non-Convex) 문제

목적 공간(Objective Space)이 비볼록(Non-convex)한 경우, 가중합 방법으로는 오목한(concave) 부분에 위치한 파레토 최적해를 절대 찾을 수 없습니다.

볼록(Convex)



가능


비볼록(Non-Convex)



불가능

ϵ -제약 (ϵ -Constraint) 방법

주 목적함수는 최적화하고 나머지는 제약조건으로 전환하여 해를 탐색하는 기법



정의 및 수학적 표현

가장 중요한 목적함수(f_μ) 하나를 선택하여 최소화하고, 나머지 목적함수들은 상한 값(ϵ)을 설정하여 제약조건으로 처리합니다.

$$\begin{aligned} & \text{Minimize } f_\mu(x) \\ & \text{Subject to } f_j(x) \leq \epsilon_j, \quad j = 1, \dots, M, j \neq \mu \end{aligned}$$

장점 및 단점

- 장점:** 볼록(Convex)하지 않은 파레토 프론트를 가진 문제에서도 해를 발견할 수 있습니다. 가중합 방법의 한계를 극복합니다.
- 단점:** 적절한 ϵ 벡터를 설정하기 어렵습니다. 각 목적함수의 가능한 범위(최소/최대)에 대한 사전 지식이 필요합니다.

가중 메트릭(Weighted Metric) 방법

이상적 해(Ideal Solution)와의 거리를 최소화하는 접근법

기본 개념

여러 목적함수를 결합할 때, 각 목적함수의 값과 해당 목적함수의 이상적 해 (Ideal Solution, z^*) 사이의 거리를 최소화하는 방식입니다.

Lp Metric Formulation

$$\text{Minimize} \left(\sum_{m=1}^M w_m |f_m(x) - z_m^*|^p \right)^{1/p}$$

- w_m : 가중치 (User preferences)
- z_m^* : m 번째 목적함수의 이상적(최적) 값
- p : 거리 척도 파라미터 ($1 \leq p \leq \infty$)

주의사항 (단점)

- 이상적 해 z^* 를 미리 알아야 함 (각 목적함수 개별 최적화 필요)
- 목적함수 값들의 스케일링(정규화)이 중요함
- 각 목적함수를 목적공간에서 미분불가능(non-differentiable) 문제가 발생함

p값에 따른 특성 변화

파라미터 p 에 따라 탐색 공간의 형태가 달라집니다.

$p = 1$

가중합(Weighted Sum)과 유사

Manhattan Distance. 모든 편차의 절대값 합을 최소화. 볼록한 문제에 적합.

$p = 2$

유클리드 거리 (Euclidean Distance)

가장 직관적인 거리 개념. 원형 등고선을 형성함.

$p = \infty$

가중 Tchebycheff Metric

$$\min_m \max \{w_m |f_m(x) - z_m^*|\}$$

핵심 장점: 비볼록(Non-convex) 파레토 프론트의 해를 모두 찾을 수 있음.

Why use Weighted Metric?

가중합 방법으로는 찾을 수 없는 비볼록(Non-convex) 영역의 파레토 최적해를 $p = \infty$ (Tchebycheff) 설정을 통해 효과적으로 발견할 수 있습니다.

다목적 진화 알고리즘

Multi-Objective Evolutionary Algorithms (MOEAs)



집단 기반 탐색

Population-based Search

단일 해가 아닌 '해 집합'을 동시에 다루어,
한 번의 실행으로 전체 파레토 프론트를 근
사 가능



비엘리트 MOEAs

Non-Elitist Methods

VEGA, MOGA 등 초기 연구 모델.
엘리트 보존 전략이 없어 우수 해가 소실될
가능성이 있음



엘리트 MOEAs

Elitist Strategies

NSGA-II, SPEA 등 현대적 표준.
우수 해를 다음 세대로 보존하여 수렴성과
해의 품질 보장

전통적 방법 대비 GA의 장점

Advantages of GAs over Traditional Methods



집단 기반 탐색 (Population-Based Search)

전통적 방법은 하나의 해를 개선해 나가지만, 유전 알고리즘(GA)은 **해의 집합(Population)**을 동시에 탐색합니다. 이를 통해 한 번의 실행으로 전체 파레토 최적해 집합을 구할 수 있습니다.



다형성 유지 (Maintaining Diversity)

다양한 개체들로 구성된 집단을 유지함으로써, 특정 지역해(Local Optima)에 빠지는 것을 방지하고 **다양한 트레이드오프 해**를 효과적으로 확보할 수 있습니다.



복잡한 문제에 대한 강인성 (Robustness)

기울기(Gradient) 정보가 필요 없으며, **미분 불가능, 불연속, 비볼록(Non-convex)**한 복잡한 탐색 공간에서도 강인하게 작동합니다.

KEY ADVANTAGES SUMMARY



Single vs Set

단일 해 → 해 집합 동시 탐색



Local vs Global

지역 최적 → 전역 최적 지향



Complex Spaces

비선형/비볼록 문제 해결

비지배 집합 식별: Kung의 알고리즘

Kung's Method for Identifying Non-Dominated Set

1

↓ 전처리 정렬 (Sorting)

첫 번째 목적함수 f_1 을 기준으로 전체 집단 P 를 내림차순 정렬합니다. 정렬을 통해 비교 연산의 효율성을 확보합니다.

2

↗ 분할 (Split)

정렬된 집단 P 를 상위 절반(T , Top)과 하위 절반(B , Bottom)으로 재귀적으로 분할합니다.

$$|P| > 1 \implies T = \text{Front}(P_{\text{top}}), \quad B = \text{Front}(P_{\text{bottom}})$$

3

🔄 병합 및 필터링 (Merge)

B 의 해들 중 T 의 어떤 해에도 지배되지 않는 해만 남겨 병합합니다. T 는 이미 상위 순위이므로 B 를 지배할 가능성이 있습니다.

$$M = T \cup \{i \in B \mid i \text{ is not dominated by any } t \in T\}$$

</> Pseudocode Logic

재귀 함수 $\text{Front}(P)$ 의 구조:

```
IF |P| = 1: Return P ELSE: T =  
Front(P[1 : |P|/2]) B = Front(P[|P|/2  
+ 1 : |P|]) M = T FOR each solution i  
in B: IF i is not dominated by any in  
T: M = M ∪ {i} Return M END
```

⌚ 시간 복잡도

단순 비교 $O(MN^2)$ 대비 효율적입니다.

COMPUTATIONAL COMPLEXITY

$$O(N(\log N)^{M-2})$$

($M = 2$ 인 경우 $O(N \log N)$)

엘리트 MOEAs 개요

Elitist Multi-Objective Evolutionary Algorithms



엘리트 보존 전략 (Elite Preservation)

이전 세대에서 발견된 우수한 비지배 해(Non-dominated solutions)를 **손실 없이 다음 세대로 전달**하는 메커니즘입니다. 무작위적 연산으로 인해 좋은 해가 사라지는 것을 방지합니다.



수렴성 향상 및 보장

엘리트주의(Elitism)는 알고리즘의 수렴 속도를 높이며, 특정 조건 하에서 **전역 최적해(Global Optimal)로의 수렴**을 수학적으로 보장합니다 (Rudolph, 1996).

REPRESENTATIVE ALGORITHMS



NSGA-II

Elitist Non-dominated Sorting GA



SPEA / SPEA2

Strength Pareto Evolutionary Algorithm



PAES

Pareto-Archived Evolution Strategy

NSGA-II 알고리즘

Elitist Non-Dominated Sorting Genetic Algorithm II

1

🧩 통합 및 비지배 정렬 (Combine & Sort)

부모 집단 P_t 와 자식 집단 Q_t 를 합친 R_t (크기 $2N$)를 생성합니다. 이 전체 집단에 대해 비지배 정렬을 수행하여 프론트 $F_1, F_2, \dots$ 를 구분합니다.

$$R_t = P_t \cup Q_t \xrightarrow{\text{Sort}} \{F_1, F_2, \dots, F_k\}$$

2

📉 엘리트 보존 및 채우기 (Elitist Fill)

상위 프론트 F_1 부터 차례대로 다음 세대 P_{t+1} 에 추가합니다. 크기 N 을 초과하게 되는 경계 프론트 F_i 에서 멈춥니다.

3

📏 혼잡도 거리 계산 (Crowding Distance)

경계 프론트 F_i 내에서 어떤 해를 선택할지 결정하기 위해 혼잡도 거리를 계산합니다. 밀집도가 낮은(거리가 큰) 해를 우선 선택하여 다양성을 유지합니다.

⚙️ 핵심 메커니즘

Crowding Distance (혼잡도 거리)

해의 분포 다양성을 유지하기 위한 지표. 동일 프론트 내에서 인접한 해들과의 거리 합으로 계산됩니다.

$$d_i = \sum_{m=1}^M \frac{f_m(i+1) - f_m(i-1)}{f_m^{\max} - f_m^{\min}}$$

Crowded Selection Operator ($\prec_n$)

토너먼트 선택 시 해 i 가 해 j 보다 우월할 조건:

- Rank가 더 낮은 경우 ($r_i < r_j$)
- Rank가 같으면 Distance가 더 큰 경우

SELECTION LOGIC

$$i \prec_n j \text{ if } (r_i < r_j) \text{ or } (r_i = r_j \text{ and } d_i > d_j)$$

SPEA (Strength Pareto EA)

외부 아카이브와 클러스터링을 활용한 엘리트 보존 전략

외부 아카이브 (External Archive)

탐색 중 발견된 비지배 해(Non-dominated solutions)들을 별도의 저장소(외부 아카이브)에 보존하여 엘리트주의를 구현합니다.

클러스터링 (Clustering)

아카이브 크기가 제한(N')을 초과할 경우, 해들 사이의 거리가 가까운 군집(Cluster)을 병합하여 해의 다양성(Diversity)과 분포를 유지합니다.

적합도 평가 (Fitness)

Strength (S): 외부 해가 지배하는 내부 해의 수에 비례

Fitness (F): 자신을 지배하는 외부 해들의 S 합

작을수록 좋은 적합도 (Minimization)

알고리즘 단계

Zitzler & Thiele (1998)

1 초기화 (Initialization)

초기 모집단 P_0 생성 및 빈 외부 아카이브 P'_0 준비

2 비지배 해 복사 (Copy)

현재 모집단 P_t 의 비지배 해를 찾아 아카이브 P'_t 에 추가

3 아카이브 업데이트 (Pruning)

아카이브 내에서 지배되는 해 제거. 만약 $|P'_t| > N'$ 이면 클러스터링으로 크기 축소

4 적합도 계산 (Fitness Eval)

아카이브와 모집단의 모든 해에 대해 적합도 부여 (Strength 기반)

5 진화 연산 (Evolution)

이진 토너먼트 선택, 교차, 변이를 통해 다음 세대 P_{t+1} 생성 ($P_t \cup P'_t$ 활용)

NSGA-II vs SPEA 비교

Comparison of Major Elitist Multi-Objective Evolutionary Algorithms

NSGA-II

Elitist Non-Dominated Sorting GA

⚙️ 핵심 메커니즘

Crowding Distance (혼잡도 거리)
별도의 외부 저장소 없이, 혼잡도 계산을 통해 다양성을 유지함

👍 장점 (PROS)

- ✅ **파라미터 프리:** 추가적인 파라미터(예: 아카이브 크기) 설정 불필요
- ✅ **다양성 유지:** Crowding Distance로 프론트 내 해의 분포를 효과적으로 유지

⚠️ 한계 (LIMITATIONS)

- ❌ 첫 번째 프론트 크기가 $\setminus(N)$ 을 초과할 경우, 일부 파레토 최적해가 손실될 수 있음 (Truncation)



SPEA

Strength Pareto Evolutionary Algorithm

📁 핵심 메커니즘

External Archive & Clustering
외부 아카이브에 엘리트 보존, 클러스터링으로 분포 조절

👍 장점 (PROS)

- ✅ **확실한 엘리트 보존:** 발견된 모든 비지배 해를 아카이브에 안전하게 저장
- ✅ **균일한 분포:** 클러스터링 기법을 통해 해의 분포를 고르게 조정

⚠️ 한계 (LIMITATIONS)

- ❌ 아카이브 크기 설정에 민감함 (너무 크면 선택압 저하, 작으면 엘리트 손실)
- ❌ 클러스터링 연산 비용이 높음

요약 및 참고문헌

Summary & References



MOO 핵심 개념

- **비지배성 (Non-dominance):** 해의 우열 판단 기준
- **파레토 프론트 (Pareto Front):** 최적의 트레이드오프 해 집합
- **두 가지 목표:** 최적해에 근접(Convergence) + 넓은 분포(Diversity)



고전적 방법론

- 가중합 / ϵ -제약 / 메트릭 방법
- 문제 구조(볼록성)와 파라미터에 민감함
- 한 번의 실행으로 하나의 해만 도출 가능



다목적 진화 알고리즘

- **집단 기반 (Population-based):** 한 번에 해 집합 탐색
- **엘리트주의 (Elitism):** 우수 해 보존으로 수렴성 보장
- 비볼록, 불연속 문제에 강인함

주요 알고리즘 메커니즘 요약

NSGA-II

빠른 비지배 정렬 + 혼잡도 거리 (Crowding Distance)
별도의 파라미터 없이 다양성을 유지하며, 구현이 비교적 간단하여 널리 사용됨.

SPEA

외부 아카이브 (Archive) + 클러스터링 (Clustering)
확실한 엘리트 보존과 균일한 분포를 보장하지만, 아카이브 크기 설정에 민감함.

SUGGESTED READING

K. Deb, *Multi-Objective Optimization using Evolutionary Algorithms*, John Wiley & Sons, Inc., 2001.