

빅데이터 연습문제

Q1. 다음 단어 집합을 Bag-of-Words 방식으로 벡터화하시오. (대소문자 무시)

['Grape', 'orange', 'melon', 'Orange', 'Peach', 'grape']

Q2. 제조 회사는 전체 불량률 0.2%를 유지하고 있다. 품질 체크 부서를 기존 1 개에서 5 개로 늘린다. Bonferroni Correction 가정 시 각 부서의 허용 불량률은?

Q3. 정규화(Normalization)의 필요성을 1 가지 이상 설명하시오.

Q4. 버스 대기시간 데이터 wait_time=[2,5,12,18,18,25,33,35,1,7]

1) PMF 에서 $P(X = 18)$ 과 $P(X = 7)$ 을 계산하시오.

2) CDF 에서 $P(X \leq 20)$ 을 구하시오.

Q5. 다음 RDD 연산 중 Transformation 만 모두 고르시오

함수명	반환형
flatMap()	$RDD[T] \rightarrow RDD[U]$
reduceByKey()	$RDD[(K,V)] \rightarrow RDD[(K,V)]$
collect()	$RDD[T] \rightarrow \text{Array}[T]$
take(5)	$RDD[T] \rightarrow \text{Array}[T]$
distinct()	$RDD[T] \rightarrow RDD[T]$

Q6. 다음 데이터에서 결측정보를 확인하세요. 결측치가 MCAR, MAR 여부인지 확인하세요. MNAR 에 대한 가능성이 있다고 할때, 그에 대한 예시를 적으시오.

ID	나이	근무경력(년)	급여	거주지
1	28	2	3200	서울
2	39	-	4500	부산
3	-	10	-	대전
4	45	20	7000	-
5	30	5	3800	서울

Q7. Spark 에서 하나의 Job 이 실행되는 과정에서 나타나는 Stage-Task 구조를 계층(Hierarchy) 관점에서 설명하시오.

Q8. 다음 Spark 코드의 line 번호 중 cache 가 영향을 미치는 구간(연산 line)을 모두 쓰시오.

```
1 val data = sc.textFile("hdfs://...")  
2 val filtered = data.filter(_.contains("INFO"))  
3 val parsed = filtered.map(_.split(","))  
4 parsed.cache()  
5 parsed.filter(_(2).toInt > 50).count()
```

Q9. 4 일 동안의 지각 학생 수에 대한 관측값과 기대값이 다음과 같을 때, 유의수준 5%에서 귀무가설(“요일 간 차이가 없다”)의 기각 여부를 판단하시오.

요일	관측값	기대값
월	5	7
화	10	7
수	8	7
목	5	7

(자유도 $df = 3$, 표 제공됨)

Q10. 다음은 임의의 3×3 행렬 A 에 대한 SVD 결과이다. SVD 의 특이값은 다음과 같다.

$$\sigma_1 = 7, \sigma_2 = 3, \sigma_3 = 1$$

- 차원 축소로, 상위 $k=2$ 개만 취하는 경우, 전체 에너지 대비 오차의 비율(오차율, Error Ratio)을 계산하시오.

Q11. Bloom Filter 정보가 다음과 같을 때, false positive 가 발생할 수 있는 원소를 찾으시오.

bit array size = 12

hash functions:

$$h_1(x) = x \% 12$$

$$h_2(x) = (x // 10 + x \% 10) \% 12$$

inserted items: [15, 27, 39]

test items: [11, 24, 36, 51]

Q12. 다음 데이터는 Flajolet-Martin 알고리즘에서 해시 결과이다. 가장 오른쪽 1 이 처음 등장하는 위치를 기반으로 고유 원소 수를 추정하시오..

값	해시값 (8bit)
A	01010000
B	00010010
C	00100000
D	10000001

Q13. Spearman Correlation 계산 결과, 국어 성적과 영어 성적 간의 순위 상관계수 $\rho = 0.92$ 가 도출되었다. 이 결과의 의미를 서술하시오.