

컴퓨터 비전

Computer Vision

- 최근 깊이 추정 및 3D 복원 관련 기술들 -


동아대학교 소프트웨어대학 AI학과
2026년 1학기

임 한 신



최근 깊이 추정 기술

- Depth Anything (CVPR 2024)




Depth Anything v3

- 단안 깊이 추정(Monocular Depth Estimation) 분야의 대표적인 파운데이션 모델(Foundation Model)
- 준지도 학습(Semi-Supervised Learning), Knowledge distillation(Student-Teacher model)을 기반으로 학습 수행
- Dinov2를 encoder로 사용
- DPT (Dense Prediction Transformer)를 decoder로 사용



최근 깊이 추정 기술

- Depth Anything (CVPR 2024)




Depth Anything v3

- 현재 v3 까지 나옴(ICLR 2026)
- Metric scale 지원(v1)
- DA3-Giant, DA3-Large, DA3-Base, DA3-Small 의 다양한 모델 사이즈를 지원(v2)
- Dual-DPT head로 깊이맵과 픽셀 별 광선을 동시에 예측(v3)




최근 깊이 추정 기술

- Depth Anything (CVPR 2024)



Depth Anything v3 결과(단안, metric)




Depth Anything v3 결과(1, 2, 13장)



Vision Transformer(ViT) 모델

- Vision Transformer(비전 트랜스포머, ViT)




Vision Transformer의 기본 구조

- 자연어 처리에 사용되었던 Transformer 구조를 영상 처리에 적용한 딥러닝 모델
- 입력 영상을 정사각형 패치로 쪼개고 이를 1D 벡터로 펼친 뒤 위치 벡터를 더해주고 transformer에 입력
- Transformer encoder에서는 패치들 간의 연관성을 계산하는 셀프 어텐션(Self-Attention) 연산을 수행



Vision Transformer(ViT) 모델

- DINO(Distillation with No Labels)




- Meta AI(FAIR)에서 개발한 자기주도 학습(Self-Supervised Learning) 기반의 비전 트랜스포머 (ViT) 학습 알고리즘 및 이를 통해 학습된 ViT encoder
- 동일한 구조의 두 신경망인 teacher model과 student model을 두고 두 model이 같은 이미지의 서로 다른 크롭(글로벌 뷰, 로컬 뷰)을 보고 동일한 표현을 갖도록 학습함으로써 정답 레이블 없이도 객체, 경계, 의미론적 구조를 스스로 학습하도록 함



Vision Transformer(ViT) 모델


- DINO(Distillation with No Labels)



- 레이블이 없어도 부분과 전체의 비주얼을 매칭하는 과정에서 모델 내부의 셀프 어텐션 헤드 (Self-Attention Heads)가 물체의 edge와 segmentation mask를 자연스럽게 발달시키게 됨
- 현재 v3까지 나옴(2025)
- v3에서는 약 17억 장의 비지도 데이터셋을 학습에 사용. 또한 7B의 파라미터 모델까지 지원
- 영상 처리 및 컴퓨터 비전의 다양한 분야의 backbone으로 사용되고 있음



NeRF(Neural Radiance Fields)



- 기본적인 목표는 3D Scene을 Implicit하게 구성하는 MLP(Multi-Layer Perceptron)을 이용하여 가상시점의 영상을 구성하는 것
- 장면을 각 지점(x, y, z) 및 방향(θ, ϕ)을 입력하여 광도(Radiance)와 밀도를 출력하는 연속적인 5D 함수로 표현하며 이를 카메라 광선(Ray)을 따라 샘플링하여 색상(광도)과 밀도(불투명도)를 예측하도록 학습
- 이후 MLP를 통해 예측된 카메라 광선 상의 색상과 밀도로부터 Volume Rendering 기법을 통해 가상시점 영상을 생성
- 학습 시에는 실제 영상과 생성된 영상 사이의 오차를 미분해 파라미터의 학습을 수행함



NeRF(Neural Radiance Fields)

- Volume Rendering


- 광선을 따라 3D 공간의 밀도와 색상을 적분하여 최종 픽셀 색을 계산하는 렌더링 기법
- 실제 계산에는 적분을 그대로 계산할 수 없어 광선을 정해진 개수(N)의 샘플로 쪼개어 계산하는 이산적 볼륨 렌더링(Discrete Volume Rendering) 공식을 사용

$$\hat{C}(\mathbf{r}) = \sum_{i=1}^N T_i \cdot \alpha_i \cdot \mathbf{c}_i$$

$\delta_i = t_{i+1} - t_i$: 샘플 i 와 $i+1$ 사이의 간격

$\alpha_i = 1 - \exp(-\sigma_i \delta_i)$: 샘플 구간 i 에서의 불투명도(Opacity). 밀도(σ_i)가 높거나 구간(δ_i)이 길수록 불투명해짐

$T_i = \prod_{j=1}^{i-1} (1 - \alpha_j)$: 현재 샘플 i 에 도달할 때까지 앞선 구간들을 통과하고 살아남은 투과도.
앞선 구간들의 투명도($(1-\alpha)$)를 모두 곱한 값




NeRF(Neural Radiance Fields)

- NeRF의 장점
 - 기존의 메쉬(Mesh)나 포인트 클라우드(Point Cloud) 방식으로는 표현하기 힘들었던 투명한 유리, 반사되는 금속 재질, 털, 연기, 미세한 불빛 등을 잘 표현
 - 3D 기하학적 구조(Topology)의 제약이 없음
- NeRF의 단점
 - 장면 하나를 학습하기 위한 시간이 필요
 - 픽셀 하나를 그릴 때마다 수많은 광선 상의 점들을 신경망에 통과시켜야 하므로 렌더링에 비교적 시간이 걸림
 - 편집 및 재사용이 어려움




3D Gaussian Splatting



- 3D Gaussian들을 Primitive로 하여 장면을 Explicit하게 표현
- 각각의 3D Gaussian들은 일반적으로 위치, 회전, 크기, 색상, 불투명도를 파라미터로 가지게 됨
- 3D Gaussian들을 Primitive로 사용함으로써 Differentiable Pipeline이 가능하도록 설계함
- 렌더링 시에는 타겟 영상의 타일별로 3D Gaussian들을 깊이에 따라 재배열하였고, 이에 기반하여 병렬처리를 통한 효율적인 렌더링이 가능



3D Gaussian Splatting



3DGS의 기본 개념



- 3D Gaussian들을 Primitive로 하여 장면을 Explicit하게 표현
- 각각의 3D Gaussian들은 일반적으로 위치, 회전, 크기, 색상, 불투명도를 파라미터로 가지게 됨
- 3D Gaussian들을 Primitive로 사용함으로써 Differentiable Pipeline이 가능하도록 설계함
- 렌더링 시에는 타겟 영상의 타일별로 3D Gaussian들을 깊이에 따라 재배열하였고, 이에 기반하여 병렬처리를 통한 효율적인 렌더링이 가능



3D Gaussian Splatting

- 4DGS(4D Gaussian Splatting)
 - 3DGS 기술을 동적 영상으로 확장한 기술
 - 정적 장면의 표현을 기본으로 하는 3DGS을 바탕으로 시간의 변화에 따른 gaussian들의 변화를 정확하고 효율적으로 표현하는 것을 목표로 함
 - Gaussian들의 파라미터들의 시간의 변화에 따른 deformation 값을 추정하고 이를 시간에 따라 업데이트하거나 시간이라는 매개변수 t 를 통한 함수의 값으로 표현



4DGS 데모



Generalizable Neural Rendering

- Neural Rendering(뉴럴 렌더링)
 - 컴퓨터 그래픽스와 인공지능이 결합된 하이브리드 기술로, 딥러닝(인공신경망)을 활용하여 3D 공간이나 물체를 표현하고 이를 2D 이미지로 생성(렌더링)하는 기술
 - 대표적인 기술
 - NeRF(Neural Radiance Fields)
 - 3D Gaussian Splatting (3DGS)
 - 약점
 - 장면의 표현을 위한 네트워크 또는 3D Gaussian들의 파라미터들은 장면별로 최적화 또는 학습 과정이 필요함




Generalizable Neural Rendering

- Generalizable Neural Rendering(일반화 가능 뉴럴 렌더링)
 - 기존 neural rendering 기술의 가장 큰 단점이었던 "장면마다 새로 학습(Per-scene Optimization)해야 한다"는 문제를 해결하기 위한 기술
 - 사전에 대규모 데이터로 학습된 하나의 피드-포워드(Feed-forward) 네트워크를 사용
 - 이를 통해 별도의 추가 학습 없이 실시간 또는 고속으로 3D 공간의 정보를 즉시 추론해 냄



Generalizable Neural Rendering

- 최근 Generalizable Neural Rendering 방법 예
 - GPS-Gaussian (CVPR 2024)




- 학습데이터를 이용하여 depth 정보 추정 네트워크와 3D Gaussian들의 파라미터를 추정하는 네트워크를 사전 학습시킴
- 추론 시에는 사전 학습된 네트워크를 통해 Feed-forward 방식으로 Gaussian 파라미터를 추정 및 영상 합성을 수행



Generalizable Neural Rendering

- 최근 Generalizable Neural Rendering 방법 예
 - MonoSplat (CVPR 2025)



- 단안 깊이 추정 파운데이션 모델의 강력한 기하학적 사전 지식(Visual Prior)을 활용
- 단안 특징들의 부족한 기하학적 일관성을 경량 어텐션 메커니즘(Lightweight Attention)을 사용하여 보완



정리

- 최근 ViT encoder를 backbone으로 하는 다양한 foundation model들이 연구되고 있음
- 영상으로부터 깊이를 추정하고 3D 구조를 추정하는 foundation model에 대한 연구가 활발히 진행되고 있고 이전보다 일반화 능력 및 정확도에서 상당히 좋은 결과를 보여주고 있음
- NeRF, 3DGS 등 neural rendering 기술에 관한 많은 연구들이 진행되고 있고 다양한 응용분야로 확대되고 있음
- 또한 최근에는 Feed-Forward 방식의 Generalizable Neural Rendering 모델들이 제안되면서 기존의 장면별 최적화 기반 방법의 한계를 극복하려는 연구가 활발히 이루어지고 있음
- NeRF, 3DGS 등 neural rendering 뿐만 아니라 다양한 컴퓨터 비전 기술들이 컴퓨터 그래픽스 분야와 융합되고 경계가 허물어지고 있음



Quiz

1. 다음 중 3D 장면의 explicit 표현법이 아닌 것은?
 - ① 메쉬
 - ② 3D 가우시안
 - ③ 포인트 클라우드
 - ④ 네트워크 파라미터

2. 다음 depth anything에 대한 설명 중 잘못된 것은?
 - ① Teacher-student model로 학습한다.
 - ② DINO를 encoder로 사용한다.
 - ③ 카메라 파라미터를 알아야 한다.
 - ④ Metric scale을 지원한다.

