

Dong-A Univ. (ISPL)



동아대학교
DONG-A UNIVERSITY

Linear Regression 이론

컴퓨터공학부 컴퓨터공학과
머신러닝

Linear Regression

회귀 (Regression)


- 관측된 데이터를 통해 변수 사이의 숨어있는 관계를 추정하는 것
- 변수 y 를 오염도, x 를 약품 투입량으로 가정했을 때, **기존의 데이터를 이용하여 $y = wx + b$ 수식 생성**

변수 x	변수 y
사람의 키	사람의 몸무게
주택의 크기	주택의 가격
공부 시간	시험 점수
약품 투입량	오염도
...	...

Linear Regression

회귀 (Regression)

- 관측된 데이터를 통해 변수 사이의 숨어있는 관계를 추정하는 것
- 변수 y 를 오염도, x 를 약품 투입량으로 가정했을 때, 기존의 데이터를 이용하여 $y = wx + b$ 수식 생성
- 이후 신규 데이터를 이용하여 오염도 예측





회귀 분석을 통해 두 개의 수식 중
오차가 더 작은 수식 탐색

Linear Regression

■ 선형 회귀 (Linear Regression)


- 선형회귀: 변수 사이의 숨어있는 관계를 1차원 수식으로 표현 ($y = wx + b$)
- 비선형회귀: 변수 사이의 숨어있는 관계를 2차원 이상의 수식으로 표현 ($y = w_1x^n + w_2x^{n-1} \dots w_nx + b$)



Linear Regression

■ 문제 해결방법

- Ordinary Least Squares method (OLS)
= Least Squares Method (LSM)
= Normal Equation
- Gradient Descent method (GD)




단일 선형회귀 예시

Linear Regression

▪ Ordinary Least Squares method (OLS)

- 아래 예시 data를 이용하여 선형회귀 진행 (최적의 $\theta (w, b)$ 탐색)




$$X = \begin{bmatrix} -3 \\ -1 \\ 1 \\ 3 \end{bmatrix} \quad Y = \begin{bmatrix} -1 \\ -1 \\ 3 \\ 3 \end{bmatrix} \quad \theta = \begin{bmatrix} w \\ b \end{bmatrix}$$

4x1 4x1 2x1

Linear Regression

▪ Ordinary Least Squares method (OLS)

- 아래 예시 data를 이용하여 선형회귀 진행 (최적의 $\theta (w, b)$ 탐색)



$$X = \begin{bmatrix} -3 & 1 \\ -1 & 1 \\ 1 & 1 \\ 3 & 1 \end{bmatrix} \quad Y = \begin{bmatrix} -1 \\ -1 \\ 3 \\ 3 \end{bmatrix} \quad \theta = \begin{bmatrix} w \\ b \end{bmatrix}$$

4x2 4x1 2x1


bias

$$X\theta = \hat{Y} \quad \diamond \text{ 최종목표: } Y = \hat{Y} \text{ 가 되는 } \theta \text{ 탐색}$$

Linear Regression

▪ Ordinary Least Squares method (OLS)

- 아래 예시 data를 이용하여 선형회귀 진행 (최적의 $\theta (w, b)$ 탐색)



$$X = \begin{bmatrix} -3 & 1 \\ -1 & 1 \\ 1 & 1 \\ 3 & 1 \end{bmatrix} \quad Y = \begin{bmatrix} -1 \\ -1 \\ 3 \\ 3 \end{bmatrix} \quad \theta = \begin{bmatrix} w \\ b \end{bmatrix}$$

4x2 4x1 2x1

bias


$$X\theta = \hat{Y} \quad \diamond \text{ 최종목표: } Y = \hat{Y} \text{ 가 되는 } \theta \text{ 탐색}$$

$$\theta = X^{-1} \cdot Y \quad \rightarrow X \text{가 정방행렬이 아니기 때문에 불가능}$$

Linear Regression

▪ Ordinary Least Squares method (OLS)

- 아래 예시 data를 이용하여 선형회귀 진행 (최적의 $\theta (w, b)$ 탐색)



$$X = \begin{bmatrix} -3 & 1 \\ -1 & 1 \\ 1 & 1 \\ 3 & 1 \end{bmatrix} \quad Y = \begin{bmatrix} -1 \\ -1 \\ 3 \\ 3 \end{bmatrix} \quad \theta = \begin{bmatrix} w \\ b \end{bmatrix}$$

4×2 4×1 2×1

bias


$$X\theta = \hat{Y} \quad \diamond \text{ 최종목표: } Y = \hat{Y} \text{ 가 되는 } \theta \text{ 탐색}$$

$$(X^T \cdot X)\theta = X^T \cdot Y$$

Linear Regression

▪ Ordinary Least Squares method (OLS)

- 아래 예시 data를 이용하여 선형회귀 진행 (최적의 $\theta (w, b)$ 탐색)



$$X = \begin{bmatrix} -3 & 1 \\ -1 & 1 \\ 1 & 1 \\ 3 & 1 \end{bmatrix} \quad Y = \begin{bmatrix} -1 \\ -1 \\ 3 \\ 3 \end{bmatrix} \quad \theta = \begin{bmatrix} w \\ b \end{bmatrix}$$

4x2 4x1 2x1

bias

$$X\theta = \hat{Y} \quad \diamond \text{ 최종목표: } Y = \hat{Y} \text{ 가 되는 } \theta \text{ 탐색}$$

$$(X^T \cdot X)\theta = X^T \cdot Y$$


$$\cancel{(X^T \cdot X)^{-1} \cdot (X^T \cdot X)}\theta = (X^T \cdot X)^{-1} \cdot (X^T \cdot Y)$$

→ $(X^T \cdot X)^{-1}$ 를 양변에 곱하여 θ 계산

Linear Regression

▪ Ordinary Least Squares method (OLS)

- 아래 예시 data를 이용하여 선형회귀 진행 (최적의 $\theta (w, b)$ 탐색)



$$X = \begin{bmatrix} -3 & 1 \\ -1 & 1 \\ 1 & 1 \\ 3 & 1 \end{bmatrix} \quad Y = \begin{bmatrix} -1 \\ -1 \\ 3 \\ 3 \end{bmatrix} \quad \theta = \begin{bmatrix} w \\ b \end{bmatrix}$$

4x2 4x1 2x1

bias


$$\theta = (X^T \cdot X)^{-1} \cdot (X^T \cdot Y)$$

$$\theta = \begin{bmatrix} 0.8 \\ 1 \end{bmatrix}$$

Linear Regression

▪ Gradient Descent method (GD)

- 예측 값($\hat{Y}$) 과 정답 값(Y) 간의 차이를 이용하여 θ 를 업데이트하며 최적의 θ 를 탐색하는 방법



bias

$$X = \begin{bmatrix} -3 & 1 \\ -1 & 1 \\ 1 & 1 \\ 3 & 1 \end{bmatrix} \quad Y = \begin{bmatrix} -1 \\ -1 \\ 3 \\ 3 \end{bmatrix} \quad \theta = \begin{bmatrix} w \\ b \end{bmatrix}$$

4x2 4x1 2x1

$$X\theta = \hat{Y}$$


$$Loss = \frac{1}{N} \sum (Y - \hat{Y})^2$$

❖ 평균제곱오차 (Mean Square Error (MSE))

Linear Regression

▪ Gradient Descent method (GD)

- 예측 값($\hat{Y}$) 과 정답 값(Y) 간의 차이를 이용하여 θ 를 업데이트하며 최적의 θ 를 탐색하는 방법



$$X = \begin{bmatrix} -3 & 1 \\ -1 & 1 \\ 1 & 1 \\ 3 & 1 \end{bmatrix} \quad Y = \begin{bmatrix} -1 \\ -1 \\ 3 \\ 3 \end{bmatrix} \quad \theta = \begin{bmatrix} w \\ b \end{bmatrix}$$

4x2 4x1 2x1

$$X\theta = \hat{Y}$$


$$Loss = \frac{1}{N} \sum (Y - \hat{Y})^2$$

❖ 평균제곱오차 (Mean Square Error (MSE))

Linear Regression

▪ Gradient Descent method (GD)

- 현재 지점에서 Loss 값을 θ 에 대한 편미분을 통해 gradient 계산
- Gradient에 learning rate를 곱하고 반대방향으로 weight 업데이트




$$\theta_{t+1} = \theta_t - \underbrace{\alpha}_{\text{Learning rate}} \underbrace{\frac{\partial L}{\partial \theta_t}}_{\text{Gradient}}$$

Linear Regression

▪ Gradient Descent method (GD)

- 현재 지점에서 Loss 값을 θ 에 대한 편미분을 통해 gradient 계산
- Gradient에 learning rate를 곱하고 반대방향으로 weight 업데이트





$$\theta_{t+1} = \theta_t - \alpha \frac{\partial L}{\partial \theta_t}$$
$$= \theta_t - 0.08$$

Linear Regression

▪ Gradient Descent method (GD)

- 현재 지점에서 Loss 값을 θ 에 대한 편미분을 통해 gradient 계산
- Gradient에 learning rate를 곱하고 반대방향으로 weight 업데이트
 - Learning rate: 파라미터를 얼마나 업데이트할 지 정하는 **하이퍼파라미터**



❖ α : Learning rate

Linear Regression

- Gradient Descent method (GD)

$$\hat{Y} = wx + b$$

$$Loss = \frac{1}{N} \sum (Y - \hat{Y})^2$$

$$= \frac{1}{N} \sum (Y - wx_i - b)^2 \quad \rightarrow \hat{Y} = wx + b \text{ 대입}$$

Linear Regression

- Gradient Descent method (GD)

$$\hat{Y} = wx + b$$

$$Loss = \frac{1}{N} \sum (Y - \hat{Y})^2$$

$$= \frac{1}{N} \sum (Y - wx_i - b)^2$$

$$\frac{\partial L}{\partial w} = \frac{1}{N} \times 2 \times \sum (Y - wx_i - b) \times -x_i$$

$$\approx \frac{2}{N} \sum (Y - \hat{Y}) \times -X$$

→ w에 대한 편미분

Linear Regression

- Gradient Descent method (GD)

$$\hat{Y} = wx + b$$

$$Loss = \frac{1}{N} \sum (Y - \hat{Y})^2$$

$$= \frac{1}{N} \sum (Y - wx_i - b)^2$$

$$\frac{\partial L}{\partial w} = \frac{1}{N} \times 2 \times \sum (Y - wx_i - b) \times -x_i$$

$$\approx \frac{2}{N} \sum (Y - \hat{Y}) \times -X$$

$$\frac{\partial L}{\partial b} = \frac{1}{N} \times 2 \times \sum (Y - wx_i - b) \times -1$$

$$\approx \frac{2}{N} \sum (Y - \hat{Y}) \times -1$$

→ b에 대한 편미분

Linear Regression

- Gradient Descent method (GD)

$$\hat{Y} = wx + b$$

$$Loss = \frac{1}{N} \sum (Y - \hat{Y})^2$$

$$= \frac{1}{N} \sum (Y - wx_i - b)^2$$

$$w_{t+1} = w_t - \alpha \times \frac{\partial L}{\partial w}$$

$$b_{t+1} = b_t - \alpha \times \frac{\partial L}{\partial b}$$

$$\frac{\partial L}{\partial w} = \frac{1}{N} \times 2 \times \sum (Y - wx_i - b) \times -x_i$$

$$\approx \frac{2}{N} \sum (Y - \hat{Y}) \times -X$$

$$\frac{\partial L}{\partial b} = \frac{1}{N} \times 2 \times \sum (Y - wx_i - b) \times -1$$

$$\approx \frac{2}{N} \sum (Y - \hat{Y}) \times -1$$



Questions & Answers

Dongsan Jun (dsjun@dau.ac.kr)

Image Signal Processing Laboratory (www.donga-ispl.kr)

Dept. of Computer Engineering

Dong-A University, Busan, Rep. of Korea

