


LLM 기초 – RNN, LSTM

컴퓨터AI공학부
2025년 1학기 머신러닝



Large Language Model (LLM)

- **Language Model**

- 인간의 언어를 이해하고 생성하기 위해 설계된 인공지능 모델

- **Large Language Model**

- 방대한 양의 데이터에 기반하여 Training된 수많은 Parameter를 가지는 인공지능 모델

Large Language Model (LLM)

- **Language Model**

- 인간의 언어를 이해하고 생성하기 위해 설계된 인공지능 모델

- **Large Language Model**

- 방대한 양의 데이터에 기반하여 Training된 수많은 Parameter를 가지는 인공지능 모델
- 대표적인 LLM: **Chat GPT**




ChatGPT

Generative Pre-trained Transformer

Large Language Model (LLM)

History of Language Model


- 기존 Language model은 RNN 기반으로 설계 되었음
- RNN 기반 모델들의 문제점을 Transformer가 해결하면서 높은 성능을 도출함



Large Language Model (LLM)

History of Language Model

- 기존 Language model은 RNN 기반으로 설계 되었음
- RNN 기반 모델들의 문제점을 Transformer가 해결하면서 높은 성능을 도출함




RNN을 기반으로 설계된 model

Large Language Model (LLM)

History of Language Model

- 기존 Language model은 RNN 기반으로 설계 되었음
- RNN 기반 모델들의 문제점을 Transformer가 해결하면서 높은 성능을 도출함




RNN 기반 Model의 한계점 해결

Large Language Model (LLM)


History of Language Model

- 기존 Language model은 RNN 기반으로 설계 되었음
- RNN 기반 모델들의 문제점을 Transformer가 해결하면서 높은 성능을 도출함



▪ Overview


- 기존의 CNN은 데이터의 공간적인 정보만을 학습함



CNN은 이미지 데이터의 공간적 특징을 추출하여 학습

Overview

- 시간 순서가 있는 데이터 (Time Series Data)를 효율적으로 학습하기 위해 등장
- 순환 구조를 통해서 이전 상태의 정보를 함께 사용하여 현재 상태의 정보 학습



순서가 있는 데이터를 순차적으로 입력하여 학습

■ 시계열 데이터 (Time Series Data)

- 시간의 흐름에 따라 관측되어 시간의 영향을 받게 되는 데이터
- 현재 상태가 과거의 상태에 영향을 받음

Index	Bedrooms	Bathrooms	Sqft_living	Price
0	3	1	1180	221900
1	3	2.25	2570	538000
2	2	1	770	180000
3	4	3	1960	604000
...	...	...	...	...
N	3	2	1680	510000

다변량 데이터 예시 (Kc house dataset)

■ 시계열 데이터 (Time Series Data)

- 시간의 흐름에 따라 관측되어 시간의 영향을 받게 되는 데이터
- 현재 상태가 과거의 상태에 영향을 받음

Index	Bedrooms	Bathrooms	Sqft_living	Price
0	3	1	1180	221900
1	3	2.25	2570	538000
2	2	1	770	180000
3	4	3	1960	604000
...	...	...	...	...
N	3	2	1680	510000

각각의 데이터가 서로 독립적

다변량 데이터 예시 (Kc house dataset)

■ 시계열 데이터 (Time Series Data)

- 시간의 흐름에 따라 관측되어 시간의 영향을 받게 되는 데이터
- 현재 상태가 과거의 상태에 영향을 받음

시간	센서1	센서2	센서3	상태
12:00	0	98.9	3.9	정상
13:00	0	98.9	3.9	정상
14:00	0.3	74.5	6.7	불량
15:00	6.8	98.9	7.9	불량
...	...	...	...	...
24:00	-0.9	78.3	6.6	정상

현재 상태의 데이터가 이전 시점 상태에 영향을 받음

시계열 데이터 예시

■ 시계열 데이터 (Time Series Data)

- 시간의 흐름에 따라 관측되어 시간의 영향을 받게 되는 데이터
- 현재 상태가 과거의 상태에 영향을 받음
- 인간의 언어 또한 각 단어별 순서와 맥락이 시간적 의존성을 가짐

시간	센서1	센서2	센서3	상태
12:00	0	98.9	3.9	정상
13:00	0	98.9	3.9	정상
14:00	0.3	74.5	6.7	불량
15:00	6.8	98.9	7.9	불량
...	...	...	...	...
24:00	-0.9	78.3	6.6	정상

시계열 데이터 예시

“안녕하세요 머신러닝 강의 너무 좋아요”

시간 순서에 영향을 받음

- **인공신경망 (Deep Neural Network, DNN)**
 - Ex) 한글 → 영어 번역 예시 (단어 단위 입력 및 출력)

“나는”



“I”

“머신러닝이”



“Like”


“좋다”



“Machine Learning”

인공신경망 (Deep Neural Network, DNN)

- Ex) 한글 → 영어 번역 예시 (단어 단위 입력 및 출력)



“나는”
↓
“I”

“머신러닝이”
↓
“Like”

“좋다”
↓
“Machine Learning”


$$h_i = f(W_{xh}x_i + bias)$$

$$y_i = f(W_{hy}h_i + bias)$$

❖ f : activation function

인공신경망 (Deep Neural Network, DNN)

- Ex) 한글 → 영어 번역 예시 (단어 단위 입력 및 출력)



“나는”
↓
“I”

“머신러닝이”
↓
“Like”

“좋다”
↓
“Machine Learning”

$$h_i = f(W_{xh}x_i + bias)$$

$$y_i = f(W_{hy}h_i + bias)$$

❖ f : activation function


인공신경망 (Deep Neural Network, DNN)

- Ex) 한글 → 영어 번역 예시 (단어 단위 입력 및 출력)
- 이전 시점의 정보를 반영하지 않아 예측 어려움

“나는”
↓
“I”

“머신러닝이”
↓
“Like”

“좋다”
↓
“Machine Learning”




$$h_i = f(W_{xh}x_i + bias)$$

$$y_i = f(W_{hy}h_i + bias)$$

❖ f : activation function

순환신경망 (Recurrent Neural Network, RNN)


- 이전 시점의 정보를 반영하여 더 나은 예측 수행



RNN


■ 순환신경망 (Recurrent Neural Network, RNN)

- 이전 시점의 정보를 반영하여 더 나은 예측 수행



■ 순환신경망 (Recurrent Neural Network, RNN)



- 이전 시점의 정보를 반영하여 더 나은 예측 수행
- 이전 정보들이 순환 (반복)하여 입력



RNN


■ 순환신경망 (Recurrent Neural Network, RNN)

- 이전 시점의 정보를 반영하여 더 나은 예측 수행
- 이전 정보들이 순환 (반복)하여 입력




■ 순환신경망 구조의 종류

- 순차적인 입력의 길이, 순차적인 예측의 길이에 따라 다음과 같이 구분 가능



■ 순환신경망 구조의 종류


- 순차적인 입력의 길이, 순차적인 예측의 길이에 따라 다음과 같이 구분 가능



Sequence to Sequence

Sequence to Sequence


- 순차적인 X (Many)로 순차적인 Y (Many)를 예측하는 문제
- 예시: 한글 문장이 주어졌을 때 영어 문장으로 번역




RNN

Sequence to Sequence

- 순차적인 X (Many)로 순차적인 Y (Many)를 예측하는 문제
- 예시: 한글 문장이 주어졌을 때 영어 문장으로 번역



Sequence



<SOS>

I

Like

Sequence


나는

머신러닝이

좋다

RNN 학습


- 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})
 - 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)



RNN 학습

■ 학습 파라미터 (W_{hy} , W_{hh} , W_{xh})


- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)



RNN 학습

■ 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})

- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)




$$\frac{\partial Loss}{\partial W_{hy}} = \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial W_{hy} h_t} \times \frac{\partial W_{hy} h_t}{\partial W_{hy}}$$

RNN 학습

■ 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})

- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)




$$\frac{\partial Loss}{\partial W_{hh}} = \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial W_{hh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial W_{hh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial h_{t-2}} \times \frac{\partial h_{t-2}}{\partial W_{hh}}$$

t 시점에서의 영향

RNN 학습

■ 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})

- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)




$$\frac{\partial Loss}{\partial W_{hh}} = \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial W_{hh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial W_{hh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial h_{t-2}} \times \frac{\partial h_{t-2}}{\partial W_{hh}}$$

$t-1$ 시점에서의 영향

RNN 학습

■ 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})

- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)




$$\frac{\partial Loss}{\partial W_{hh}} = \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial W_{hh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial W_{hh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial h_{t-2}} \times \frac{\partial h_{t-2}}{\partial W_{hh}}$$

RNN 학습

■ 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})

- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)




$$\frac{\partial Loss}{\partial W_{hh}} = \sum_{k=0}^t \left(\frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_k} \times \frac{\partial h_k}{\partial W_{hh}} \right)$$

RNN 학습

■ 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})

- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)




$$\frac{\partial Loss}{\partial W_{xh}} = \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial W_{xh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial W_{xh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial h_{t-2}} \times \frac{\partial h_{t-2}}{\partial W_{xh}}$$

t 시점에서의 영향

RNN 학습

■ 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})

- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)




$$\frac{\partial Loss}{\partial W_{xh}} = \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial W_{xh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial W_{xh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial h_{t-2}} \times \frac{\partial h_{t-2}}{\partial W_{xh}}$$

t-1 시점에서의 영향

RNN 학습

■ 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})

- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)




$$\frac{\partial Loss}{\partial W_{xh}} = \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial W_{xh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial W_{xh}} + \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_{t-1}} \times \frac{\partial h_{t-1}}{\partial h_{t-2}} \times \frac{\partial h_{t-2}}{\partial W_{xh}}$$

RNN 학습

■ 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})

- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)




$$\frac{\partial Loss}{\partial W_{xh}} = \sum_{k=0}^t \left(\frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_k} \times \frac{\partial h_k}{\partial W_{xh}} \right)$$

RNN 학습

■ 학습 파라미터 (W_{hy}, W_{hh}, W_{xh})

- 각 파라미터는 매 시점마다 동일한 값을 사용함 (Shared parameter)



$$\frac{\partial Loss}{\partial W_{hy}} = \frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial W_{hy} h_t} \times \frac{\partial W_{hy} h_t}{\partial W_{hy}}$$


$$\frac{\partial Loss}{\partial W_{hh}} = \sum_{k=0}^t \left(\frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_k} \times \frac{\partial h_k}{\partial W_{hh}} \right)$$

$$\frac{\partial Loss}{\partial W_{xh}} = \sum_{k=0}^t \left(\frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_k} \times \frac{\partial h_k}{\partial W_{xh}} \right)$$

RNN의 한계점

장기 의존성 문제 (Long-term dependency problem)

- Sequence의 길이가 길어질수록, 과거 정보 학습에 어려움이 발생함
- 학습 과정 중 기울기 소실 (Vanishing Gradient) 발생




$$\frac{\partial Loss}{\partial W_{hh}} = \dots + \frac{\partial Loss}{\partial \hat{y}_{100}} \times \frac{\partial \hat{y}_{100}}{\partial h_{100}} \times \frac{\partial h_{100}}{\partial h_{99}} \times \frac{\partial h_{99}}{\partial h_{98}} \times \frac{\partial h_{98}}{\partial h_{97}} \times \frac{\partial h_{97}}{\partial h_{96}} \times \dots \times \frac{\partial h_3}{\partial h_2} \times \frac{\partial h_2}{\partial h_1} \times \frac{\partial h_1}{\partial h_0} \times \frac{\partial h_0}{\partial W_{hh}}$$

$t = 0$ 시점에서의 영향

RNN의 한계점

장기 의존성 문제 (Long-term dependency problem)

- Sequence의 길이가 길어질수록, 과거 정보 학습에 어려움이 발생함
- 학습 과정 중 기울기 소실 (Vanishing Gradient) 발생




$$\frac{\partial Loss}{\partial W_{hh}} = \dots + \frac{\partial Loss}{\partial \hat{y}_{100}} \times \frac{\partial \hat{y}_{100}}{\partial h_{100}} \times \overset{0 \sim 1}{\frac{\partial h_{100}}{\partial h_{99}}} \times \overset{0 \sim 1}{\frac{\partial h_{99}}{\partial h_{98}}} \times \overset{0 \sim 1}{\frac{\partial h_{98}}{\partial h_{97}}} \times \overset{0 \sim 1}{\frac{\partial h_{97}}{\partial h_{96}}} \times \dots \times \overset{0 \sim 1}{\frac{\partial h_3}{\partial h_2}} \times \overset{0 \sim 1}{\frac{\partial h_2}{\partial h_1}} \times \overset{0 \sim 1}{\frac{\partial h_1}{\partial h_0}} \times \frac{\partial h_0}{\partial W_{hh}} \approx 0$$

$t = 0$ 시점에서의 영향

RNN의 한계점

장기 의존성 문제 (Long-term dependency problem)

- Sequence의 길이가 길어질수록, 과거 정보 학습에 어려움이 발생함
- 학습 과정 중 기울기 소실 (Vanishing Gradient) 발생



$$\frac{\partial Loss}{\partial W_{hh}} = \dots + \frac{\partial Loss}{\partial \hat{y}_{100}} \times \frac{\partial \hat{y}_{100}}{\partial h_{100}} \times \frac{\partial h_{100}}{\partial h_{99}} \times \frac{\partial h_{99}}{\partial h_{98}} \times \frac{\partial h_{98}}{\partial h_{97}} \times \frac{\partial h_{97}}{\partial h_{96}} \times \dots \times \frac{\partial h_3}{\partial h_2} \times \frac{\partial h_2}{\partial h_1} \times \frac{\partial h_1}{\partial h_0} \times \frac{\partial h_0}{\partial W_{hh}} \approx 0$$

0 ~ 1 0 ~ 1 0 ~ 1 0 ~ 1 0 ~ 1 0 ~ 1 0 ~ 1 0 ~ 1


→ 기울기가 소실되어 parameter가 업데이트 되지 않음

$t = 0$ 시점에서의 영향

RNN의 한계점

장기 의존성 문제 (Long-term dependency problem)


- Ex) 영어 → 한글 번역 (Don't look up → 위를 쳐다보지 마세요.)
- 입력의 "Don't" 과 출력의 "마세요"는 의미상으로 가까운 단어이지만 학습에 반영되지 않는다면 정확도 감소 가능성 존재



LSTM

장단기 메모리 순환신경망 (Long Short-Term Memory)

- RNN의 장기 의존성 문제를 완화한 개선 모델
- Cell state 구조를 제안하고 세가지 gate 추가함




RNN


LSTM

장단기 메모리 순환신경망 (Long Short-Term Memory)

- RNN의 장기 의존성 문제를 완화한 개선 모델
- Cell state 구조를 제안하고 세가지 gate 추가함




RNN



LSTM

장단기 메모리 순환신경망 (Long Short-Term Memory)

- RNN의 장기 의존성 문제를 완화한 개선 모델
- Cell state 구조를 제안하고 세가지 gate 추가함
 - Forget gate(f_t), Input gate(i_t), Output gate(o_t)




LSTM


LSTM

Cell state (C_t)

- LSTM의 핵심 구조로써, 장기적인 정보 (Long term)들을 유지
- 두가지 gate (Forget gate(f_t), Input gate(i_t))를 통해 cell state 업데이트



Cell state




Gate

LSTM

Cell state (C_t)

- Forget gate(f_t): 불필요한 과거 정보를 잊기 위한 gate



Forget gate

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Sigmoid (0 ~ 1 사이 가중치)

다 잊는 경우

$$f_t$$

0	0	0	0	0	0	0
---	---	---	---	---	---	---

$$C_{t-1}$$

0.2	0.1	0.3	0.5	0.2	0.2	0.3
-----	-----	-----	-----	-----	-----	-----


$$f_t \otimes C_{t-1}$$

0	0	0	0	0	0	0
---	---	---	---	---	---	---

LSTM

Cell state (C_t)

- Forget gate(f_t): 불필요한 과거 정보를 잊기 위한 gate



Forget gate

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Sigmoid (0 ~ 1 사이 가중치)

모두 기억하는 경우

f_t	1	1	1	1	1	1	1
-------	---	---	---	---	---	---	---


C_{t-1}	0.2	0.1	0.3	0.5	0.2	0.2	0.3
-----------	-----	-----	-----	-----	-----	-----	-----

$f_t \otimes C_{t-1}$	0.2	0.1	0.3	0.5	0.2	0.2	0.3
-----------------------	-----	-----	-----	-----	-----	-----	-----

LSTM

Cell state (C_t)

- Forget gate(f_t): 불필요한 과거 정보를 잊기 위한 gate
- Input gate(i_t): 현재 정보를 기억하기 위한 gate



Input gate

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$
$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

i_t	0.1	0	0.8	0.2	0.8	0.7	1
-------	-----	---	-----	-----	-----	-----	---


$\tilde{C}_t$	0.1	0.3	0.6	0.2	0.9	0.1	0.4
---------------	-----	-----	-----	-----	-----	-----	-----

$i_t \otimes \tilde{C}_t$	0.01	0	0.48	0.04	0.72	0.07	0.4
---------------------------	------	---	------	------	------	------	-----

LSTM

Cell state (C_t)

- Forget gate(f_t): 불필요한 과거 정보를 잊기 위한 gate
- Input gate(i_t): 현재 정보를 기억하기 위한 gate
- Cell state (C_t) = 불필요한 정보를 제거한 이전 시점의 cell state (C_{t-1}) + 현재 시점의 cell state ($\tilde{C}_t$)




$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

Cell state 업데이트

LSTM

▪ Hidden state (h_t)

- 단기적인 정보 (Short term)을 유지
- Output gate(o_t): Hidden state에 cell state를 얼마나 반영할 것인지에 대한 가중치



$$o_t = \sigma (W_o [h_{t-1}, x_t] + b_o)$$


$$h_t = o_t * \tanh (C_t)$$

Hidden state 업데이트

LSTM

▪ Review

- Cell state (C_t): 현 시점에 대한 장기적인 정보 (Long term)들을 유지
- Hidden state (h_t): 현 시점에 대한 단기적인 정보 (Short term)을 유지



$$f_t = \sigma(W_{xhf}x_t + W_{hhf}h_{t-1} + bias)$$


$$i_t = \sigma(W_{xhi}x_t + W_{hhi}h_{t-1} + bias)$$

$$o_t = \sigma(W_{xho}x_t + W_{hho}h_{t-1} + bias)$$


LSTM의 한계점 및 Transformer

장기의존성 문제

- LSTM을 이용하여 문제를 완화하였으나 여전히 장기의존성 문제가 존재함 → Seq2Seq 방법으로 완화함
- Sequence 길이가 길어지는 경우 한계점 발생



Sequence



<SOS>

I

Like

나는

머신러닝이

좋다

Sequence

LSTM의 한계점 및 Transformer

▪ 장기 의존성 문제

- LSTM을 이용하여 문제를 완화하였으나 여전히 장기 의존성 문제가 존재함
- Sequence 길이가 길어지는 경우 한계점 발생

▪ 병렬처리 문제

- RNN 및 LSTM은 순차적으로 입력, 출력하는 구조이기 때문에 병렬처리가 어려움

▪ Transformer

- Self attention 기법을 활용한 transformer가 위의 문제점을 해결함
- 이후 많은 분야에서 transformer를 이용한 연구 진행 중

Questions & Answers

Dongsan Jun (dsjun@dau.ac.kr)

Image Signal Processing Laboratory (www.donga-ispl.kr)

Division of Computer·AI Engineering

Dong-A University, Busan, Rep. of Korea