Dong-A Univ. (ISPL)

동아대학교
DONG-A UNIVERSITY

Transformer

컴퓨터AI공학부
2025년 1학기 머신러닝

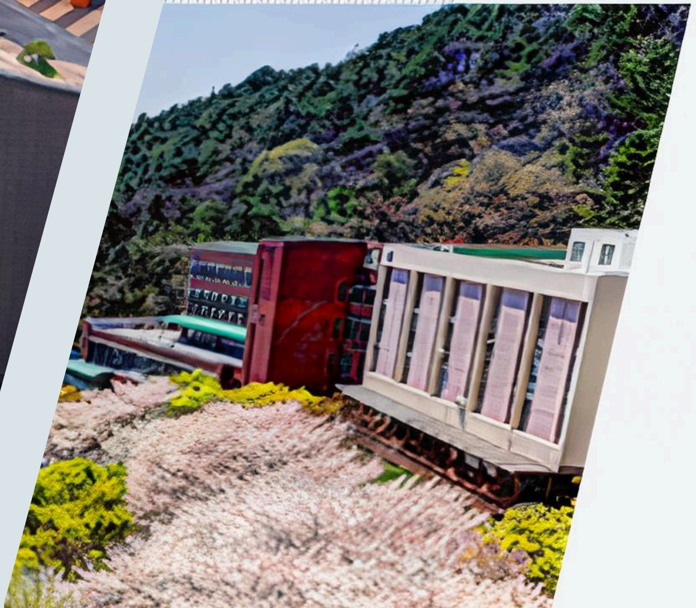

Background of Language Model

- 정의: 언어라는 현상을 모델링하고자 **단어 시퀀스(문장)에 확률을 할당(assign)**하는 모델
- 목적: 가장 자연스러운 단어 시퀀스를 찾아내는 것
- 방법: **통계(확률)를 이용한 방법**과 **인공 신경망을 이용한 방법**으로 구분

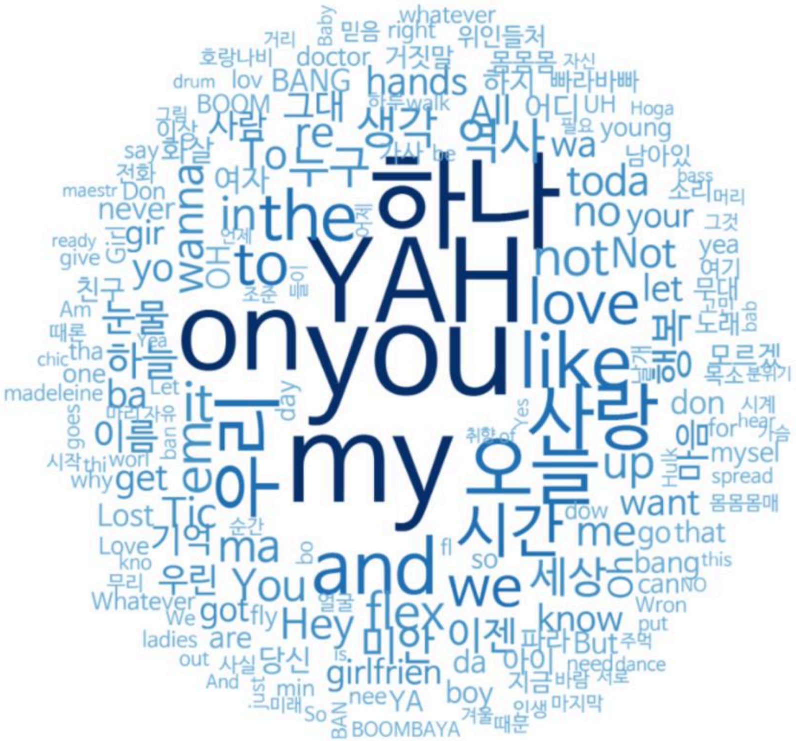

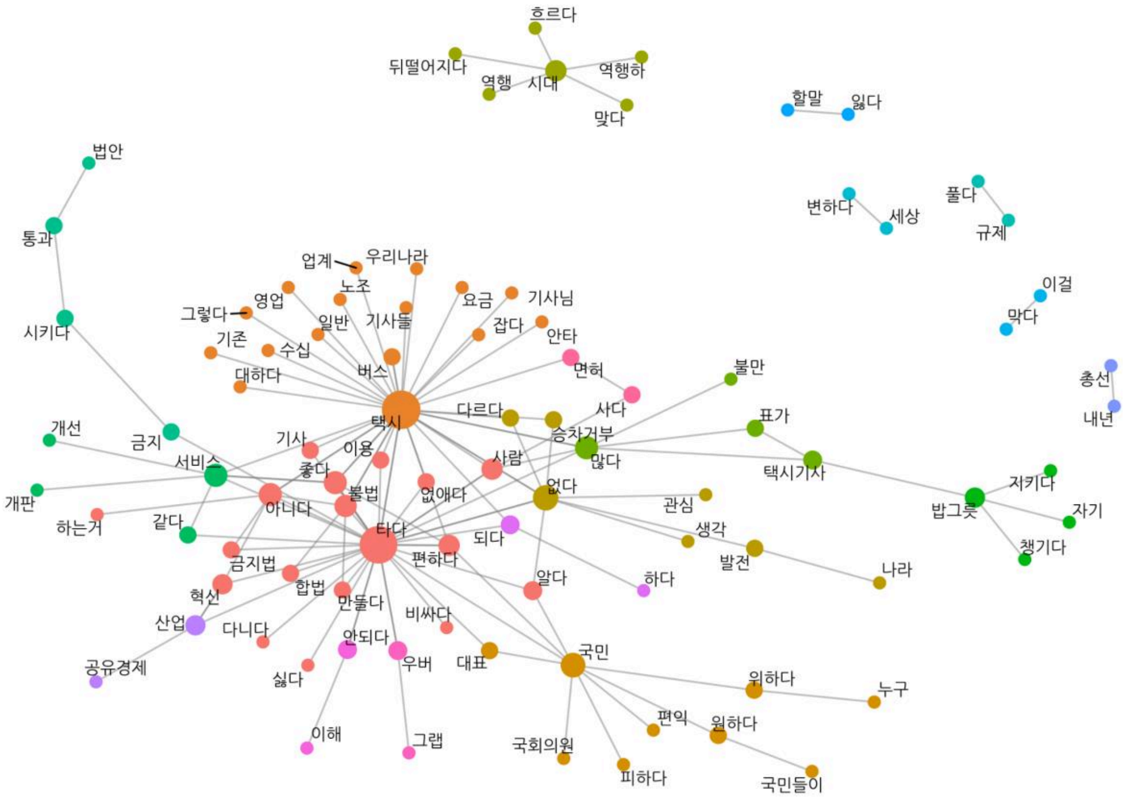

동아대학교 DONG-A UNIVERSITY

Background of Language Model

- 기본 동작방식: 이전 단어들이 주어졌을 때 다음 단어를 예측

예시 1:

나는 학교에 ?

→ 갔다 | 간다 | 도착했다

예시 2:

인공지능은 데이터를 ?

→ 분석한다 | 학습한다 | 좋아한다

Background of Language Model

- 언어 모델의 유형

1. 자기 회귀 언어 모델

- 이전 단어로부터 다음 단어 예측

예시

나는	밥을	?

예측 방향

2. 양방향 언어 모델

- 양쪽 문맥을 활용해 가운데 단어 예측
- 최근 <u>딥러닝 기반 모델</u>에서 사용

예시

나는	?	먹었다

예측 방향

Background of Language Model

- 언어 모델링: 주어진 단어로부터 모르는 단어를 예측하는 작업

1	→	2	→	3	→	4
텍스트 데이터 학습		패턴 인식		다음 단어 예측		확률 기반 출력

Background of Language Model

- 언어 모델링: 주어진 단어로부터 모르는 단어를 예측하는 작업

1 텍스트 데이터 학습 → **2** 패턴 인식 → **3** 다음 단어 예측 → **4** 확률 기반 출력

<학습 데이터>

"나는 오늘 학교에 갔다"
"친구는 학교에 간다"
"그는 매일 학교에 간다"
"친구들은 학교에 도착했다"

<패턴 인식>

"학교" 다음에 나오는 단어
"갔다" (1회)
"간다" (2회)
"도착했다" (1회)

<입력>

"나는 오늘 학교에"
다음에 나오는 단어

"갔다", "간다", "도착했다"

<확률 할당>

"갔다": 25%
"간다": **50%**
"도착했다": 25%

최종출력 ➔ **<u>"간다"</u>**

Background of Language Model

- 언어 모델의 응용

1. 텍스트 자동완성

안녕하세요, 오늘 날씨가 정말 □

2. 챗봇 및 대화 시스템

오늘 날씨 어때요?

오늘은 맑고 따뜻합니다!

3. 콘텐츠 생성

옛날 옛적에...
한 작은 마을에 살던 소년은...
모험을 떠나기로 결심했습니다...

4. 기계 번역

Hello world → 안녕 세상

Background of Language Model

- History of Language Model
    - Transformer: 최신 고성능 모델들은 해당 아키텍처 기반으로 설계

*BERT: Bidirectional Encoder Representations from Transformers
*GPT: Generative Pre-trained Transformer

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com

Noam Shazeer* Google Brain noam@google.com

Niki Parmar* Google Research nikip@google.com

Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com

Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* ‡ illia.polosukhin@gmail.com

Transformer

- 전체 구조 기계번역 (영어→프랑스어)
  - 입력: 영어 문장
  - 출력: 프랑스어 문장

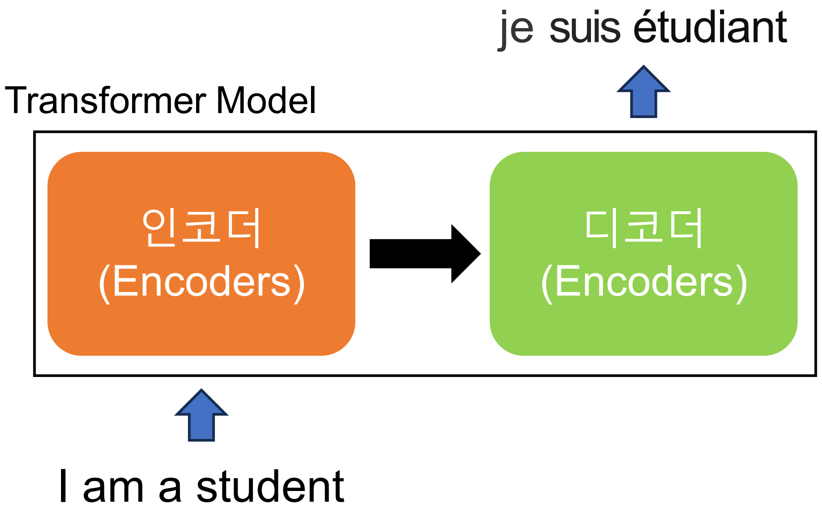

- 전체 구조 기계번역 (영어→프랑스어)
  - 입력: 영어 문장
  - 출력: 프랑스어 문장

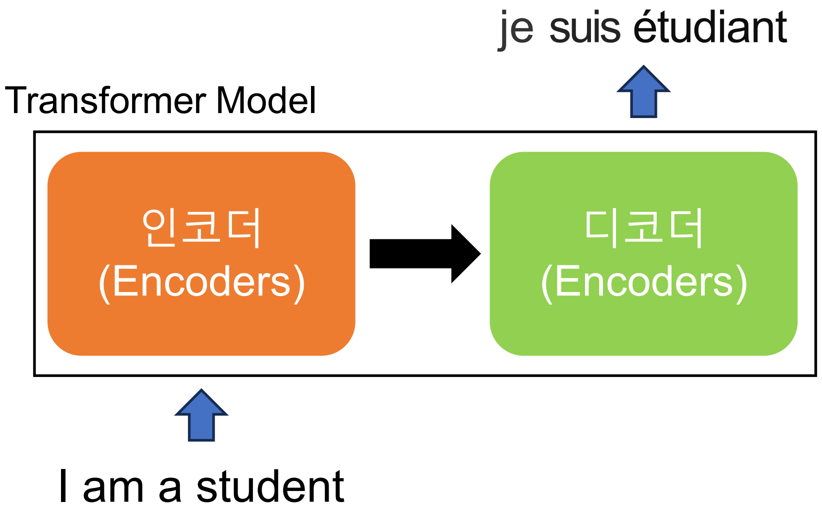

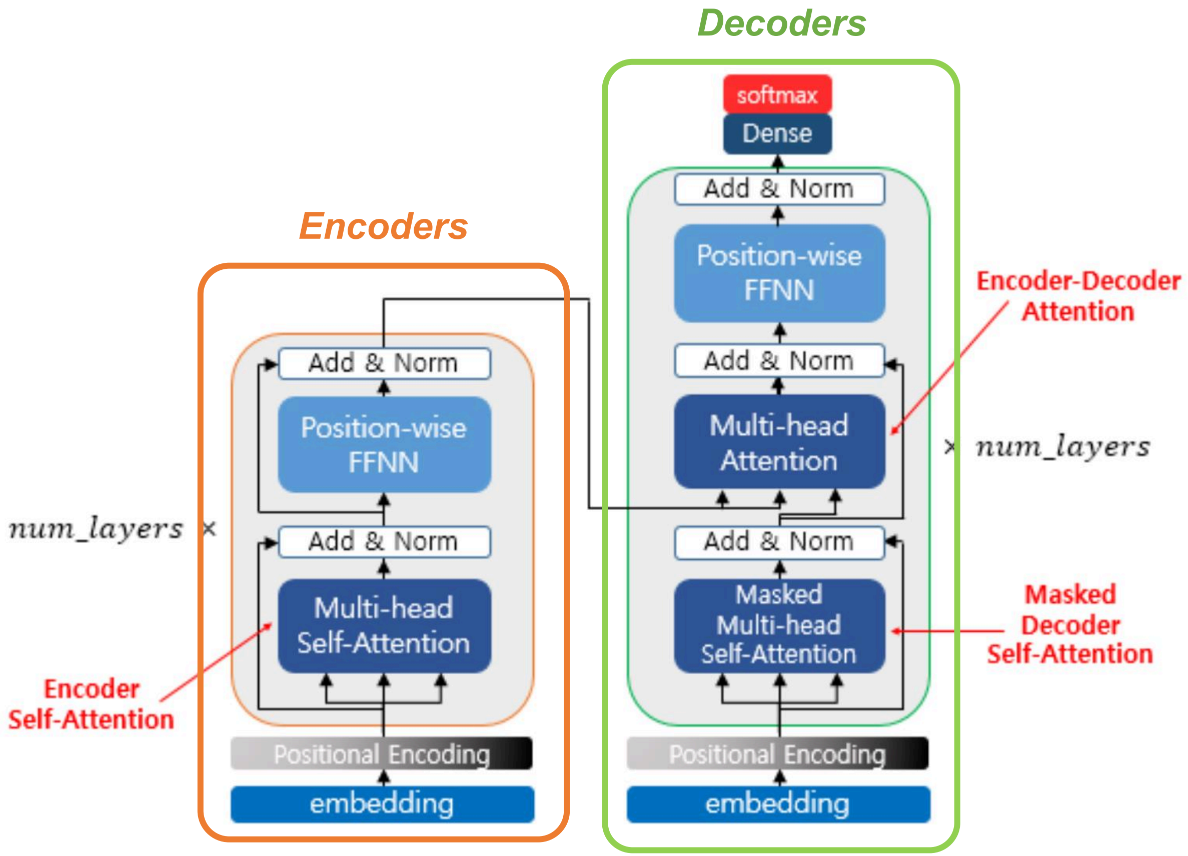

Transformer

- 전체 구조 기계번역 (영어→프랑스어)
  - **학습 시** 입력: 영어, 프랑스어 문장
  - **학습 시** 출력: 프랑스어 문장

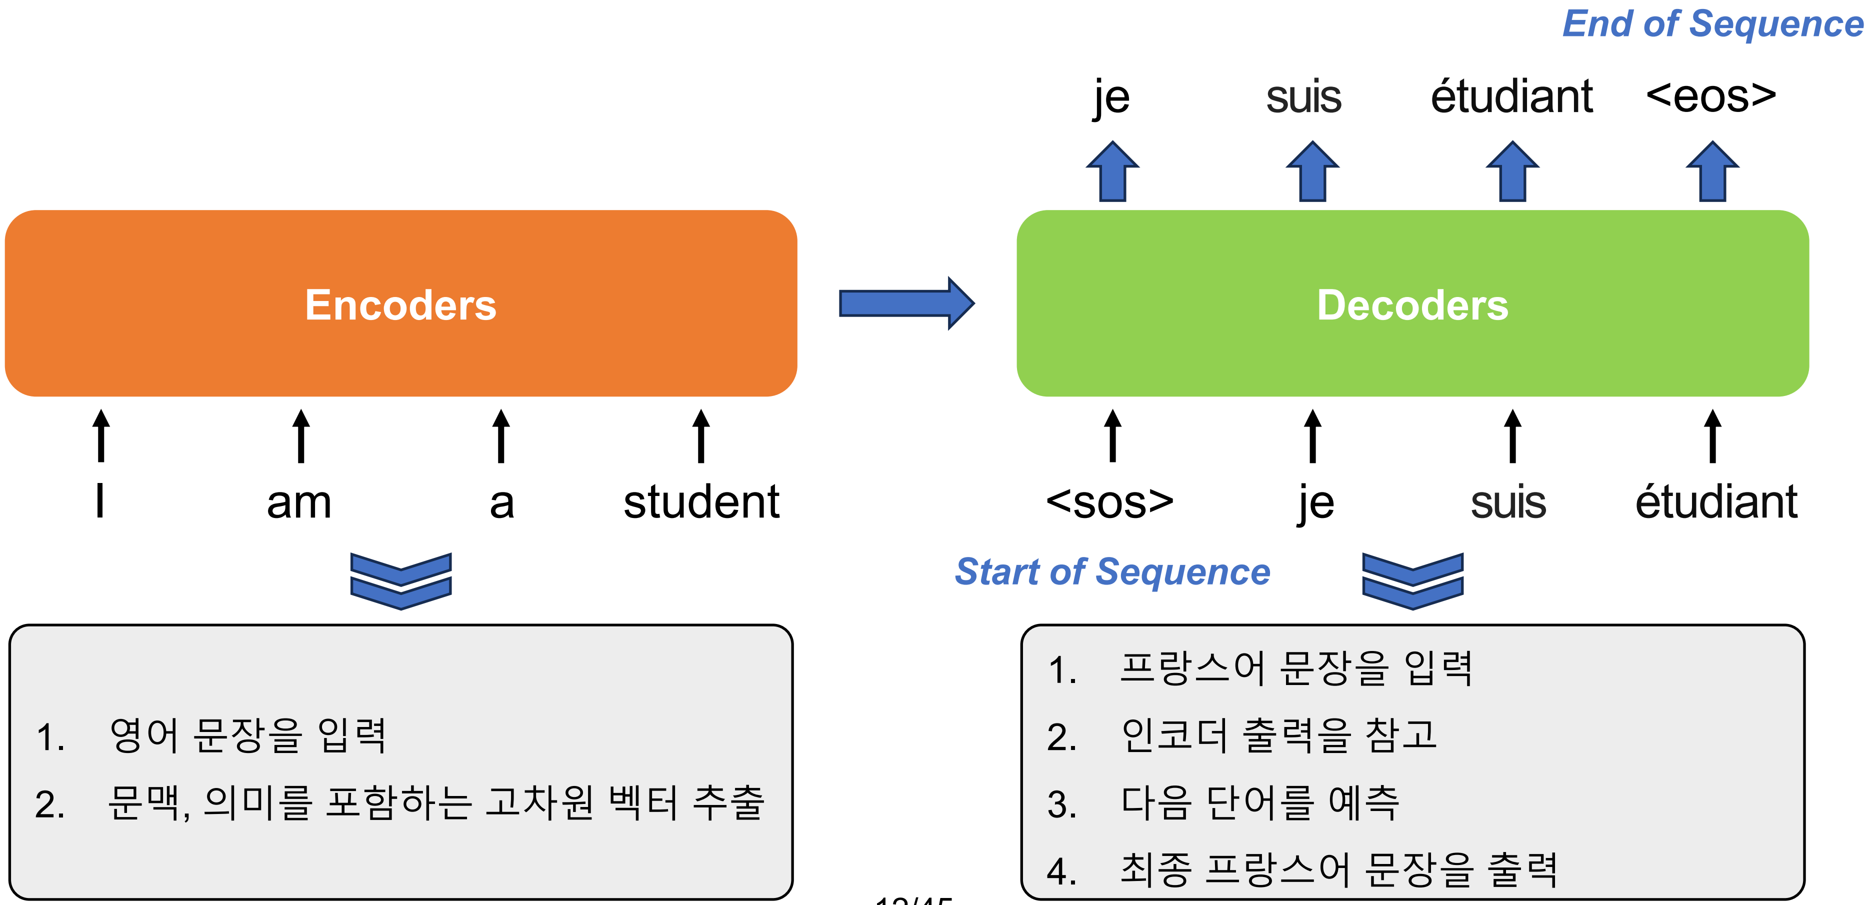

Transformer

- Embedding

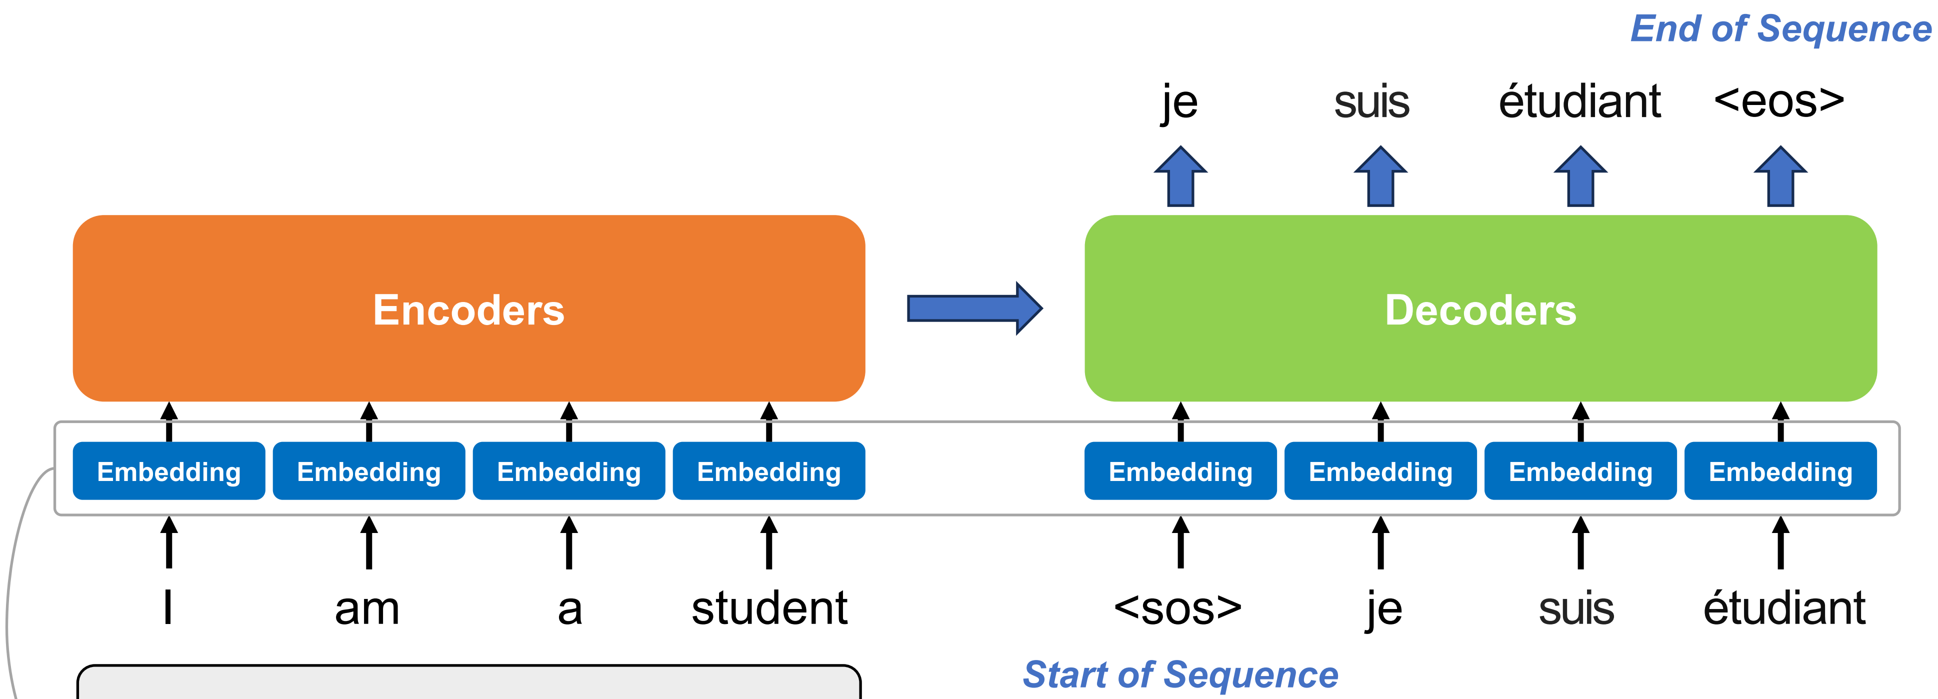

1. 딥러닝 모델은 텍스트(단어) 이해 x
2. 임베딩 과정을 통해 숫자(벡터)로 변환
3. Ex. Student → [0.17,−0.12,0.55,...,0.03]

Transformer

- Positional Encoding

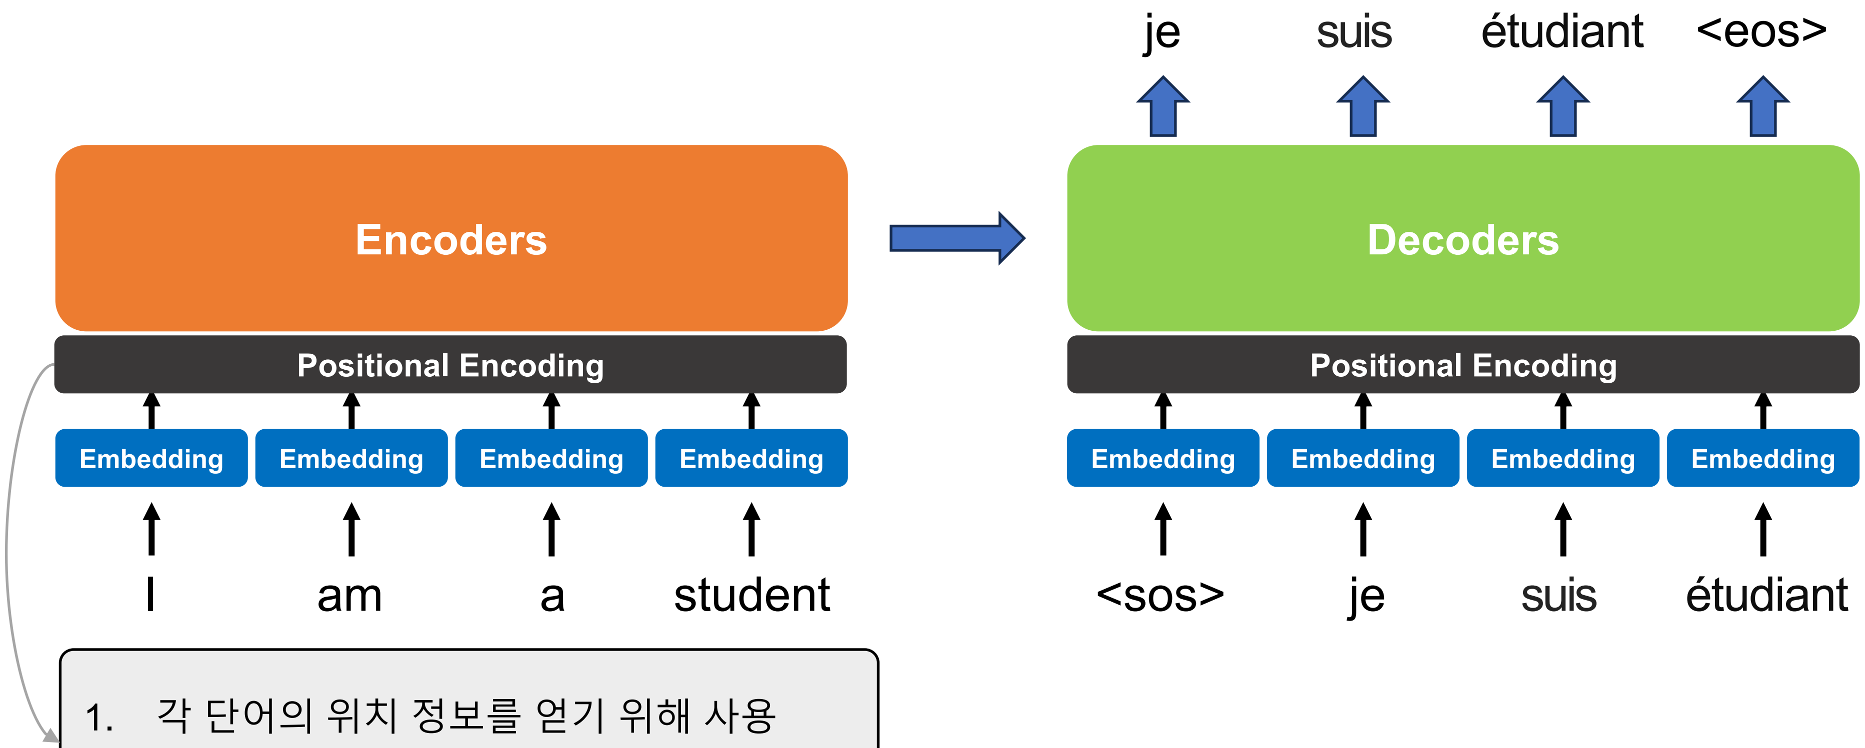

1. 각 단어의 위치 정보를 얻기 위해 사용
2. positional encoding을 통해 위치 정보 추가

Transformer

- Positional Encoding

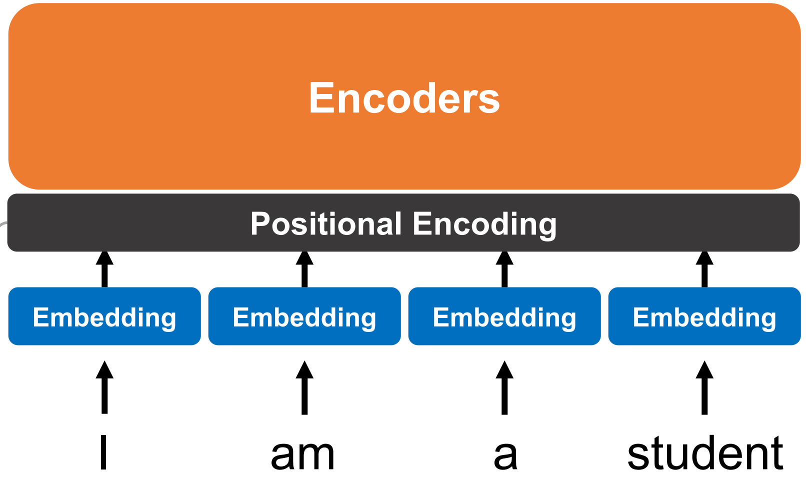

1. 각 단어의 위치 정보를 얻기 위해 사용
2. positional encoding을 통해 위치 정보 추가

Ex. "I love you" vs "You love I"

➔ 단어는 동일하지만, **순서에 따라 의미가 완전히 달라짐**

➔ ["I”, “love”, “you“] → 3개의 벡터가 동시에 처리 → 위치x

➔ **순서 정보가 없으면** 트랜스포머는 **두 문장을 같다고 인식**

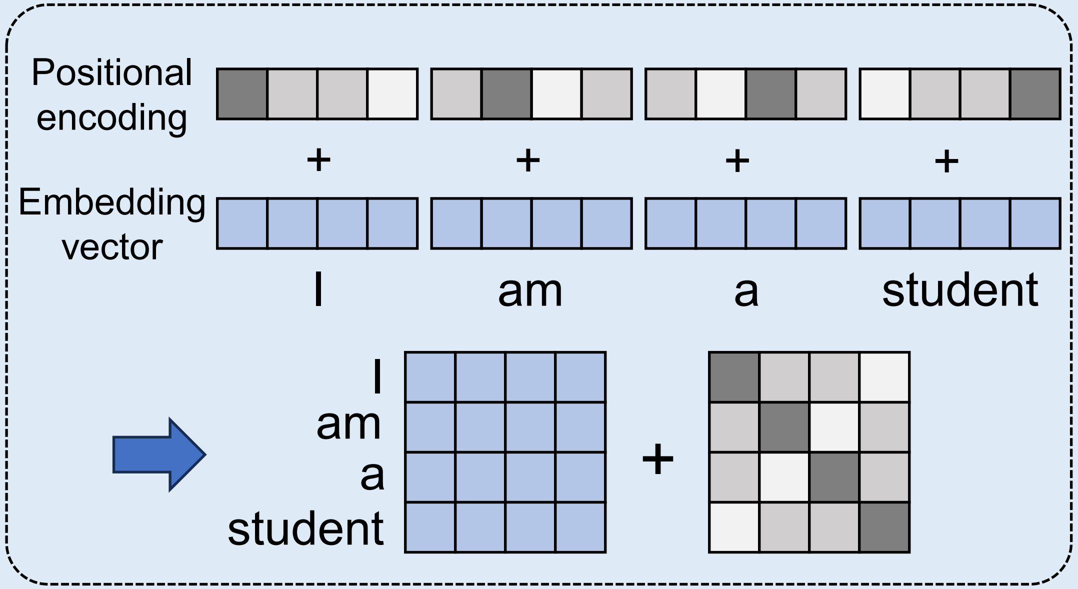

➔ 위치 정보 추가를 위해 덧셈 연산 진행

➔ 임베딩 벡터 위치, 차원 인식 가능

- Positional Encoding

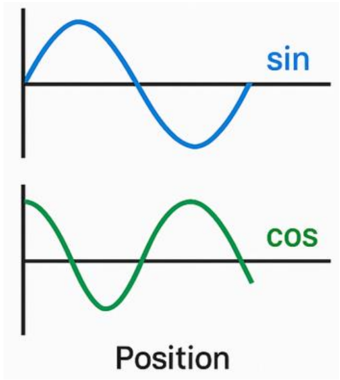

$$PE_{(pos,\,2i)} = sin(pos/10000^{2i/d_{model}})$$

$$PE_{(pos,\,2i+1)} = cos(pos/10000^{2i/d_{model}})$$

✓ pos: 위치 인덱스 (ex. 0, 1, 2, …)
✓ i : 벡터 차원 인덱스 (ex. 0부터 시작)
✓ d_{model} : 전체 임베딩 차원 수 (ex. 4)

$(pos,\ i)$

➔ Embedding vector의 정보 기반으로 Positional encoding 정보 생성

Ex. "I love you" vs "You love I"

➔ 단어는 동일하지만, **순서에 따라 의미가 완전히 달라짐**

➔ ["I", "love", "you"] → 3개의 벡터가 동시에 처리 → 위치x

➔ **순서 정보가 없으면** 트랜스포머는 **두 문장을 같다고 인식**

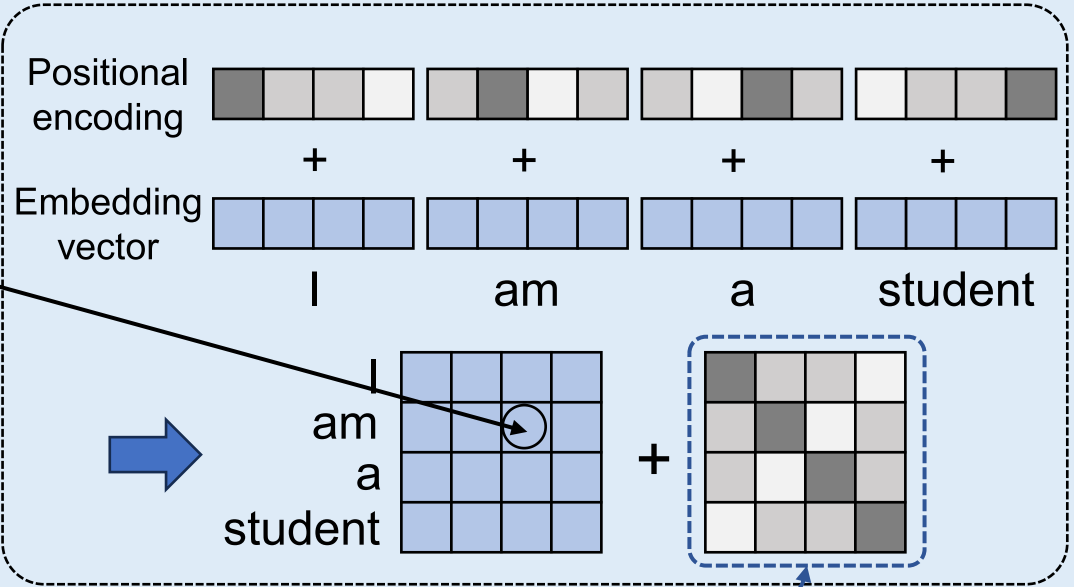

➔ 위치 정보 추가를 위해 덧셈 연산 진행

➔ 임베딩 벡터 위치, 차원 인식 가능

Transformer

- Encoders

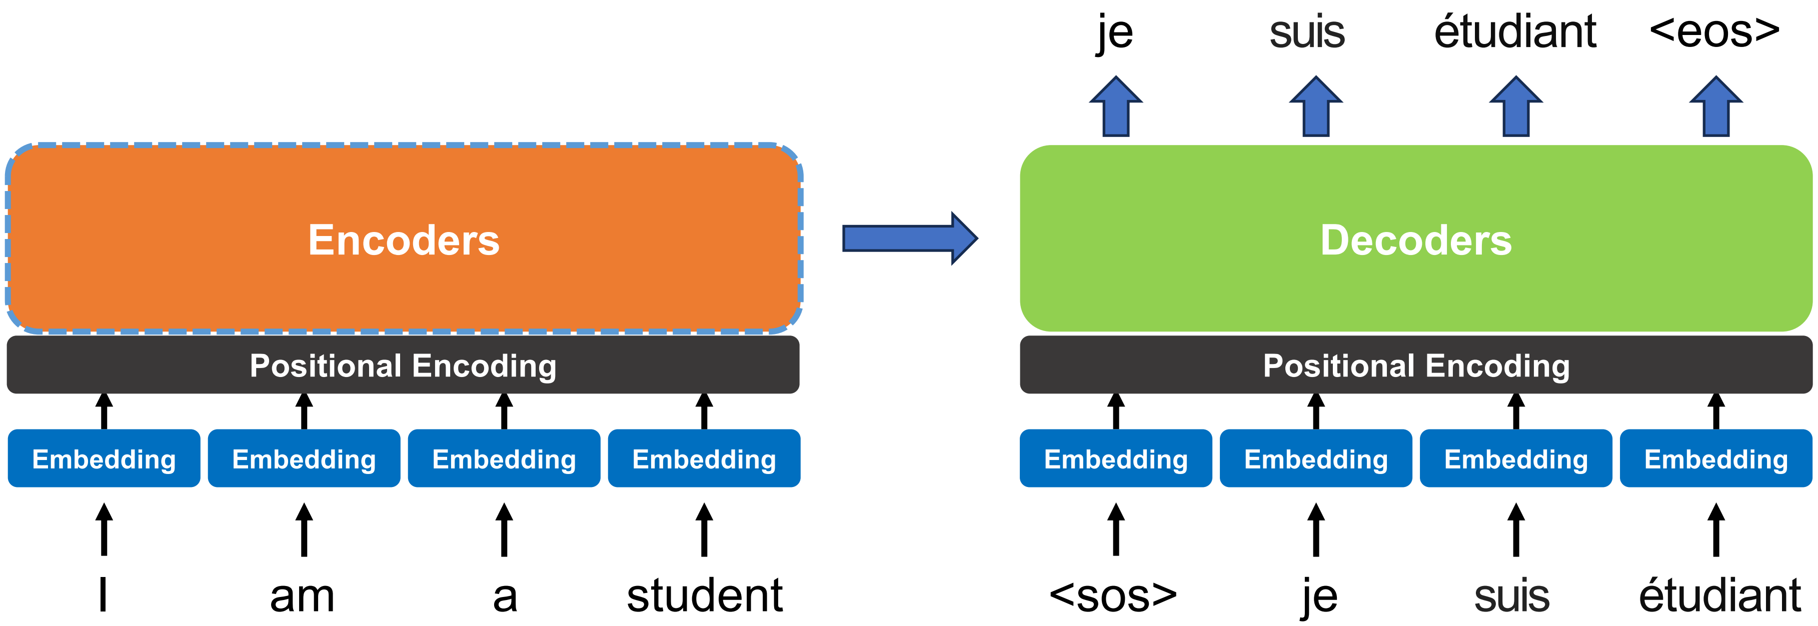

동아대학교 DONG-A UNIVERSITY

Transformer

- Encoders
  - 자연어를 벡터로 변환한 뒤 단어간 유사도 (Relevance) 표현

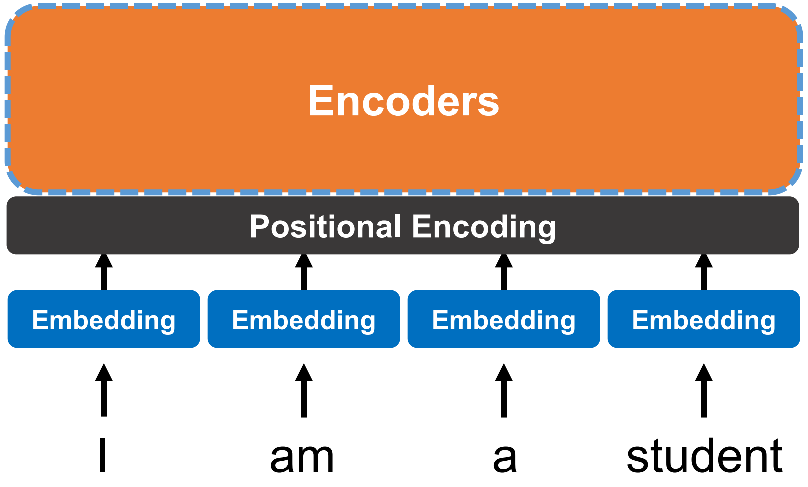

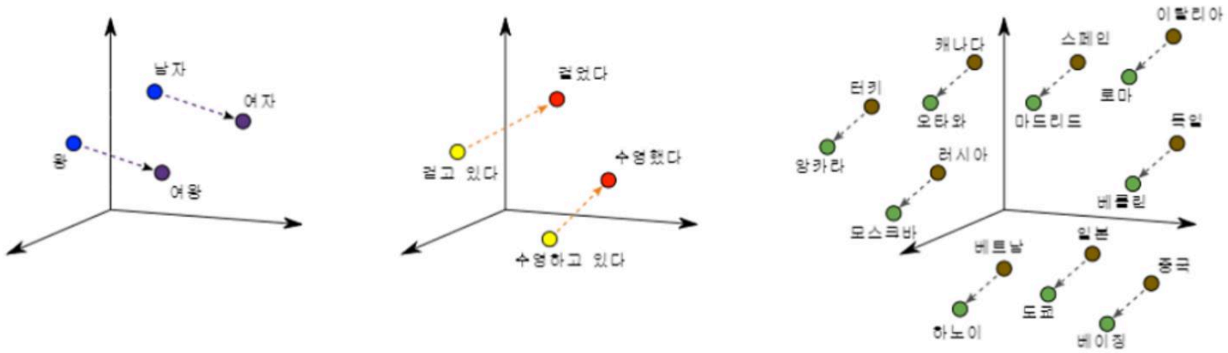

남자-여자 동사 시제 국가-수도

Transformer

- Encoders
  - 자연어를 벡터로 변환한 뒤 단어간 유사도 (Relevance) 표현
  - 각각의 단어별 연관성이 높은 정도를 학습 ➔ 단어별 Attention을 통해 문맥에 대한 정보 학습

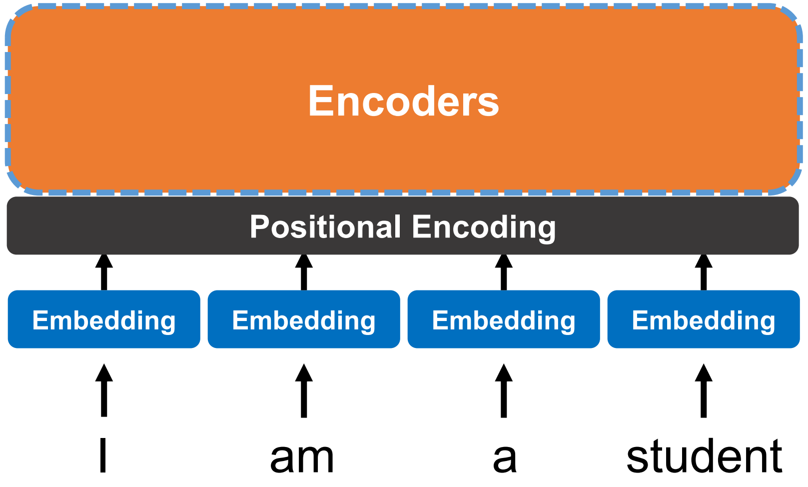

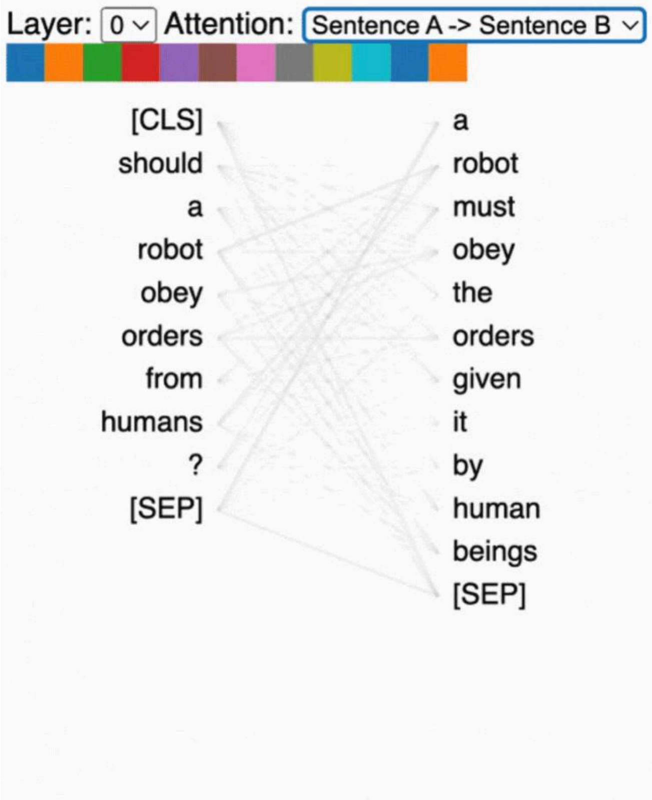

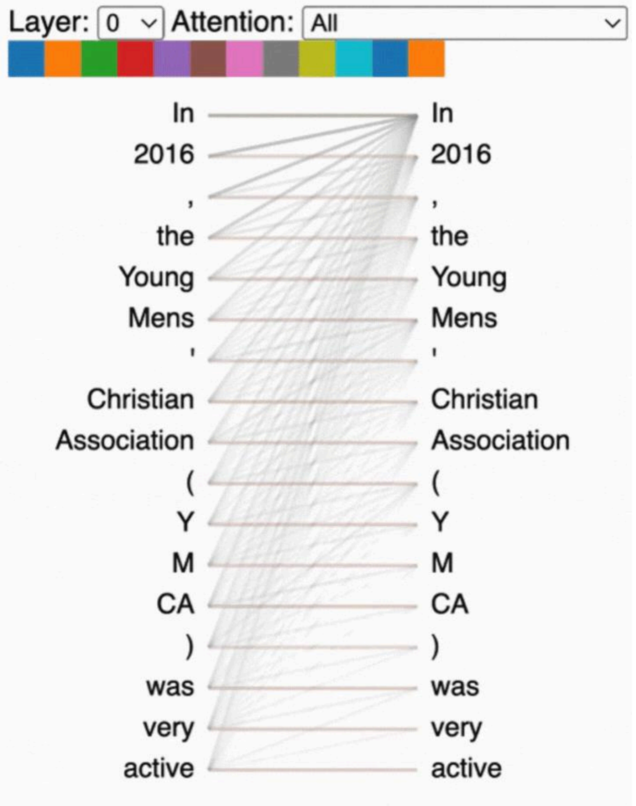

Transformer

- Encoders
  - 자연어를 벡터로 변환한 뒤 단어간 유사도 (Relevance) 표현
  - 각각의 단어별 연관성이 높은 정도를 학습 ➔ 단어별 Attention을 통해 문맥에 대한 정보 학습

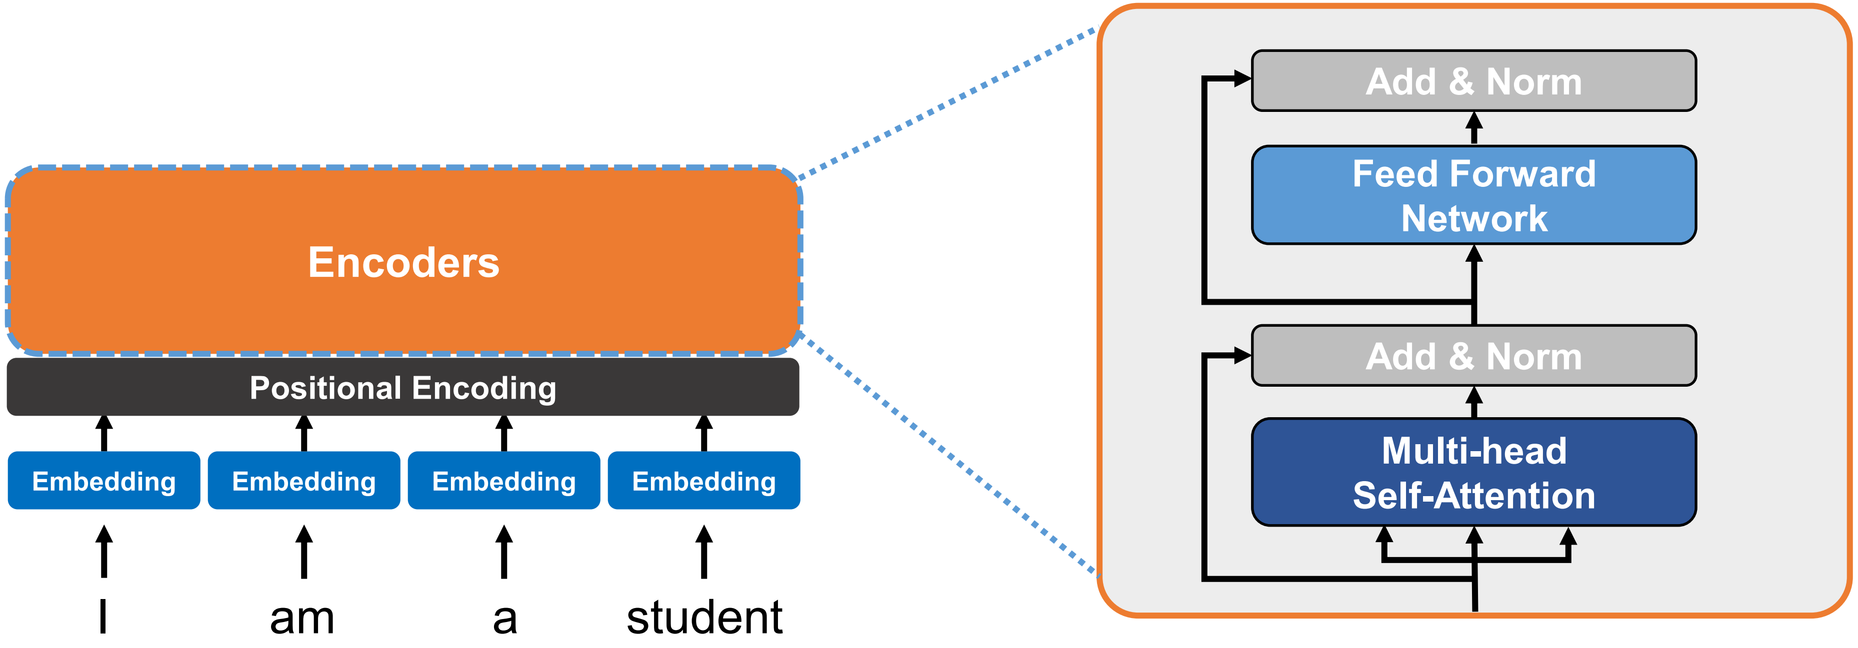

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention

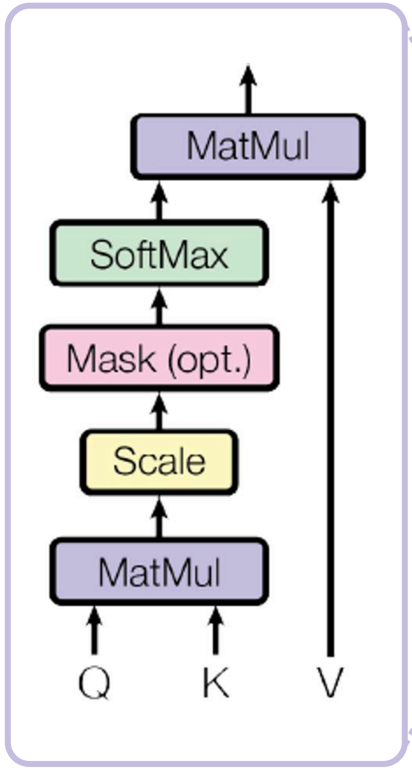

Scaled Dot-Product Attention

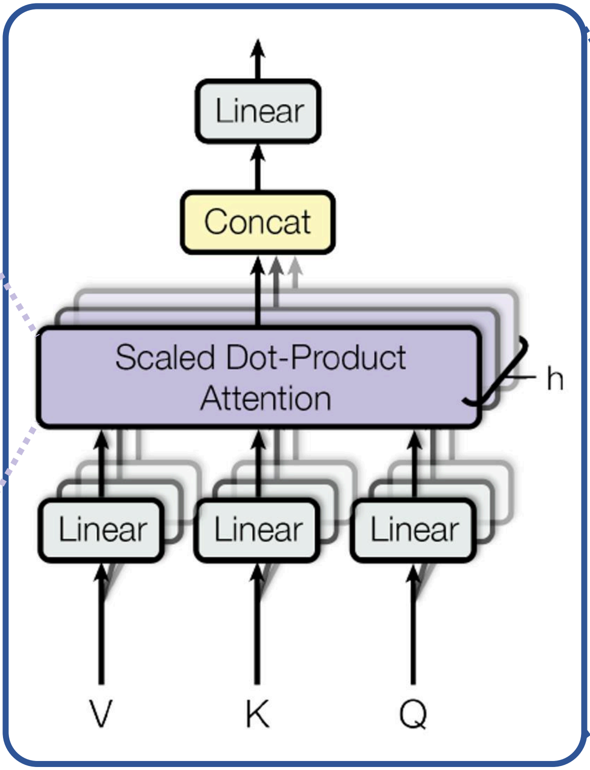

Multi-head Self-Attention

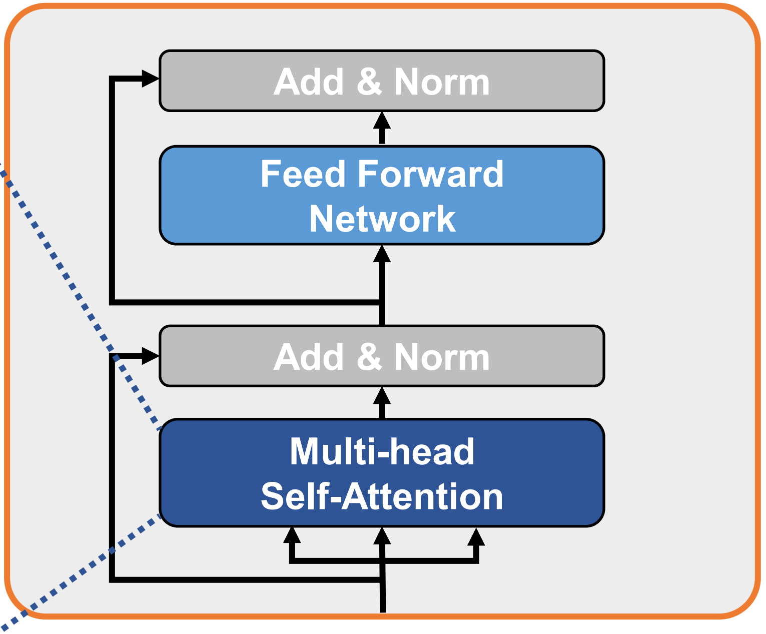

- ✓ Query (Q): 비교 기준
- ✓ Key (K): 비교 대상
- ✓ Value (V): 참조 정보

Transformer

- Encoder
  - Scaled Dot-Product Attention
    - ✓ Q : Query → 분석 대상이 되는 단어에 대한 가중치 Vector
    - ✓ K : Key → Attention을 수행할 단어 집합
    - ✓ V : Value → Attention으로 도출된 weights를 적용한 단어

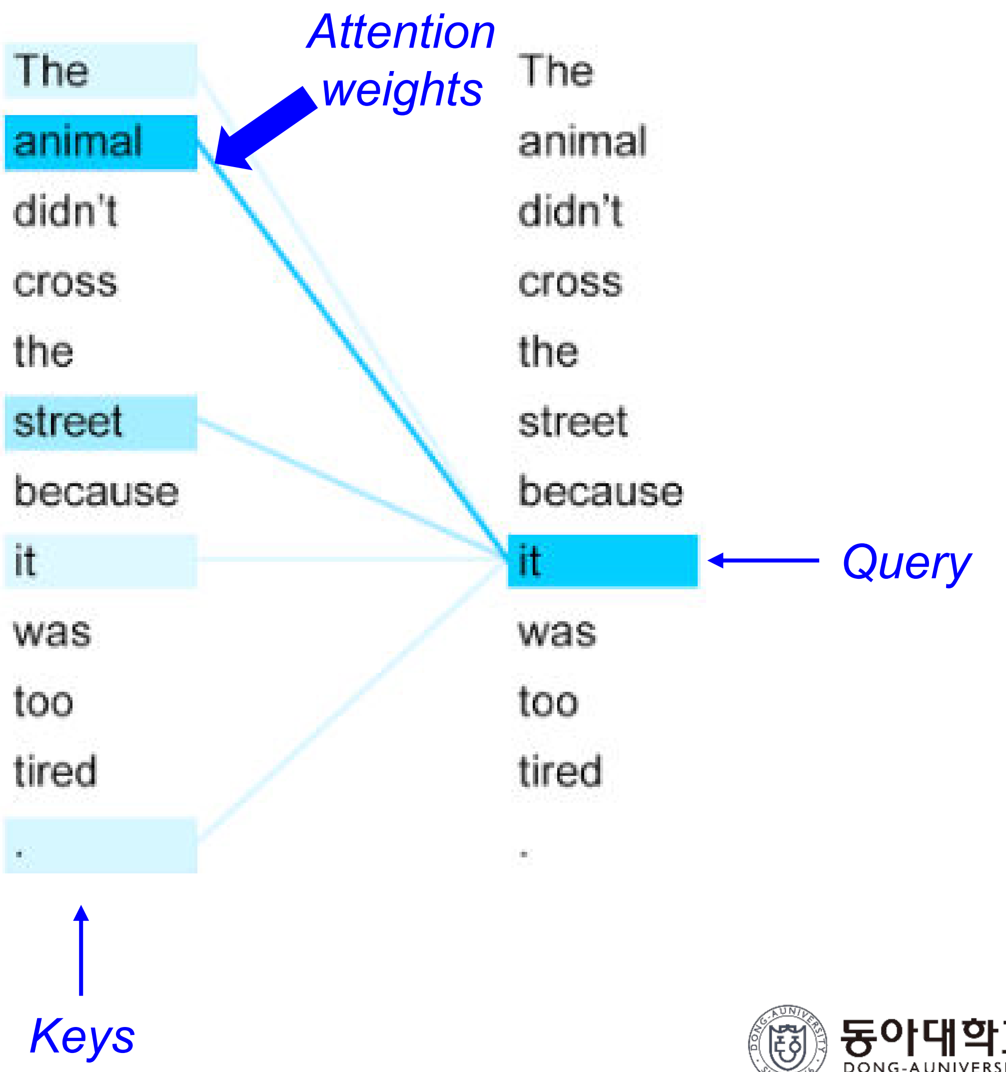

❖ 예시) 영어 → 한국어 (Self-attention의 목적 기준)

The animal didn't cross the street because it was too tired.

그 동물은 길을 건너지 않았다.

기계의 경우 "it"이 "street"인지 "animal"인지 모름

→ 입력 문장내의 단어들끼리 유사도를 계산하여 가중치 부여

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) I am a **student**

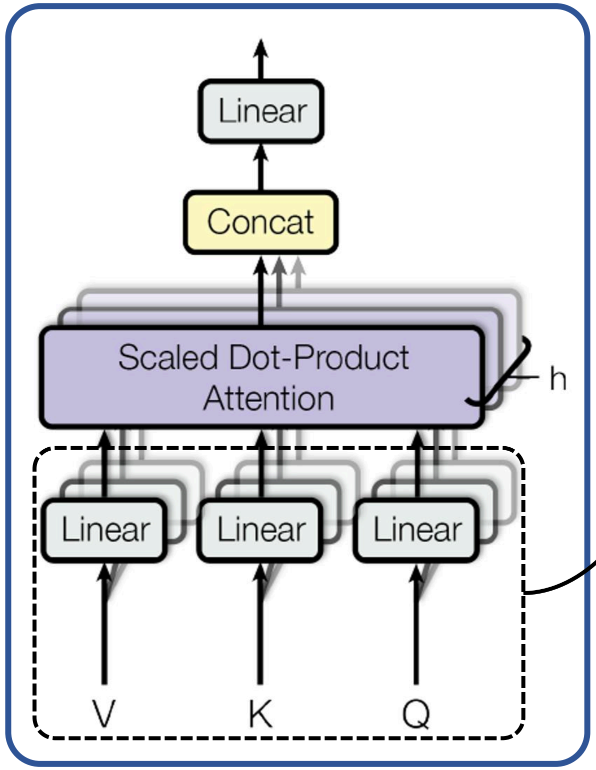

Multi-head Self-Attention

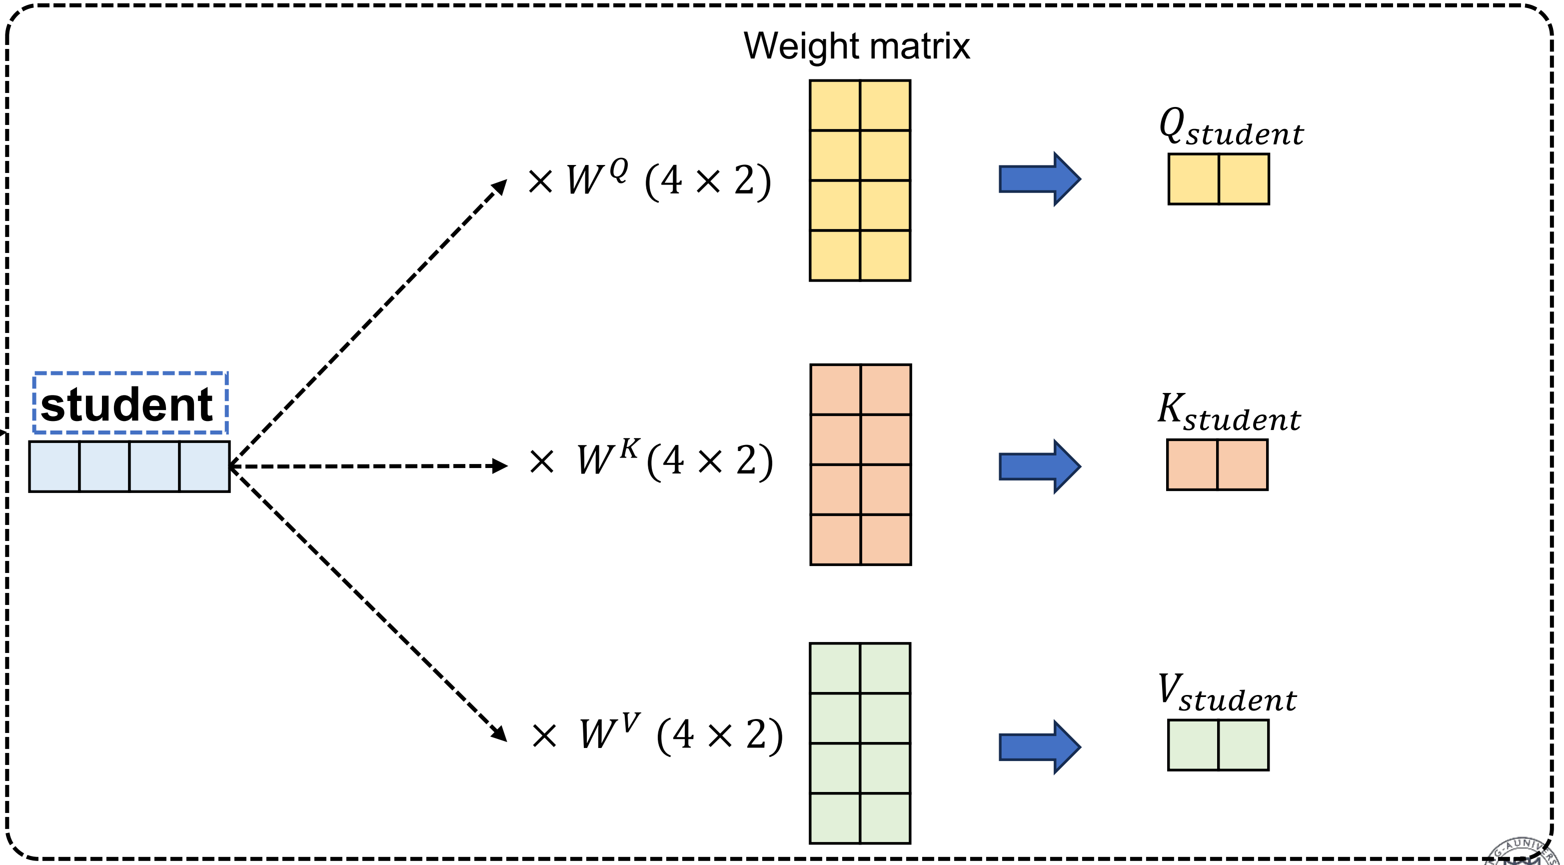

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) I am a **student**

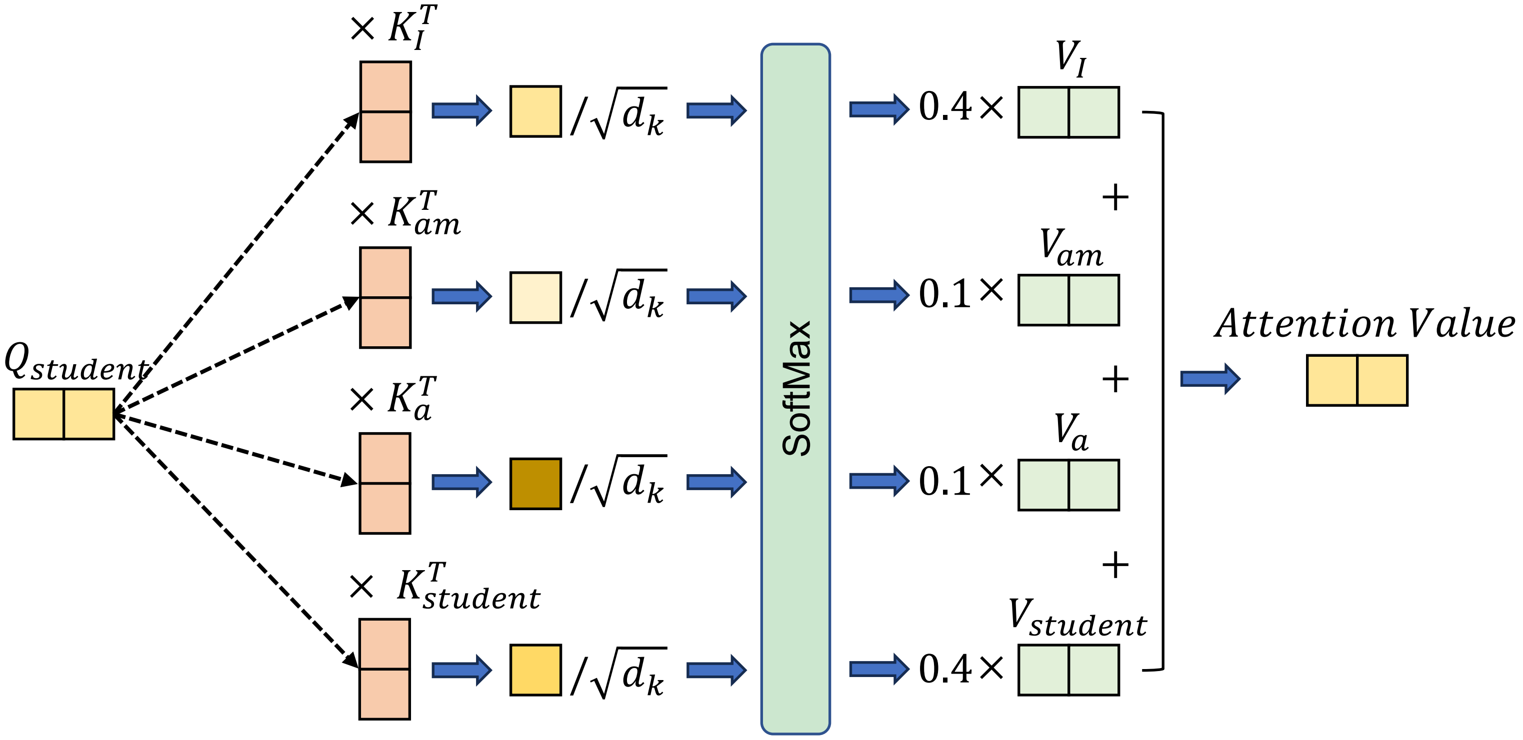

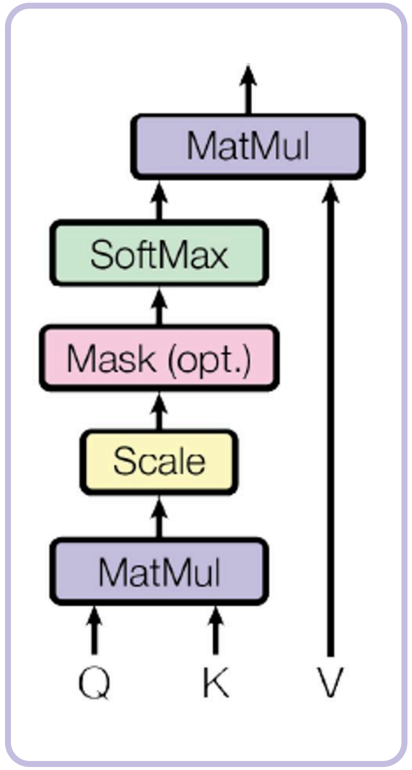

Scaled Dot-Product Attention

✓ d_k = Embedding Dimension

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) I am a **student**

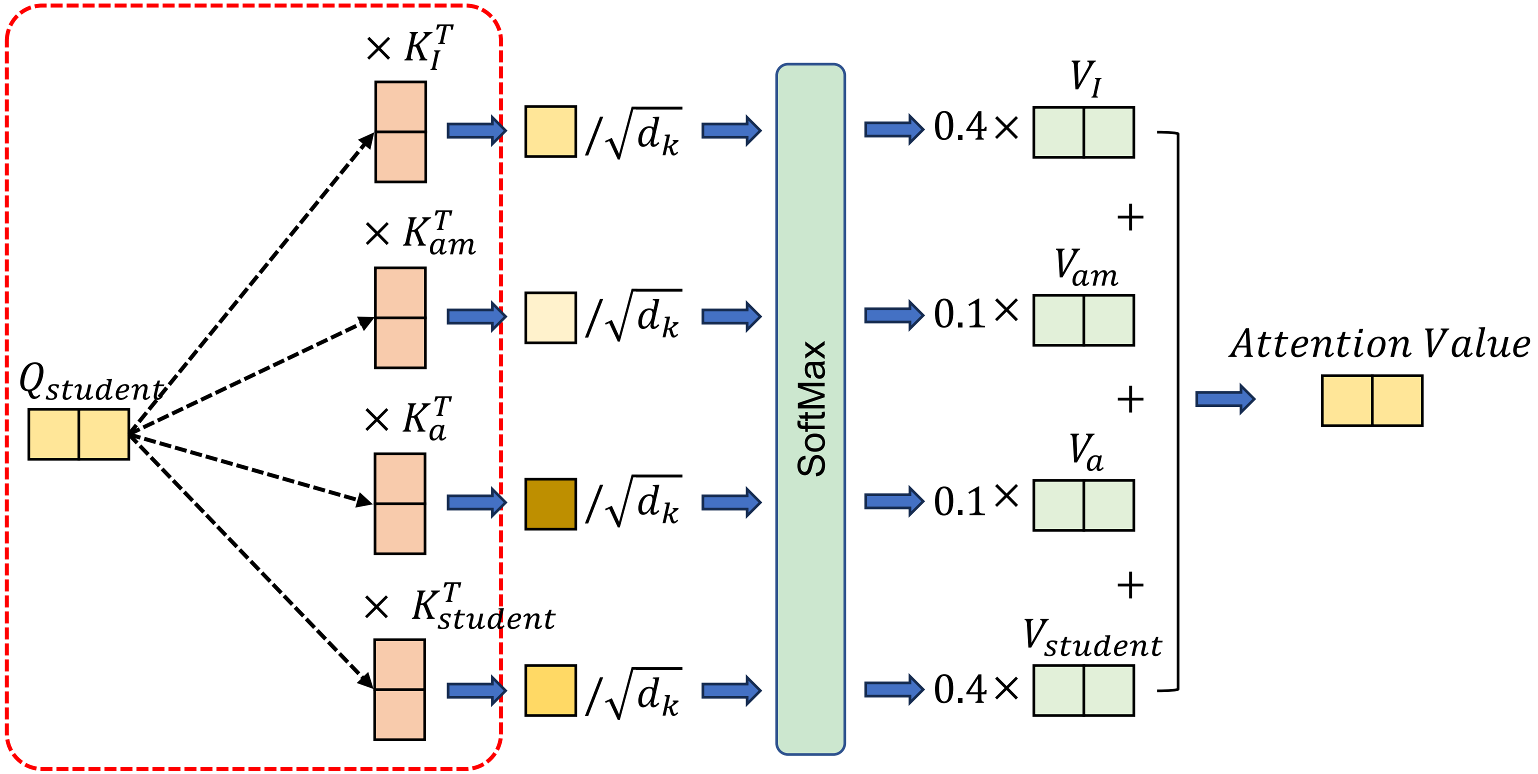

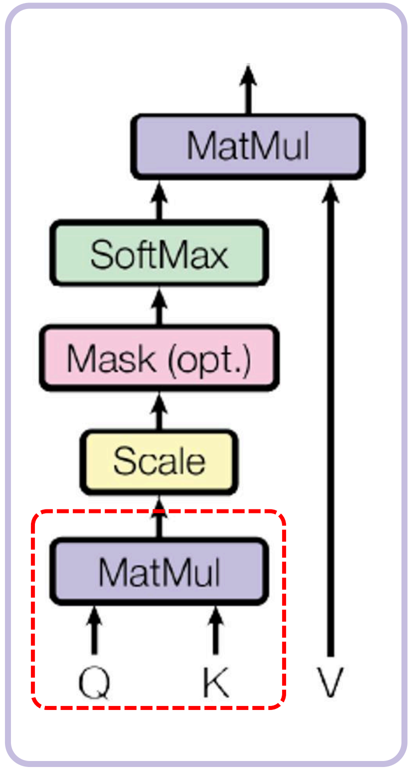

Scaled Dot-Product Attention

동아대학교 DONG-A UNIVERSITY

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) I am a **student**

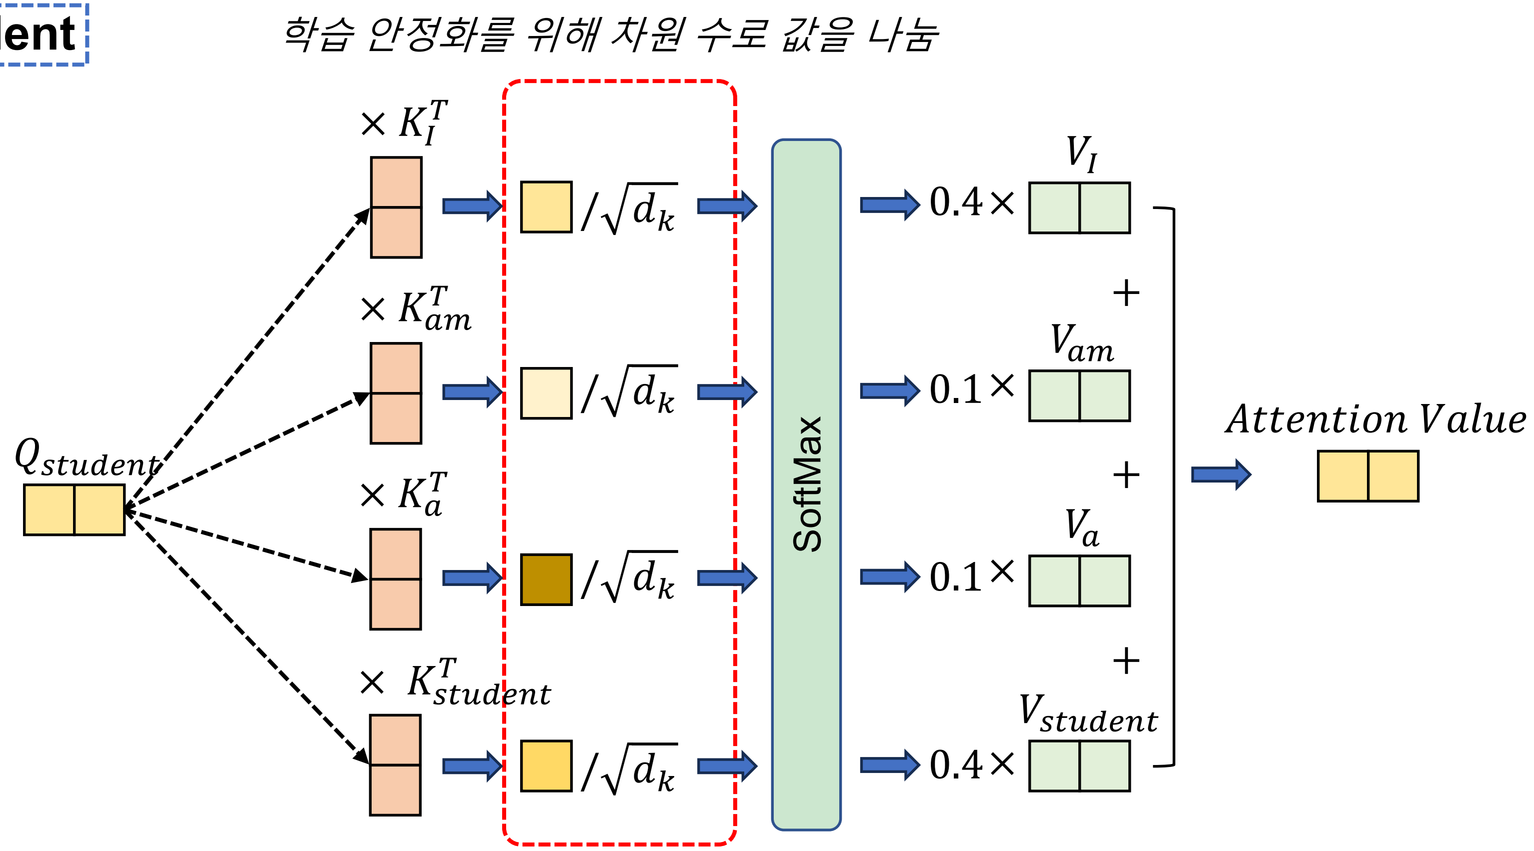

✓ d_k = Embedding Dimension ➔ 2

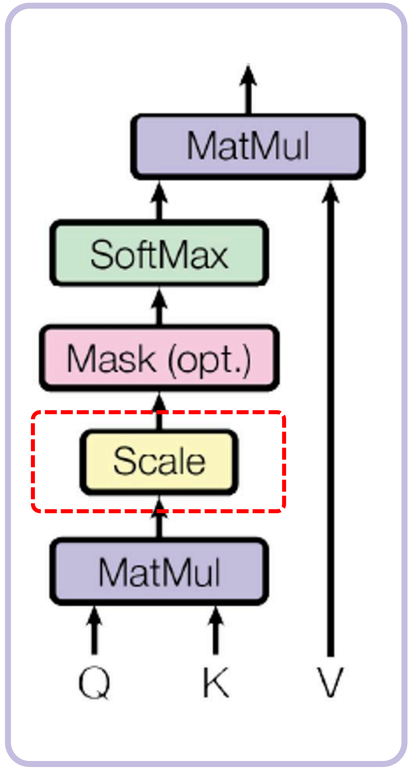

Scaled Dot-Product Attention

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) I am a **student**

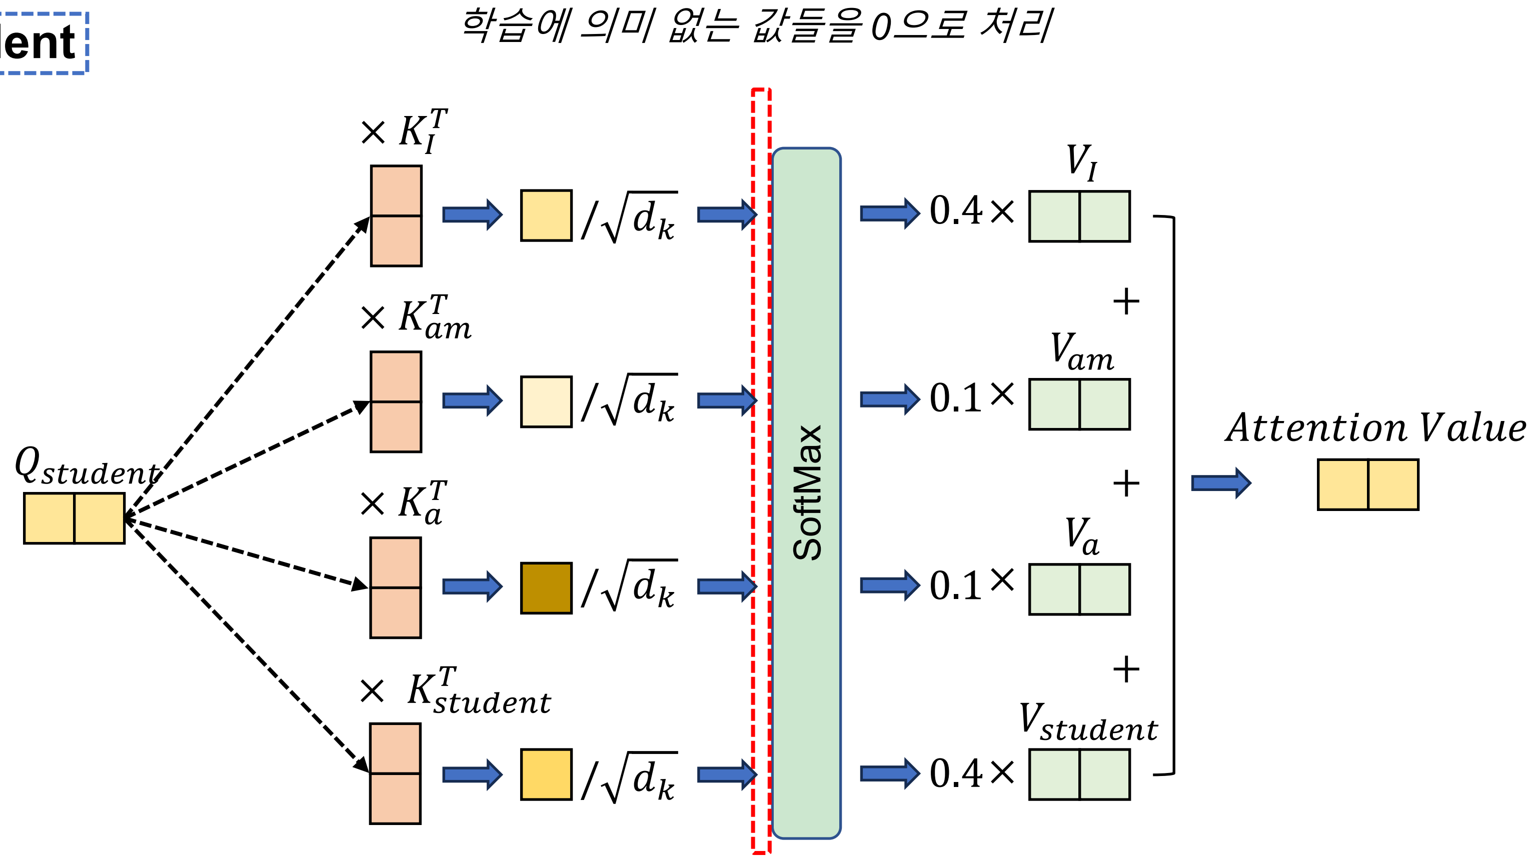

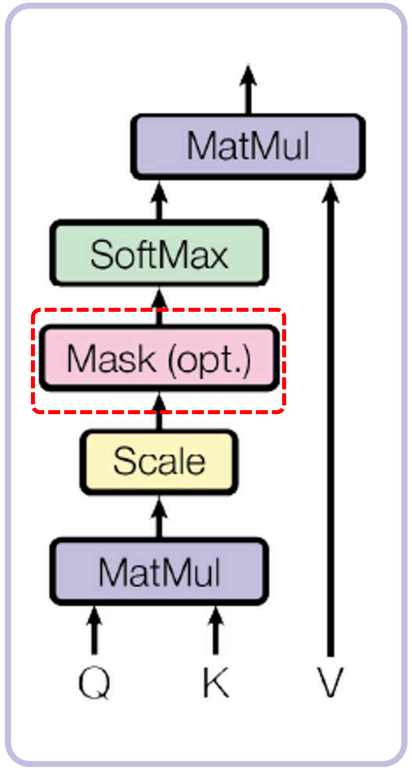

Scaled Dot-Product Attention

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) I am a **student**

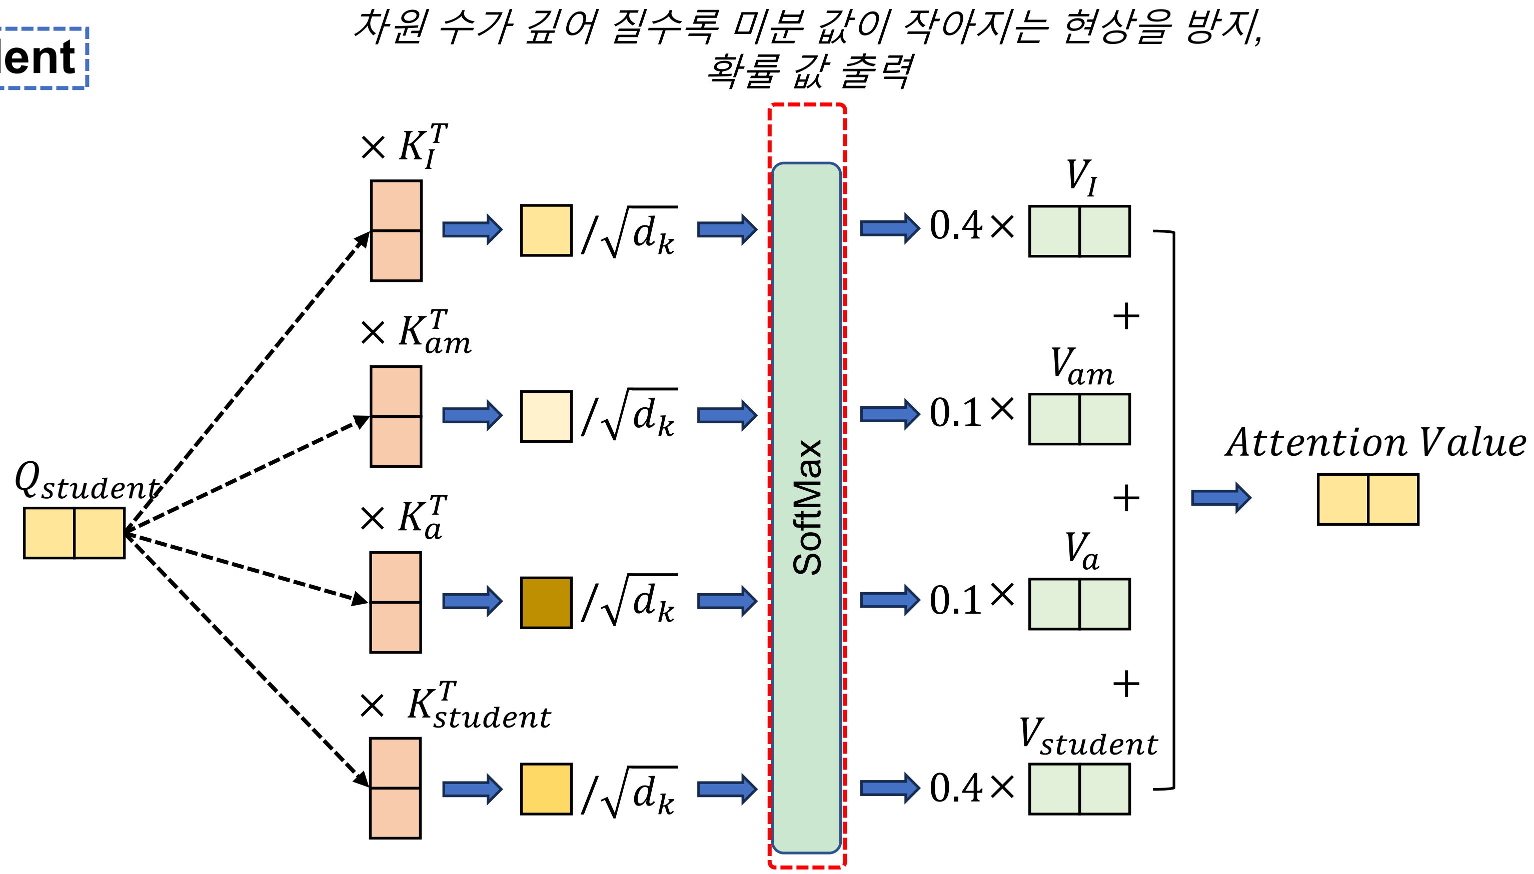

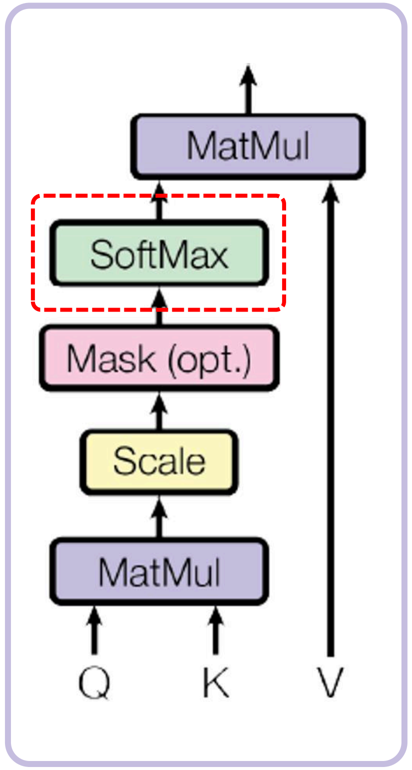

Scaled Dot-Product Attention

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) I am a **student**

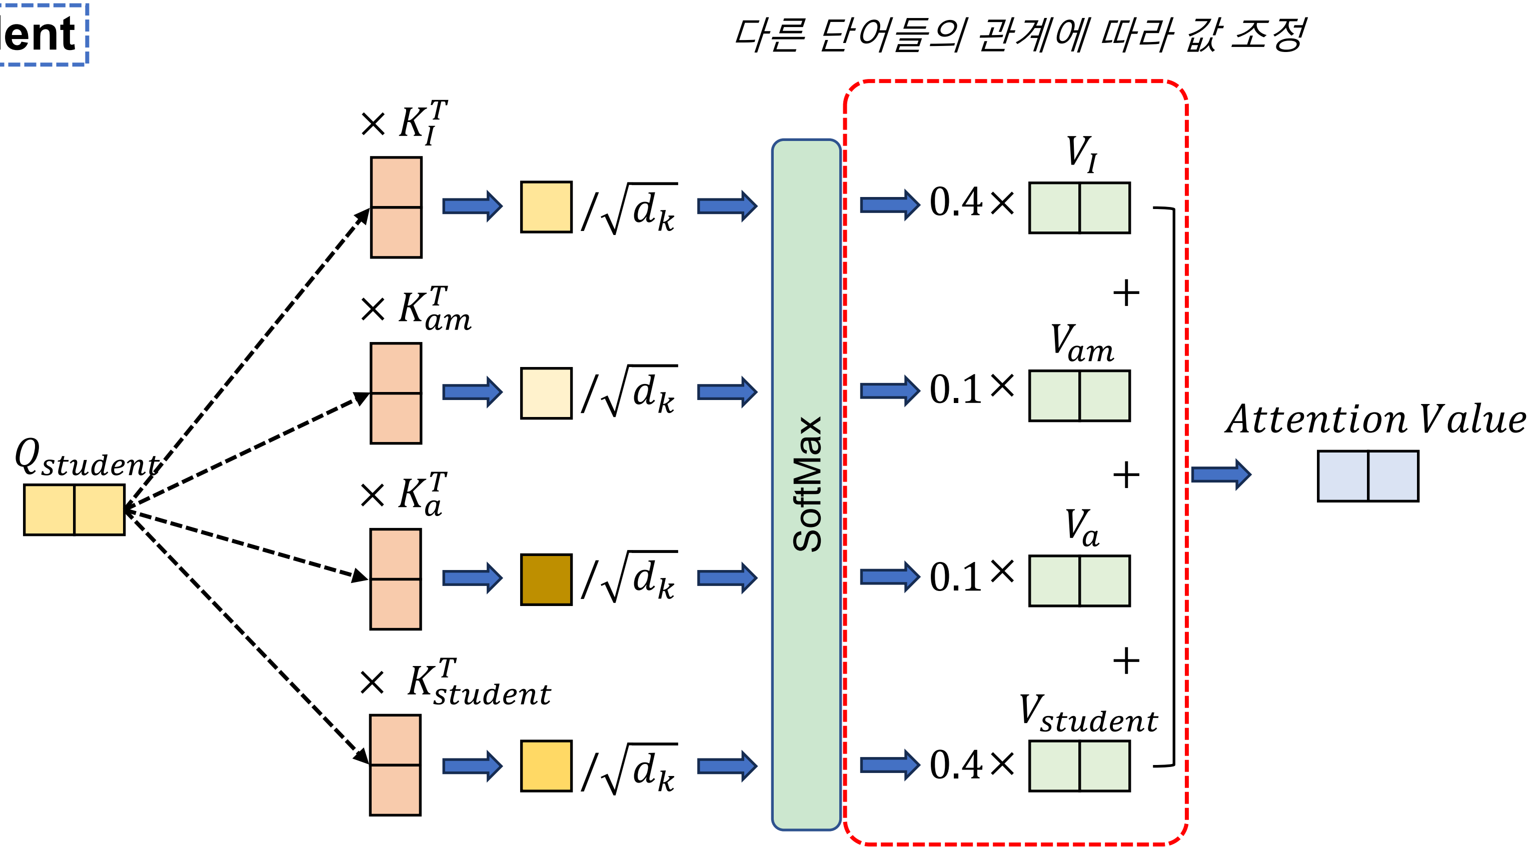

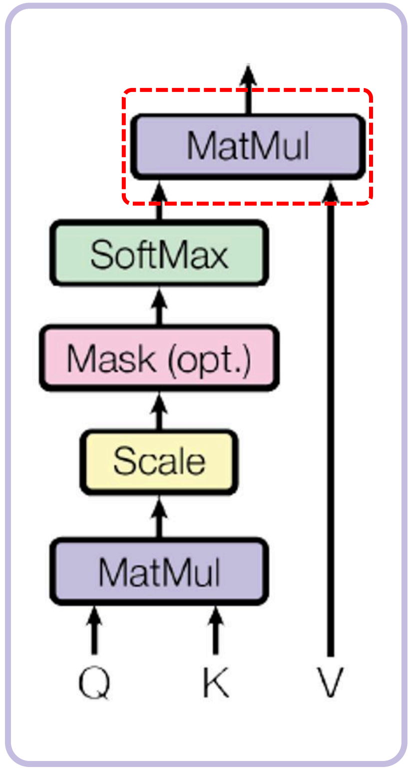

Scaled Dot-Product Attention

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) I am a **student**

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

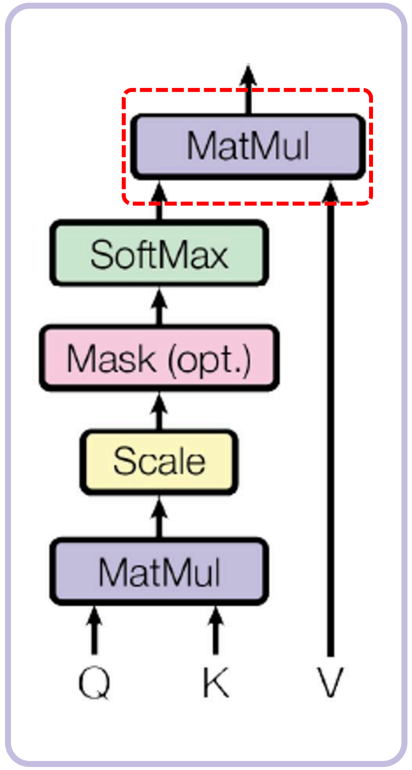

Scaled Dot-Product Attention

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) **I am a student**

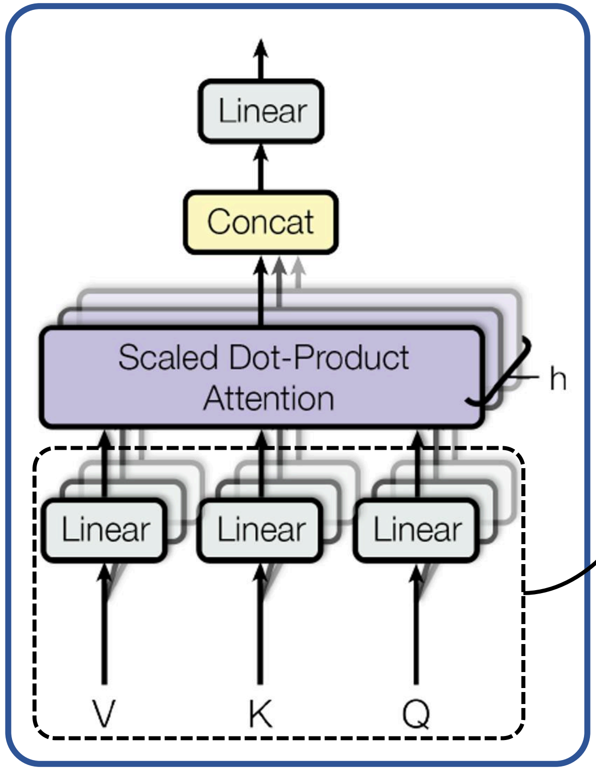

Multi-head Self-Attention

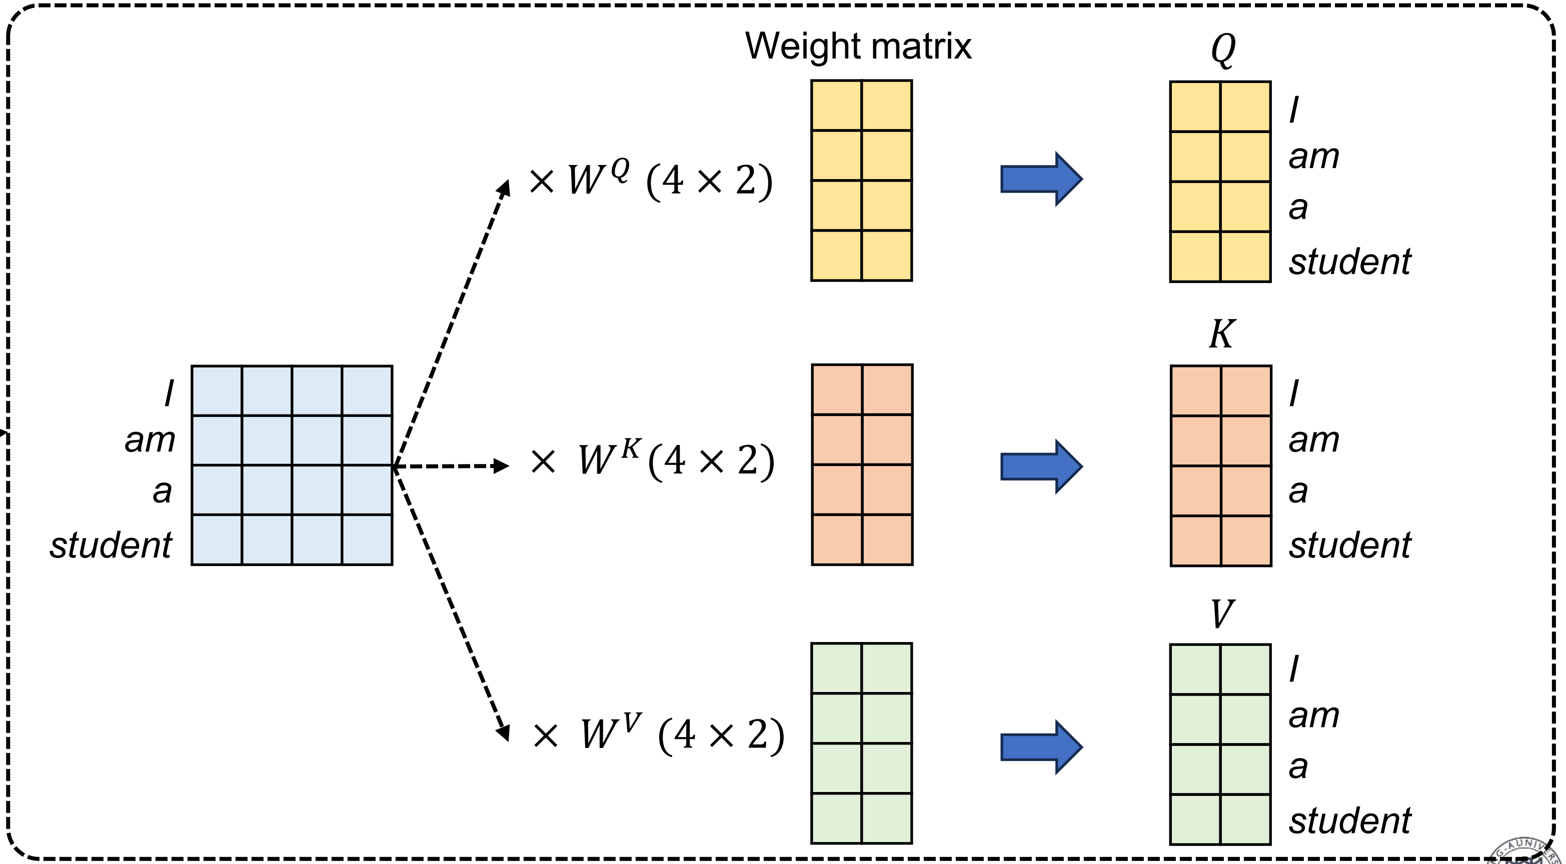

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) **I am a student**

$$Attention(Q,K,V) = softmax\left(\frac{Q \times K^T}{\sqrt{d_k}}\right) \times V$$

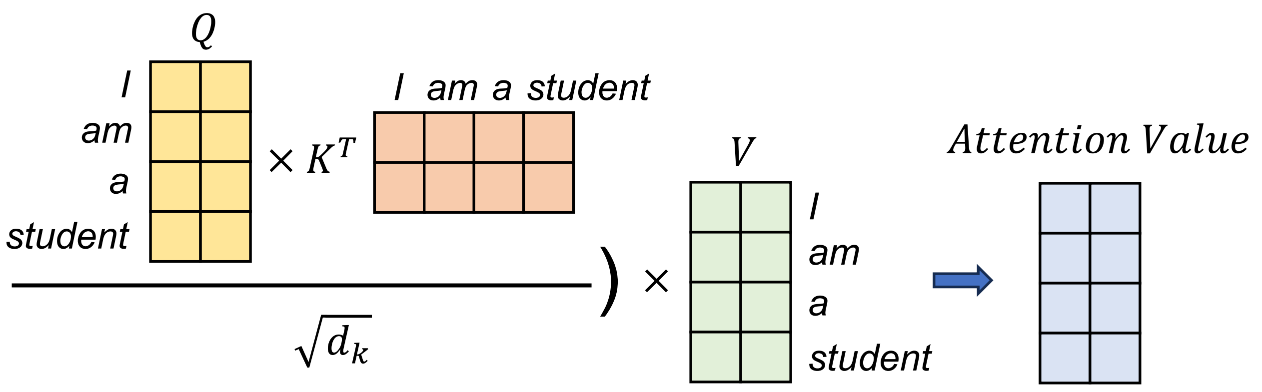

동아대학교 DONG-A UNIVERSITY

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) **I am a student**

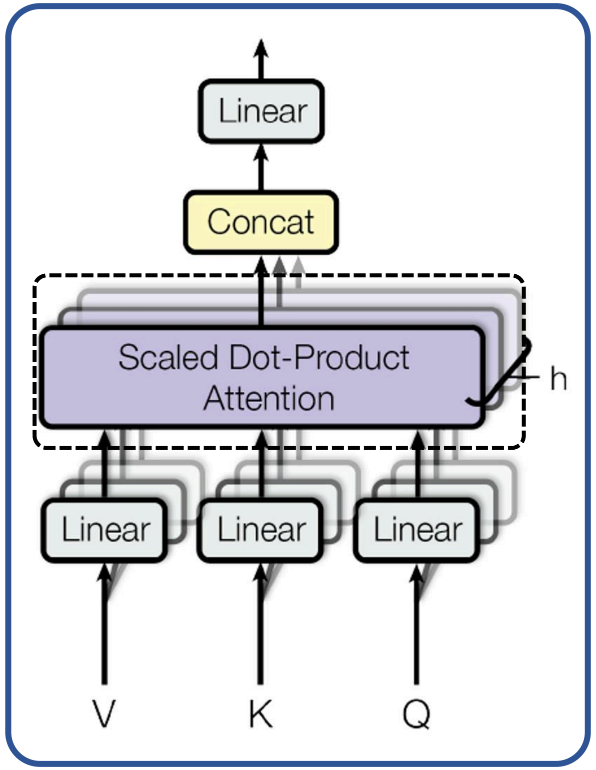

Multi-head Self-Attention

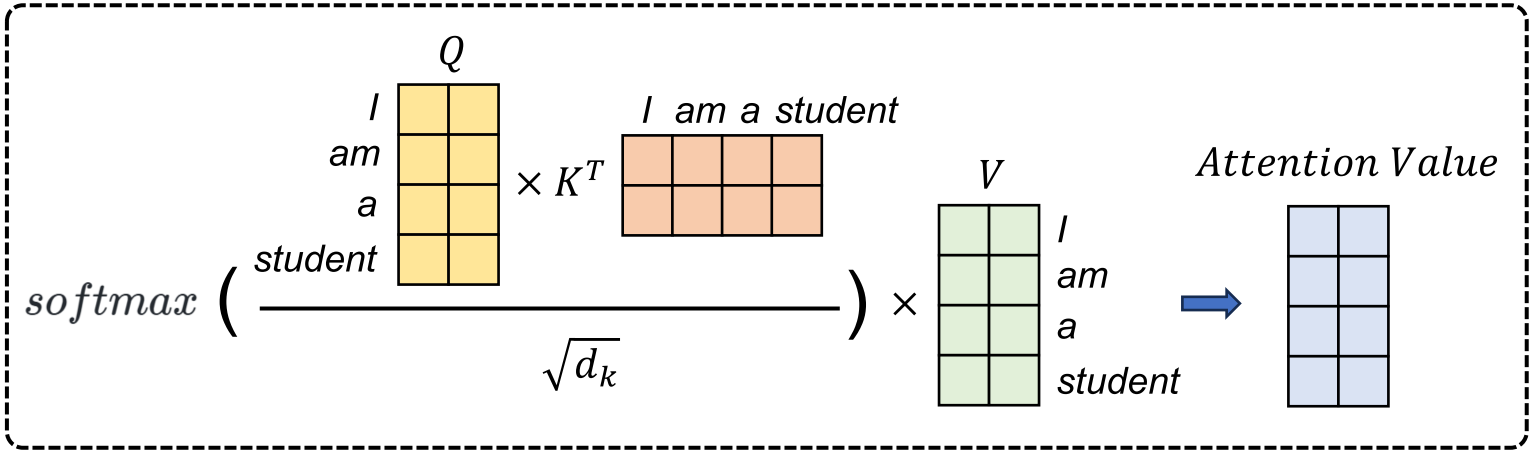

$$softmax\left(\frac{Q \times K^T}{\sqrt{d_k}}\right) \times V$$

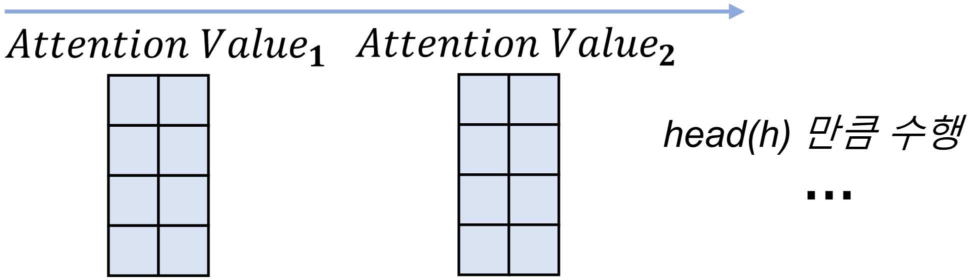

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) **I am a student**

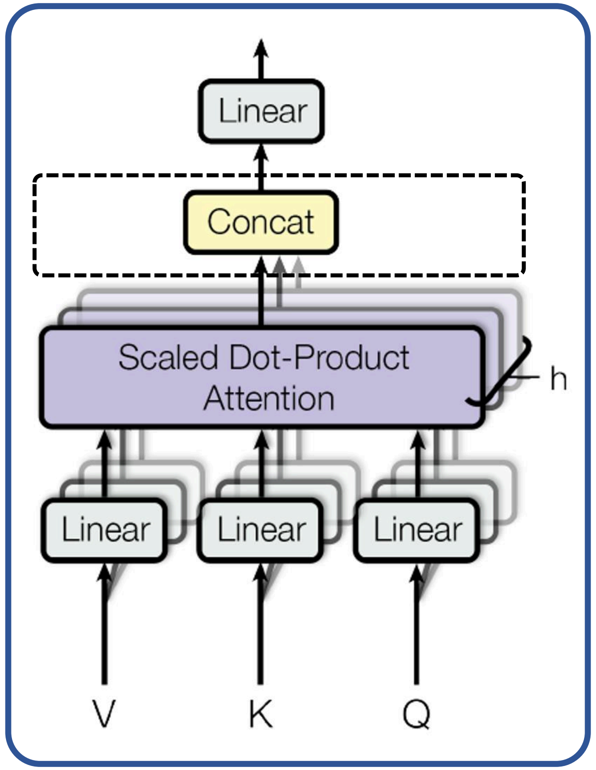

Multi-head Self-Attention

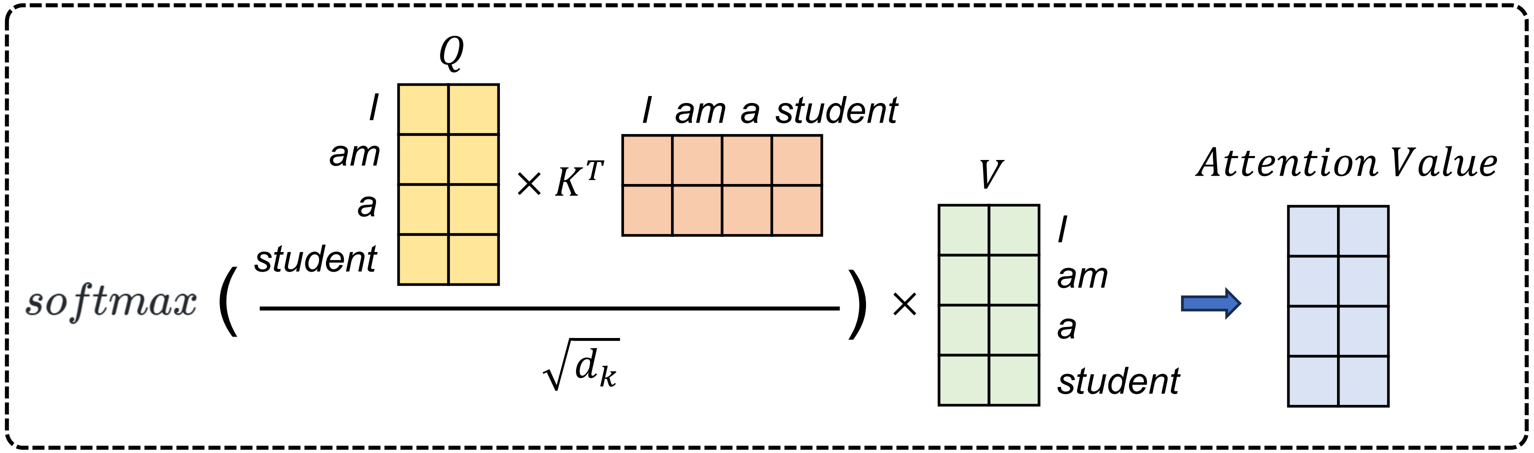

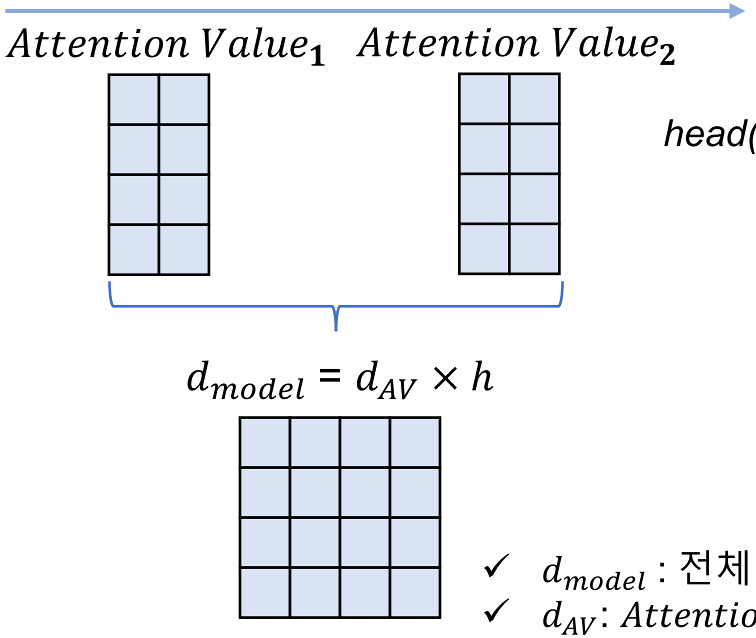

head(h) 만큼 수행

...

- ✓ d_{model} : 전체 임베딩 차원 수
- ✓ d_{AV}: $Attention\ Value$ 차원 수
- ✓ head(h): 2로 가정

Transformer

- Encoders
  - Multi-head Self-Attention
  - Scaled Dot-Product Attention
- Ex.) **I am a student**

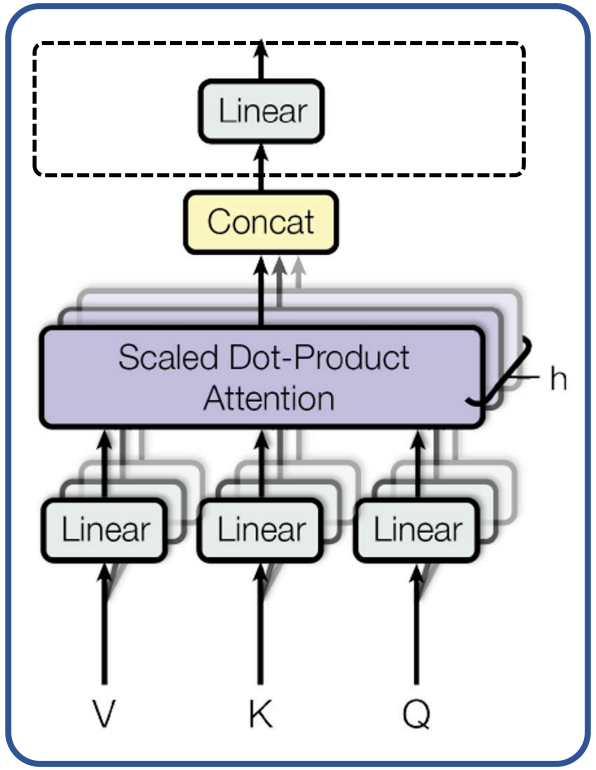

Multi-head Self-Attention

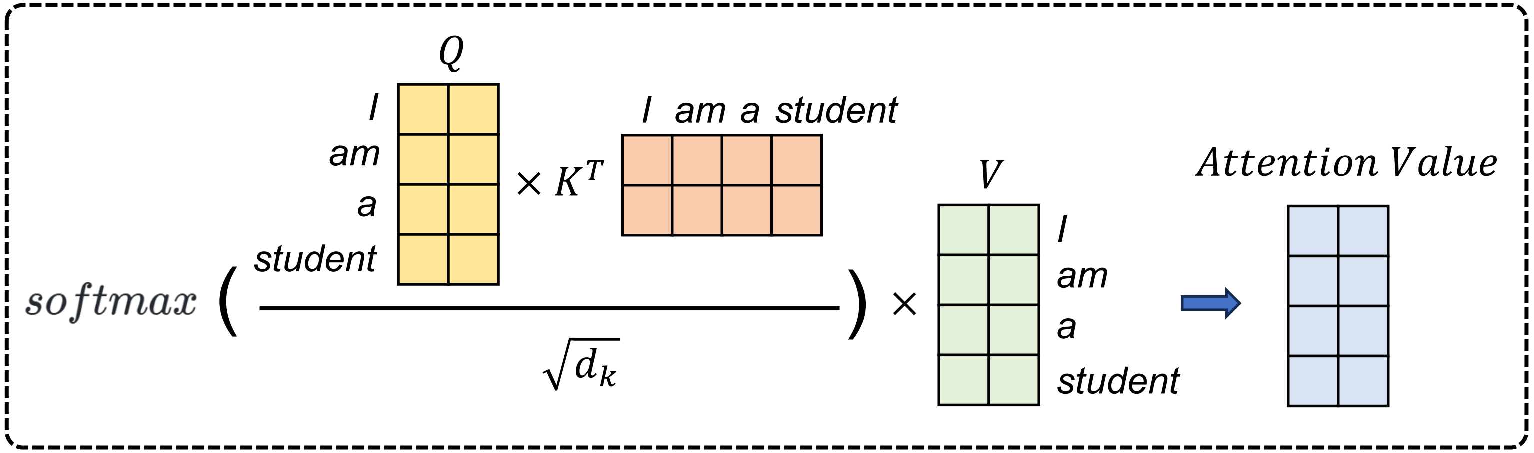

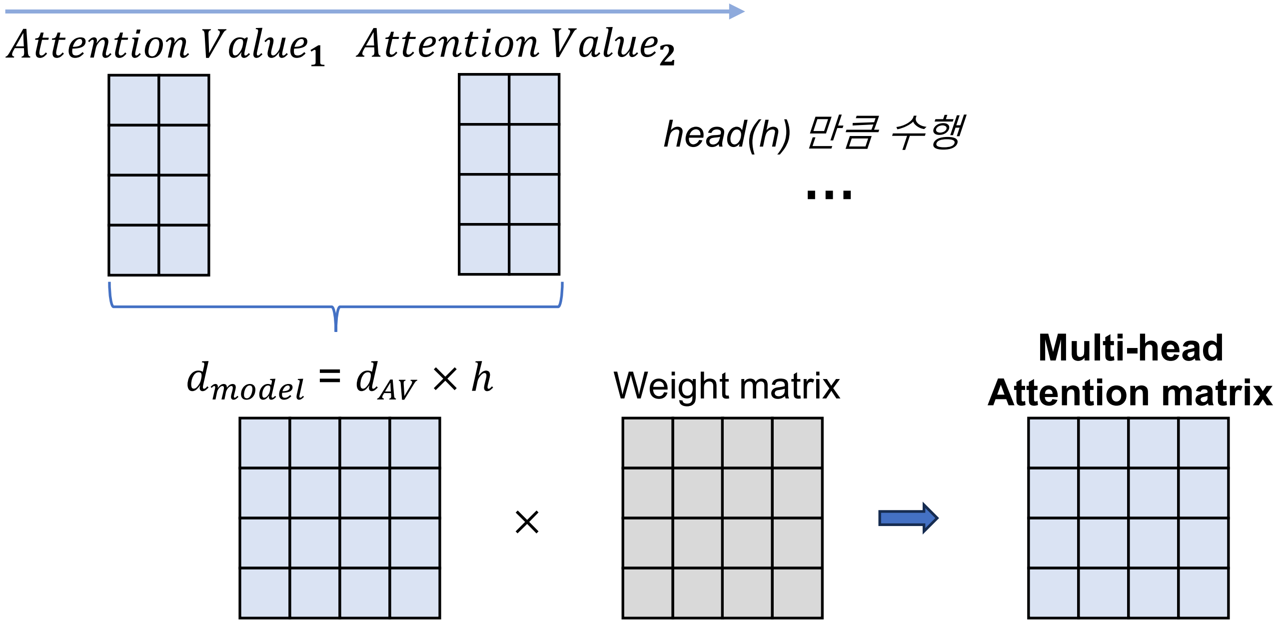

Transformer

- Encoders
  - Multi-head Self-Attention

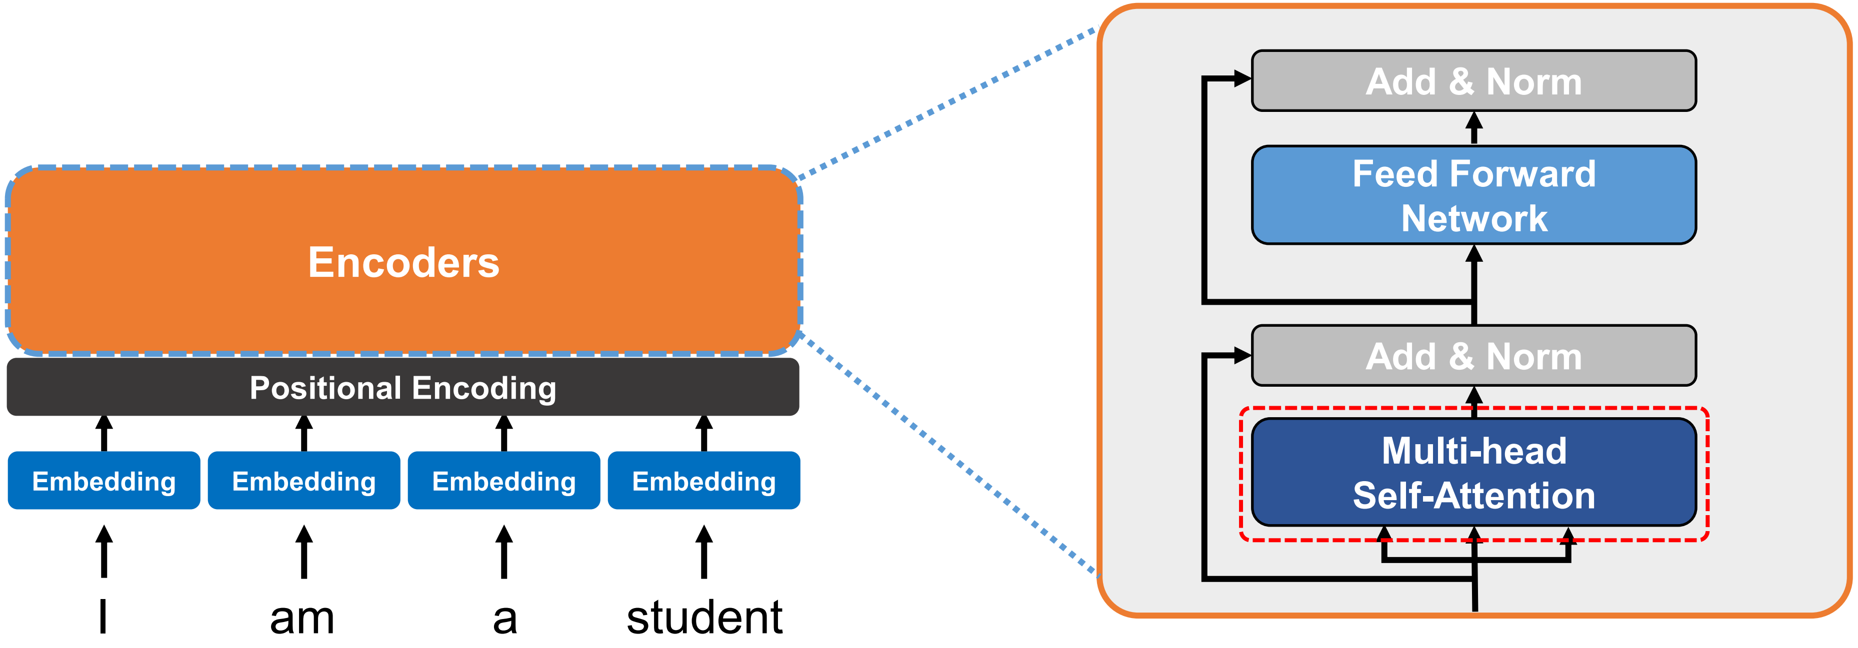

- Encoders
  - Residual Connection & Layer Normalization

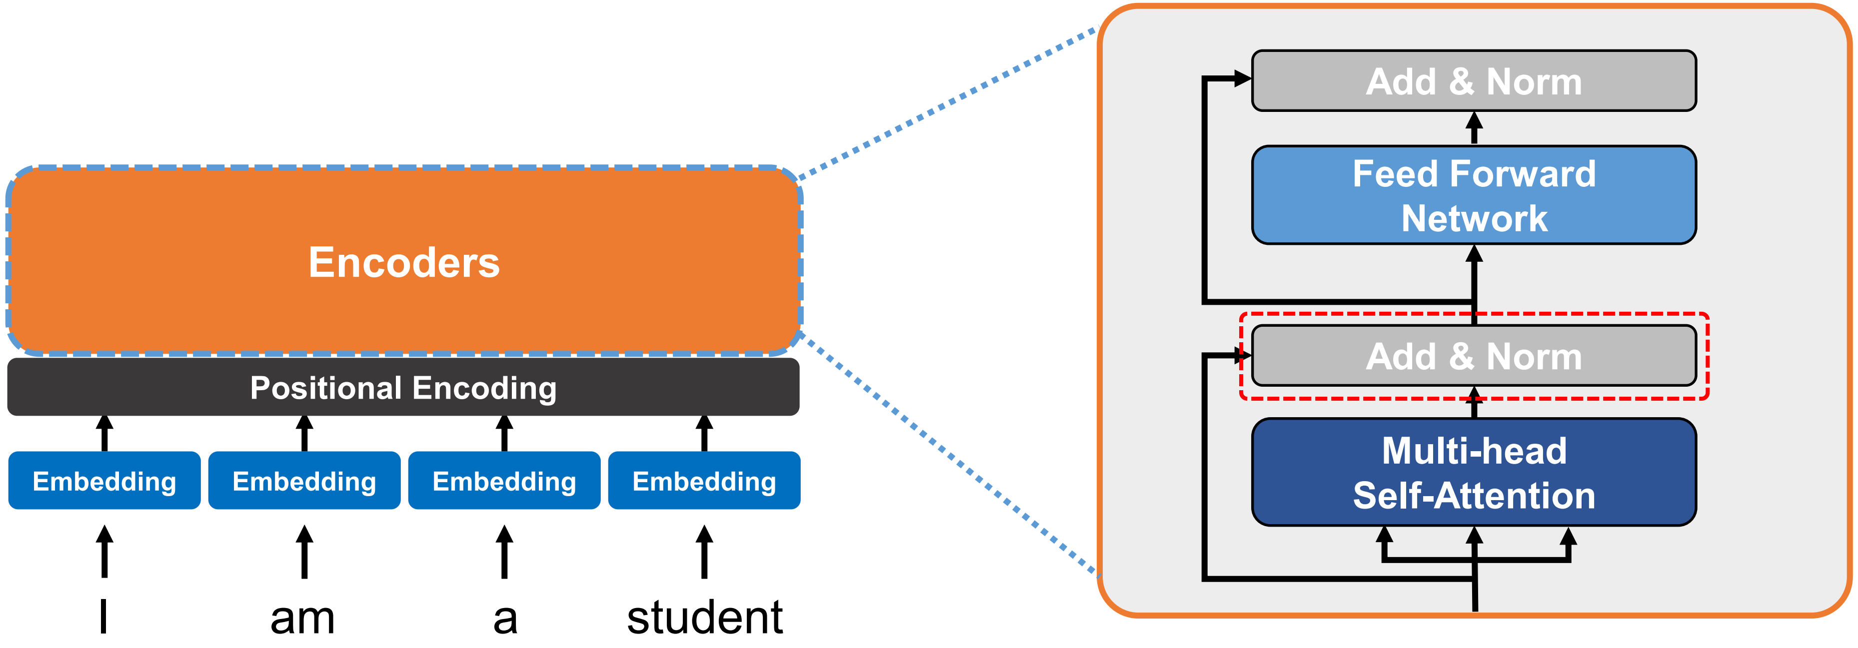

동아대학교 DONG-A UNIVERSITY

- Encoders
  - Residual Connection & Layer Normalization

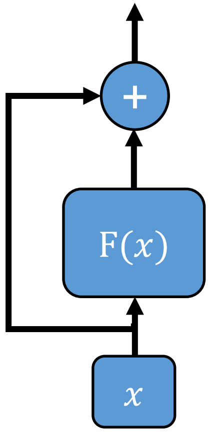

$$H(x) = x + F(x)$$

Residual Connection

$$\hat{x}_{i,k} = \frac{x_{i,k} - \mu_i}{\sqrt{\sigma_i^2 + \epsilon}}$$

- ✓ x_i : 입력벡터
- ✓ k: 벡터 x_i 의 각 차원
- ✓ μ_i: 평균
- ✓ σ_i^2: 분산
- ✓ ϵ: 분모가 0이 되는 것을 방지

Layer Normalization

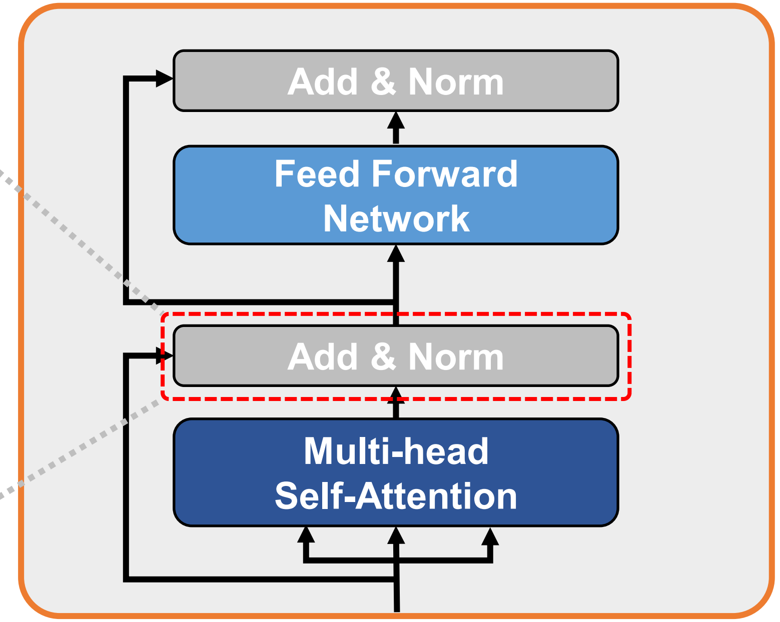

- Encoders
  - Feed Forward Network

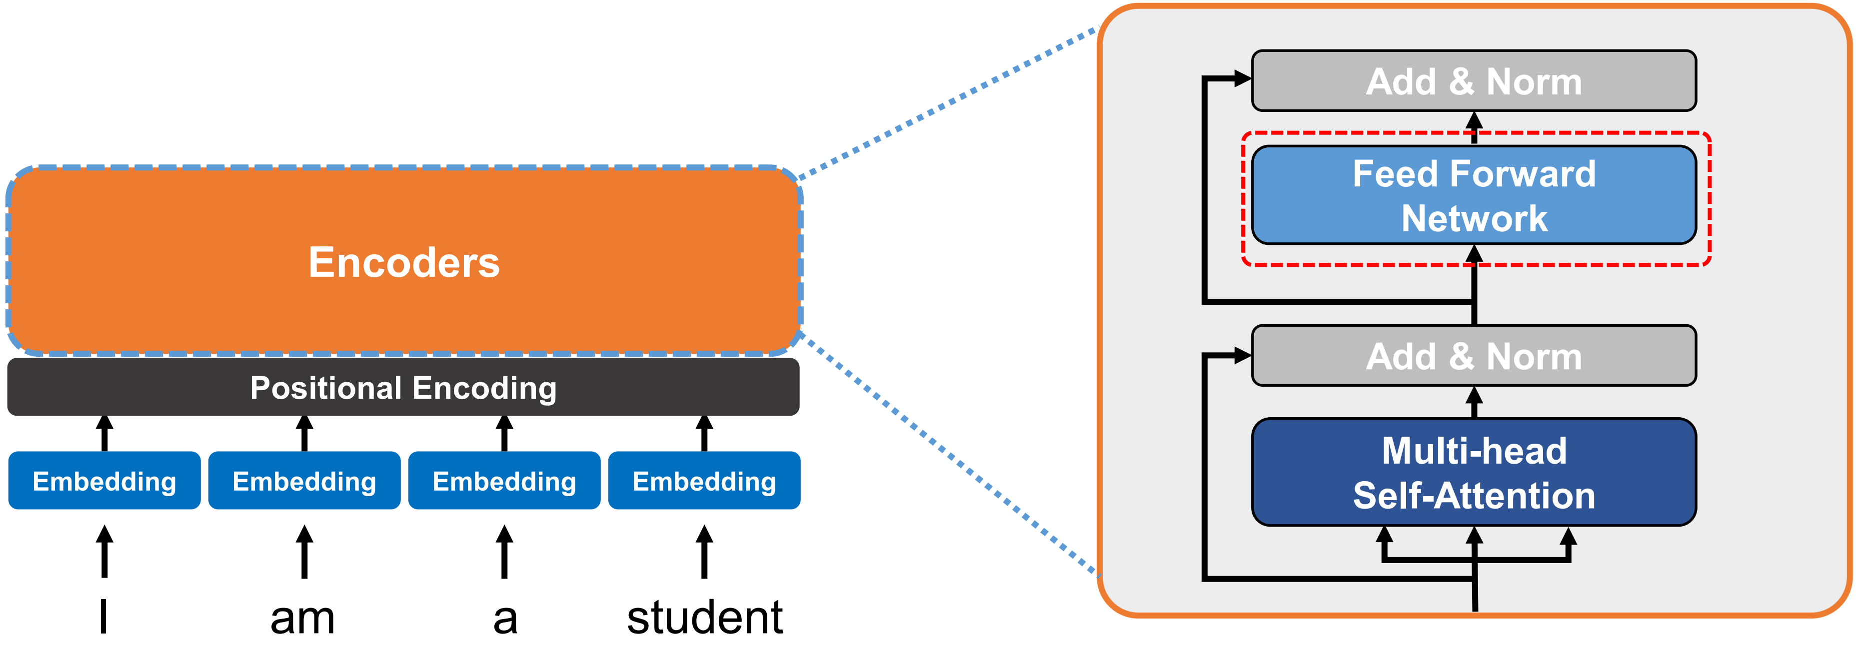

Transformer

- Encoders
  - Feed Forward Network

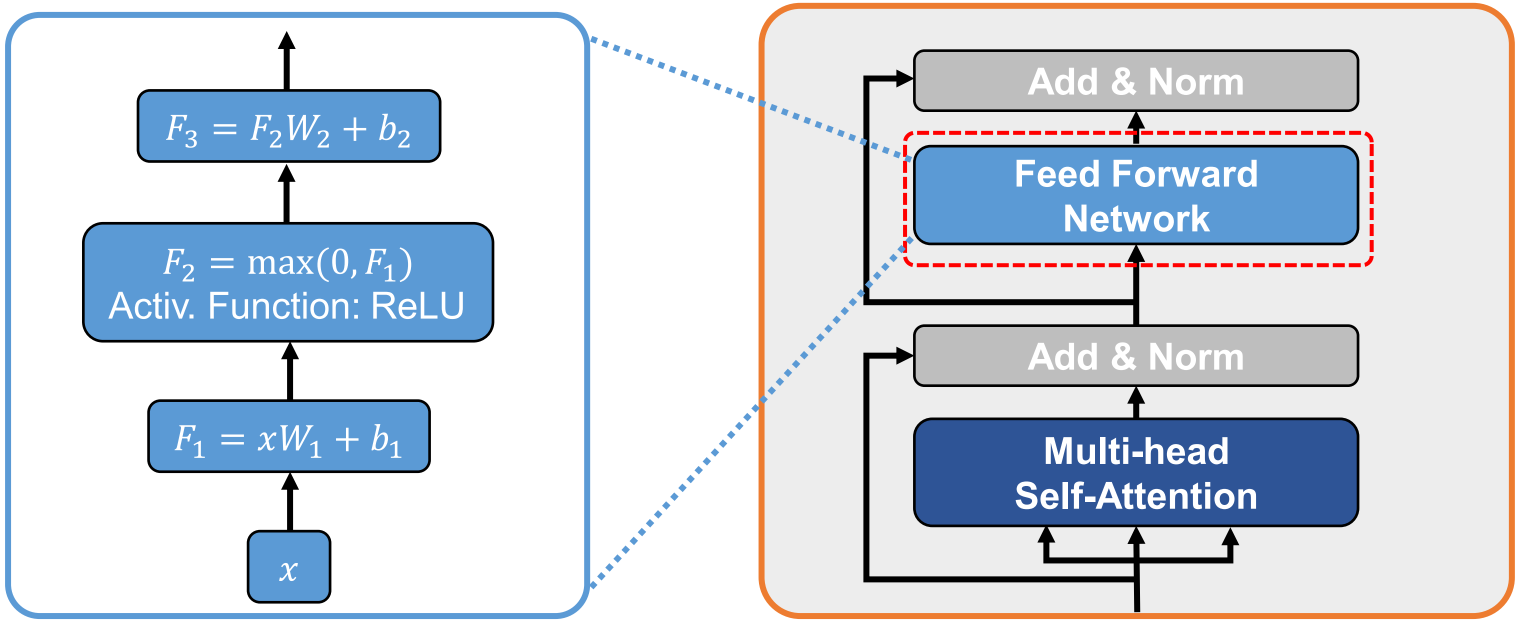

$$\mathrm{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

Transformer

- Decoders

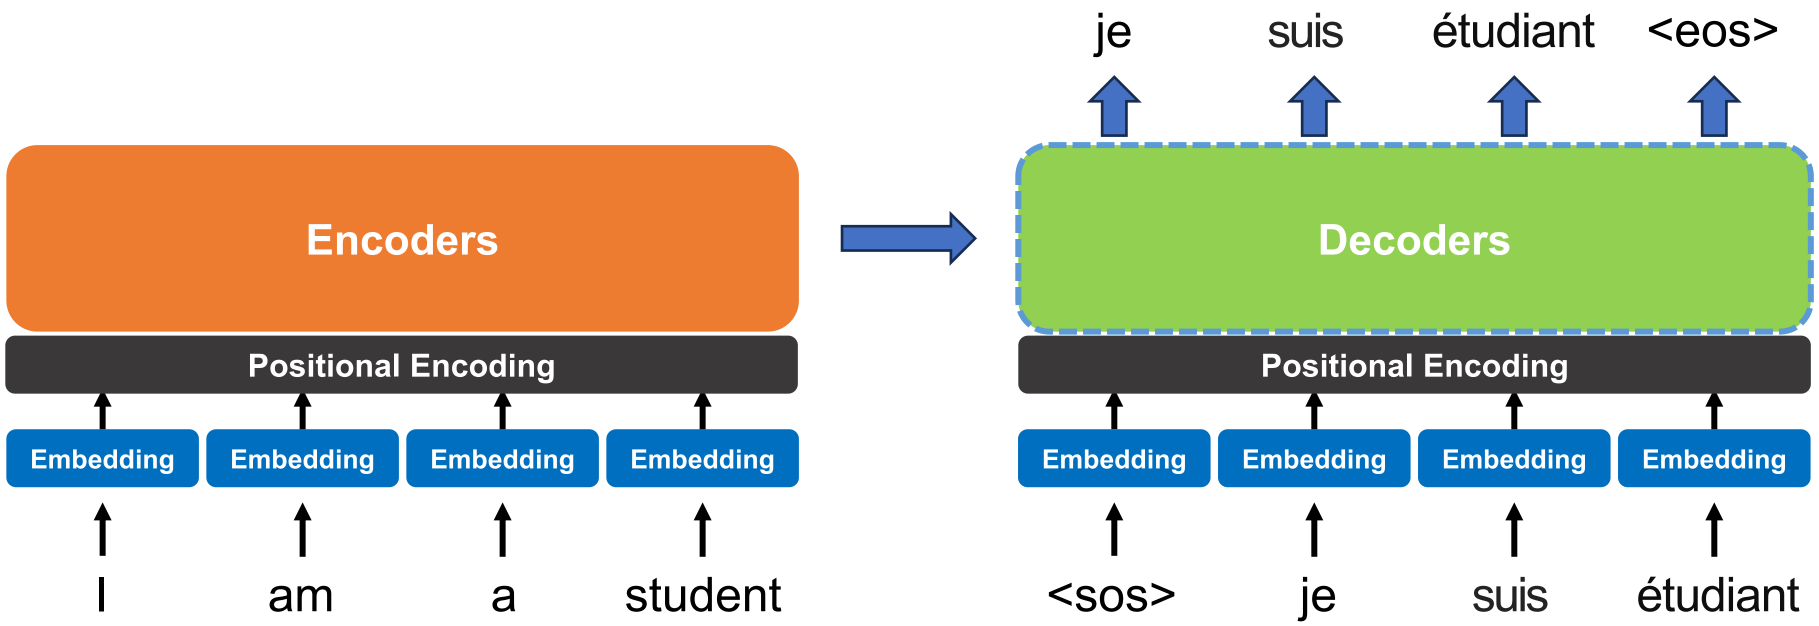

Transformer

- Decoders

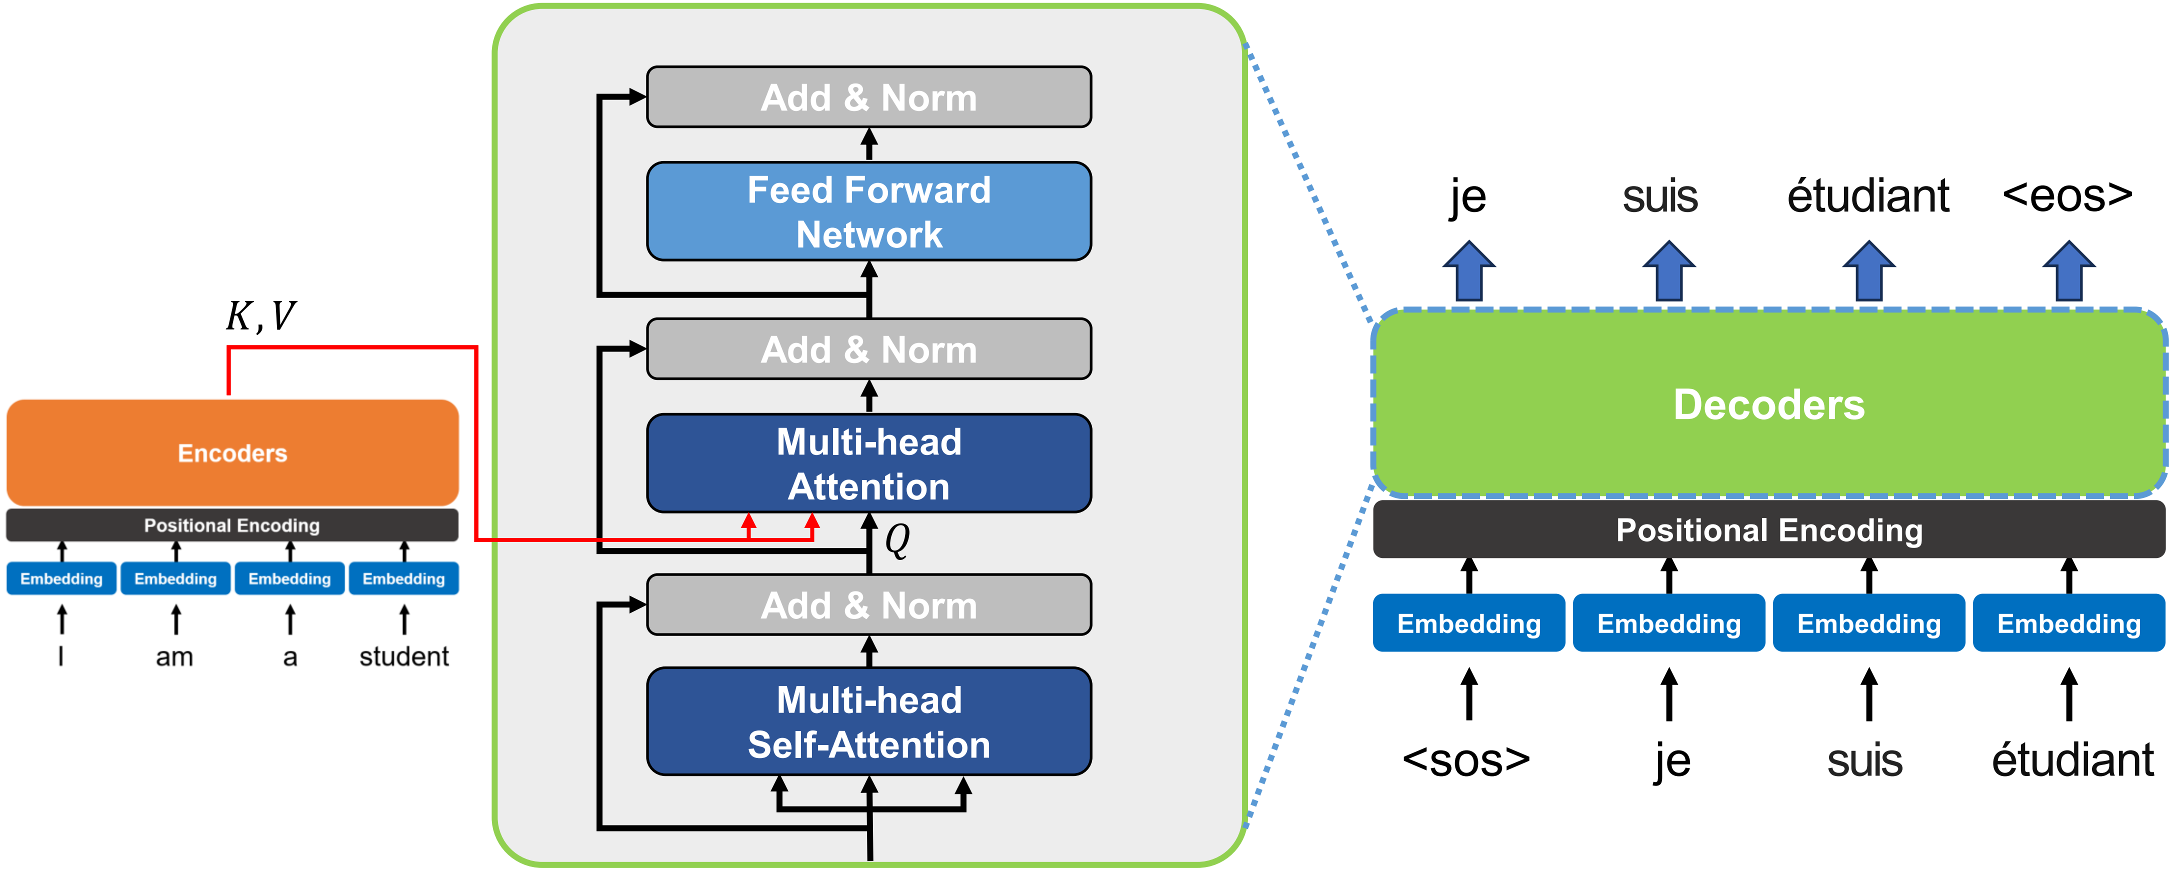

Transformer

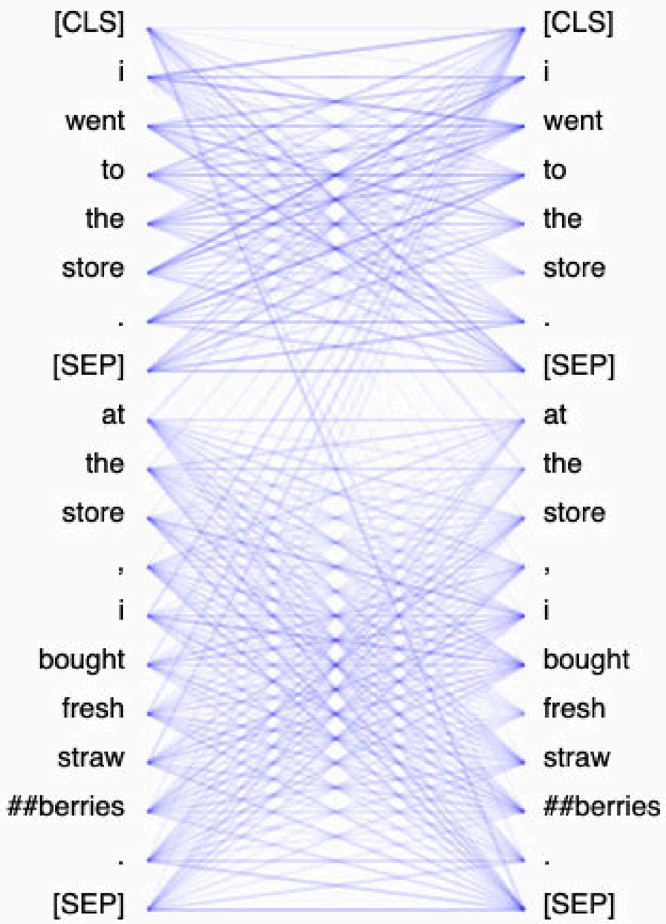

Transformer

- Transformer 등장 이후 많은 분야에서 연구

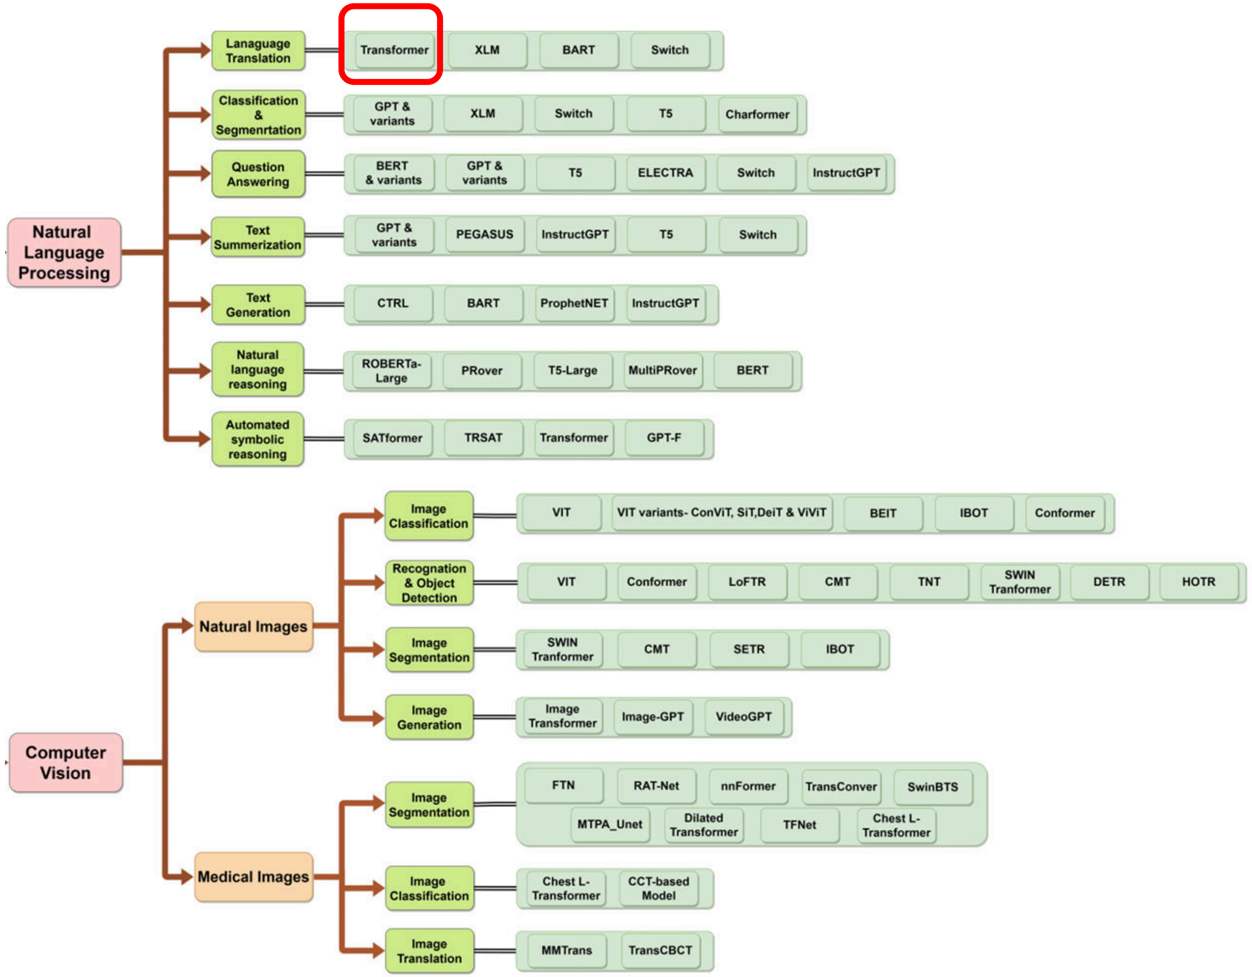

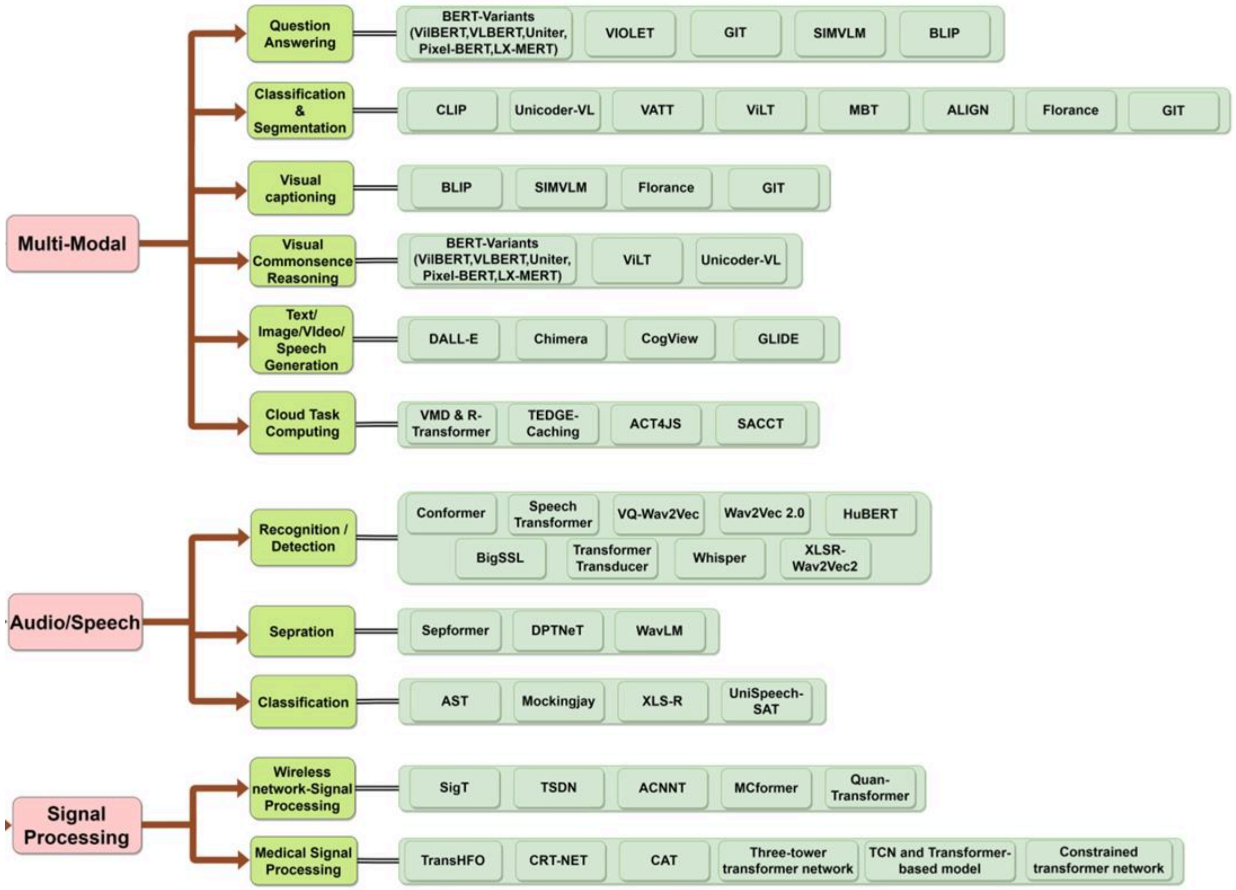

동아대학교 DONG-A UNIVERSITY

Transformer

- Transformer 등장 이후 많은 분야에서 연구

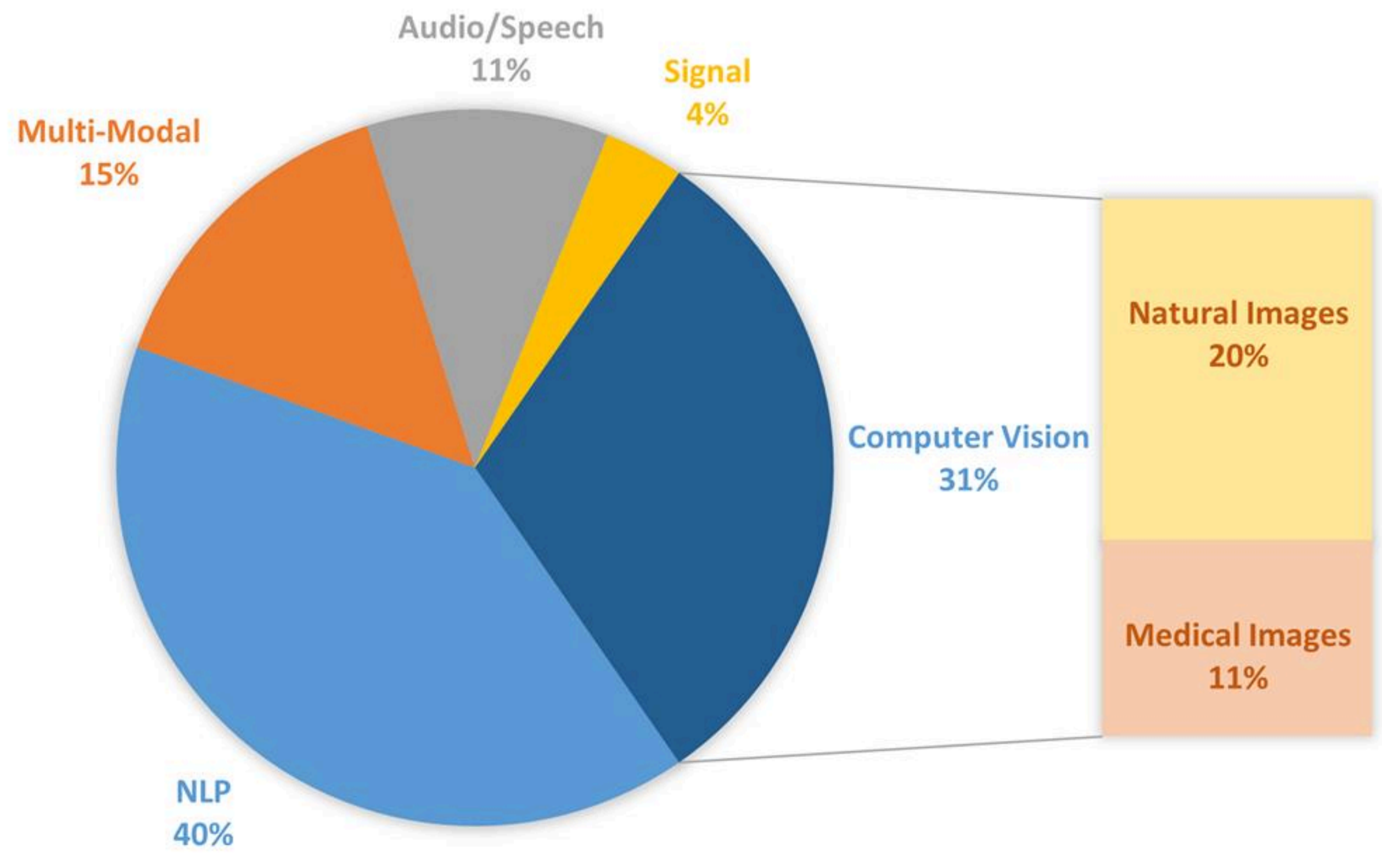

Figure 4: Proportion of transformer application in Top-5 fields

동아대학교 DONG-A UNIVERSITY

Questions & Answers

Dongsan Jun (dsjun@dau.ac.kr)
Image Signal Processing Laboratory (www.donga-ispl.kr)
Division of Computer·AI Engineering
Dong-A University, Busan, Rep. of Korea