

Quantum Machine Learning


HYUNHO PARK
hyunhopart@megazone.com
Quantum Innovation Lab

머신러닝 기술 발전 그래프

Exponential growth of parameters in notable AI systems

Parameters are variables in an AI system whose values are adjusted during training to establish how input data gets transformed into the desired output; for example, the connection weights in an artificial neural network.

Number of parameters (plotted on a logarithmic axis)



Data source: Epoch AI (2025)

OurWorldinData.org/artificial-intelligence | CC BY

Note: Estimates are based on AI literature with uncertainty up to a factor of 10. The regression lines show a sharp rise in parameters since 2010, driven by the success of deep learning methods that leverage neural networks and massive datasets.

파라미터의 폭발적 팽창

- 2010년대 초반 수천만 개 수준이던 모델 가중치가 최근 수조 개 단위로 증가했습니다.
- 연구기관 Epoch AI에 따르면, 주요 AI 모델의 파라미터 수는 2010년 기점으로 **매년 약 2배씩** 증가하는 추세를 보입니다.


레이어 깊이의 진화

- 초기 10개 미만의 얇은 신경망 구조에서, feature를 세밀하게 학습하기 위해 레이어를 수백 개까지 깊게 쌓는 방식(ResNet 등)으로 진화했습니다.
- 현재는 고도로 복잡한 트랜스포머 연산 블록을 겹겹이 쌓아 성능을 극대화하고 있습니다.

고전 컴퓨팅의 한계 도달

- 모델 훈련에 필요한 연산량(FLOPs)은 파라미터 증가 속도보다 더 가파르게 상승하여 **약 6개월마다 2배씩** 증가하고 있습니다.
- 천문학적인 하드웨어 구축 비용, 막대한 전력 소비, 훈련 소요 시간 등 고전 컴퓨터 기반 구조의 근본적인 한계가 노출되고 있습니다.

머신러닝 대표 알고리즘



머신러닝 알고리즘별 QML 최신 트렌드

고전 ML 알고리즘	초기 양자 접근 (과거)	QML 적용 트렌드 (최신)	최신 SOTA 성능 및 주요 결과	대표 참고 문헌
Neural Networks	양자 모델에 대한 초기 탐색 수준	하이브리드 양자 신경망(HQCNN, CQ-CNN): 기존 CNN 구조에 매개변수화된 양자 회로를 결합하여 특징 추출	의료 영상 분류 SOTA: 고전 딥러닝 대비 파라미터 99.99% 감소 (수백만 개 → 1만여 개) 및 96.4%~97.5% 정확도 달성	Hybrid Quantum-Classical Neural Networks for Healthcare Prediction Powered by Automated Scientific Discovery (2026)
서포트 벡터 머신 (SVM)	고전적 거리 계산의 효율적 수행	양자 커널 매핑(Quantum Kernel): 복잡한 비선형 데이터를 기하급수적으로 큰 차원의 Hilbert Space으로 매핑하여 학습	시계열/신호 데이터 SOTA: NISQ 환경에서도 뇌파(EEG) 및 금융 데이터 분류 정확도 95~99% 달성	QSVM-QNN: Quantum Support Vector Machine Based Quantum Neural Network Learning Algorithm for Brain-Computer Interfacing Systems (IEEE, 2026)
K-Means / k-NN	고전적 거리 계산의 효율적 수행	양자 충실도 및 분산 처리: 데이터의 양자 인코딩 기술 고도화, 차원 축소와 병행	3D 및 희소 데이터 SOTA: 극단적으로 적은 데이터 포인트 환경에서 고전 SOTA 도달	HyQuRP: Hybrid quantum-classical neural network with rotational and permutational equivariance for 3D point clouds (2026)
Decision Trees	양자 모델에 대한 초기 탐색 수준	양자 랜덤 포레스트(QRF): 앙상블 기법과 양자 중첩을 결합하여 다중 트리 탐색 병렬화	트리의 Node마다 양자 커널 기반의 판별기를 두어, 양자 역학적 특징 추출과 앙상블 기법을 결합하여 분류 성능 향상	A kernel-based quantum random forest for improved classification (2022~2023)
확률 모델 (베이지안 이론)	양자 시스템 언어로의 재구성	양자 상태 판별 및 확률 마르코프 모델 고도화: 양자 회로를 활용한 복잡한 확률 분포 샘플링 (QGAN 등과 연계)	6G 통신 네트워크 자원 할당 최적화, 거대 시스템 내 이상 탐지 속도 대폭 향상	Generative Quantum Machine Learning via Denoising Diffusion Probabilistic Models (QuDDPM) (2023~2026) Robust Iterative Learning Hidden Quantum Markov Models (2025)

전체 경향성

- **NISQ 친화적:** 순수 양자 알고리즘보다, Optimizer와 양자 회로를 결합한 하이브리드 방식 구현
- **Small Data & 고효율:** 적은 수의 레이어, Qubit와 파라미터만으로도 복잡한 차원 표현하고자 함

양자 데이터 매핑 (Quantum Encoding): 클래식 데이터를 큐비트로 변환하는 전략

원핫 인코딩(One-Hot Encoding)의 한계와 대안

- **기존 접근법**: 이진 문자열 $x_1, x_2, \dots, x_n$ 을 2^n 차원 공간의 n-qubit 양자 상태 $|x_1, x_2, \dots, x_n\rangle$ 로 변환합니다.
- **문제점**: N개의 클래스를 분류할 때 아홉곳에만 N개의 큐비트가 그대로 낭비됩니다.
- **효율적 대안**: 양자 중첩을 활용하면 $\lceil \log_2 N \rceil$ 개의 큐비트만으로 N개의 확률 진폭을 모두 표현할 수 있습니다 (예: 8개 클래스 = 단 3큐비트 소모).

정형 데이터 (Tabular Data) 매핑

- **앵글 인코딩 (Angle Encoding)**: 스칼라값을 양자 게이트의 회전 각도(예: $R_x(\theta), R_y(\theta)$)로 변환합니다.
N개의 특성에 N개의 큐비트가 필요하며, 현재 하이브리드 VQC 구조에서 가장 안정적으로 쓰이는 표준 방식입니다.
- **진폭 인코딩 (Amplitude Encoding)**: 고전 정보를 양자 상태의 진폭(Norm) 내에 인코딩합니다.
길이 N의 데이터를 $\log_2 N$ qubit에 압축하여 파라미터를 극단적으로 줄이지만, 초기 상태 준비가 까다롭다는 단점이 있습니다.

시계열 데이터 (Sequential Data) 매핑

- **양자 마르코프 모델 (HQMM)**: 데이터의 상태 전이를 열린 양자 시스템의 연산자로 모델링하여 매핑합니다.
- **하이브리드 시계열 인코딩**: 데이터를 슬라이딩 윈도우 형태로 잘라 스텝별로 앵글 인코딩을 수행하거나, 고전 RNN/LSTM을 거쳐 나온 은닉층 벡터를 가벼운 양자 회로에 매핑하는 방식이 주류입니다.

최근 AI의 트렌드: '생성형 AI'로, 양자 컴퓨터는 그 본질 자체가 '확률 생성기'이므로, 생성 모델에서 효율성, 성능 향상 기대됨

양자 컴퓨터 = 자연적인 확률 생성기 (Natural Probability Generator)

- 고전 머신러닝 알고리즘들(SVM, KNN 등)이 데이터를 '분류'하는 데 목적이 있다면, 생성 모델은 새로운 데이터를 '생성'해야 함
- 고전 컴퓨터는 수학적 연산을 통해 무작위성을 흉내 내지만, 양자 컴퓨터는 중첩과 얽힘 상태를 측정할 때 본질적으로 거대한 확률 분포를 붕괴시키며 데이터를 쏟아 냄 → 양자 시스템 자체 = 훌륭한 생성기

실습 타겟 선정: 하이브리드 QuGAN

- **QuGAN:** 양자 얽힘(Entanglement)만 잘 조작하면 복잡한 확률 분포를 자연스럽게 생성함
→ 양자의 본질적 특성을 GAN에 적용하여 양자 생성적 적대 신경망 알고리즘 연구함
- **적은 Layer:** QuGAN은 고전 GAN이 199개의 파라미터를 필요로 하는 작업을 10개의 파라미터(-94.98%)만으로 동일하게 수행함
- **실습 방향:** "적은 레이어로 직접 코드를 구현하고 의미 있는 결과를 도출한다"는 교육 목표에 부합하는 모델로 선정함

GAN (Generative Adversarial Network)

Q u a n t u m
Innovation Laboratory

GAN (Generative Adversarial Network)

GAN은 'Generative Adversarial Network'의 약자로, '생성적 적대 신경망'을 의미함

- 데이터 '생성'을 목적으로 하는 인공지능 모델 중에서도 대표적인 접근 방식 중 하나로 평가받고 있음
- GAN의 핵심은 **두 개의 개별적인 인공지능 모델이 서로 '적대적 경쟁'하는 방식으로 학습하며 발전함**
- 주로 이미지, 음성, 텍스트 등 실제와 유사한 새로운 데이터를 만들어내는 데 활용됨

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

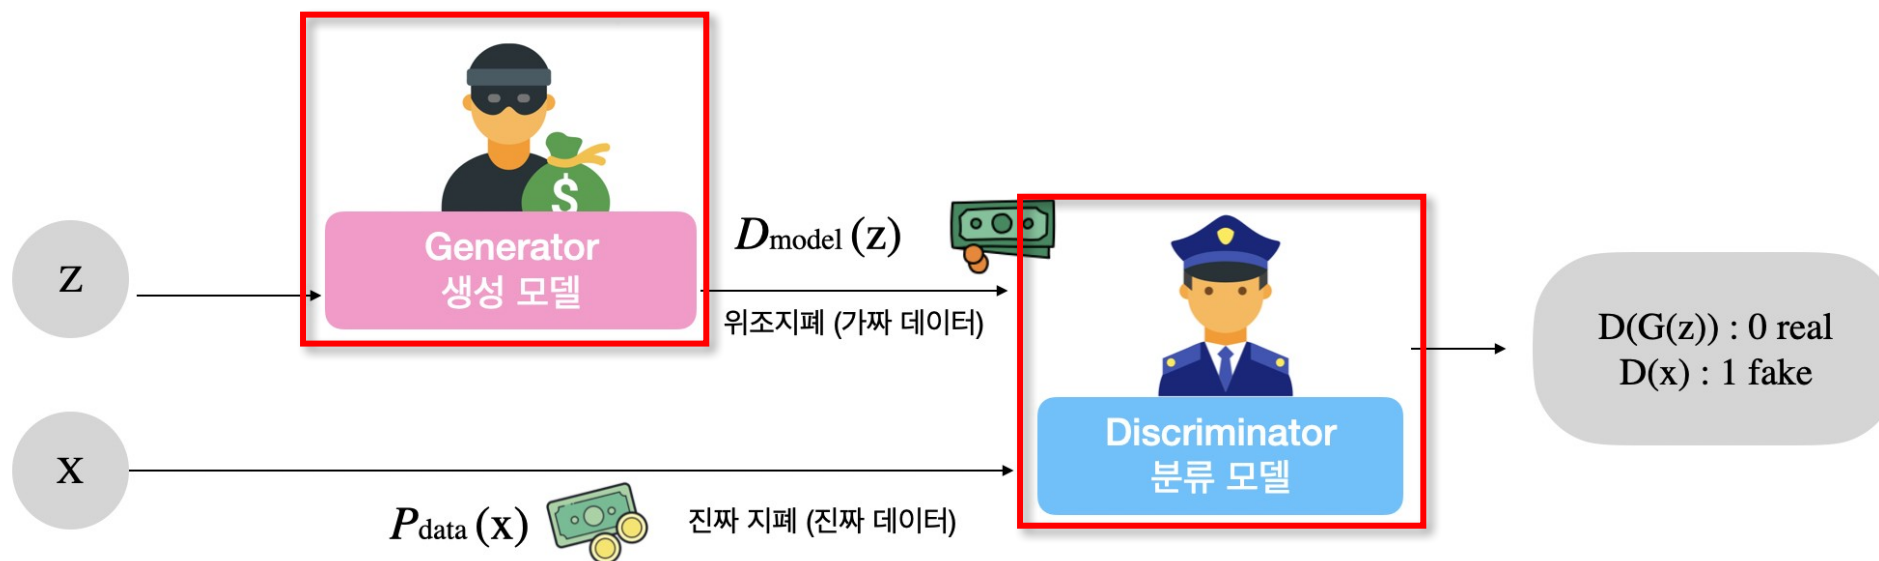


Image :

<https://www.pexels.com/photo/54>
Copyright 2020 © MegazoneCloud Corp. ALL RIGHTS RESERVED.

생성자(Generator) & 판별자(Discriminator)

생성자 (Generator)

무작위 노이즈를 입력받아 실제와 유사한 '가짜 데이터'를 생성하는 신경망으로, 목표는 판별자를 성공적으로 속이는 것




판별자 (Discriminator)

'진짜 데이터'인지 생성자가 만든 '가짜 데이터'인지 구분하는 이진 분류 신경망으로, 목표는 진짜와 가짜를 정확하게 판별하는 것

생성자/판별자 학습 과정

두 모델은 서로 경쟁하면서 학습함

생성자는 점점 더 정교한 가짜 데이터를 만들고, 판별자는 진짜와 가짜를 더 날카롭게 구별하려고 노력함
적대적 경쟁의 결과로, **생성자는 궁극적으로 실제 데이터와 거의 구별할 수 없는 고품질의 데이터를 만들어낼 수 있게 됨**



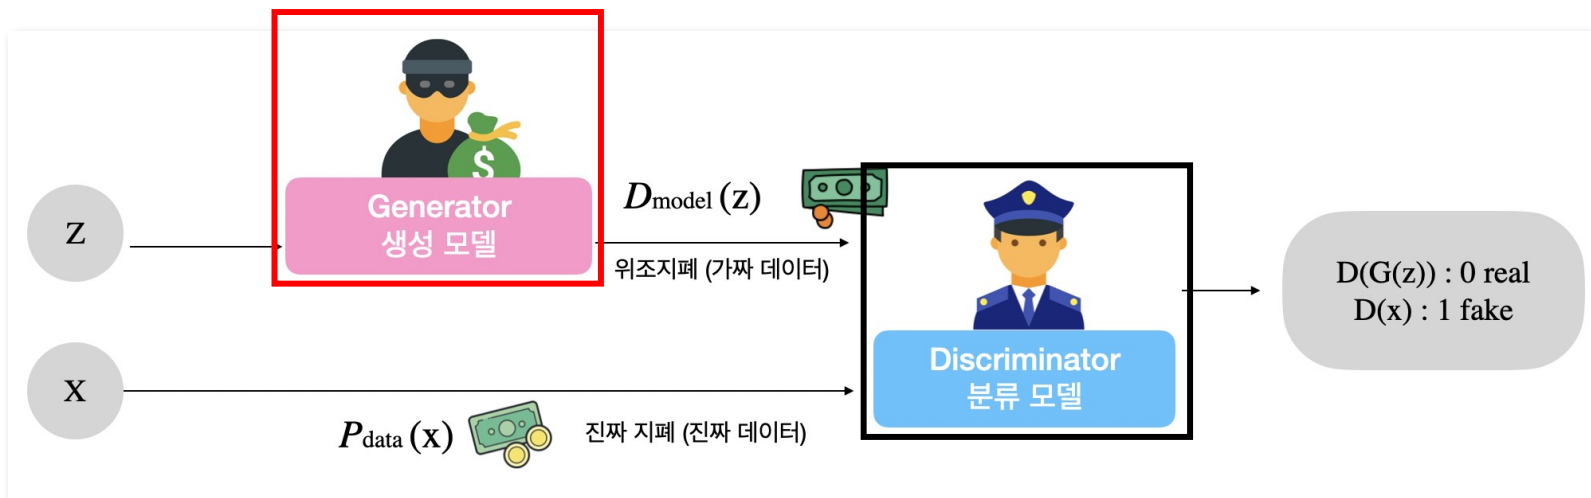
1. 생성자는 가짜 데이터를 만들고, 판별자는 진짜 데이터와 가짜 데이터를 함께 입력 받아 구분함
2. 판별자가 올바르게 판별하면 보상을 받고, 틀리면 페널티를 받음
3. 생성자는 판별자를 속이는 데 성공하면 보상을 받음
4. 피드백을 통해 생성자는 점점 더 정교한 가짜 데이터를 만들고, 판별자는 더욱 정교하게 진짜와 가짜를 구분하는 능력을 키움
5. 경쟁은 생성자가 실제 데이터와 거의 구별 불가능한 데이터를 만들어낼 때까지 반복함

QuGAN Architecture

Q u a n t u m
Innovation Laboratory

GAN vs QuGAN 아키텍처

GAN



QuGAN




Fig. 4: Inter-model Communication Architecture

QuGAN System Architecture





Fig. 1: QuGAN System Architecture

QuGAN Data Flow

Q u a n t u m
Innovation Laboratory


QuGAN DATA FLOW



Dimension Reduction

Dimension Reduction 차원 축소 (784 차원 → 4 차원)


- QuGAN은 성능 평가를 위해 손으로 쓴 숫자 이미지 데이터셋인 MNIST를 사용함
- MNIST 이미지의 원래 크기는 28x28 픽셀이며, 이를 펼치면 (1D Flatten) 784개의 픽셀 값으로 이루어진 784차원의 벡터가 됨
- 현재의 양자 컴퓨터나 시뮬레이터로 784개의 특징(차원)을 모두 다루는 것은 어려움
- 주성분 분석(Principal Component Analysis, PCA)을 사용하여 데이터의 차원을 줄임
- PCA는 데이터의 분산(정보량)을 가장 잘 설명하는 주요 축(주성분)들을 찾아내어 원본 데이터를 더 낮은 차원으로 압축하는 방법
- 논문에서는 PCA를 통해 784차원의 이미지 데이터를 정보 손실을 감수하고 4차원의 데이터로 축소하며, 각 이미지는 이제 4개의 숫자 값으로 표현됨



Qubit Encoding 1-2

Qubit Encoding (Qubit Encoding)


- 정규화된 4차원 데이터를 실제 큐비트에 입력(인코딩)하는 과정
- 4차원 데이터이므로 4개의 큐비트를 사용하며, 각 큐비트는 데이터의 각 차원 값을 담당함
- 데이터 값 x (0과 1 사이의 값)를 큐비트의 상태로 인코딩하기 위해, 특정 각도 θ 만큼 큐비트를 회전시키는 양자 게이트(RY(θ) 게이트)를 사용함
- 회전 각도 θ 는 다음 공식을 통해 계산됩니다
 - $\theta = 2 \cdot \arcsin(x)$
- 계산된 각도 θ 로 RY 게이트를 큐비트에 적용하면, 해당 큐비트를 측정했을 때 '1'이 나올 확률의 기대값이 정확히 원래의 데이터 값 x 와 같아짐
- MNIST 이미지 한 장은 다음과 같은 과정을 거쳐 양자 회로에 입력됩니다
 - 28x28 픽셀의 784차원 데이터를 PCA를 통해 4차원의 숫자 벡터로 압축함
 - 4개의 숫자 값을 각각 0과 1 사이로 정규화함 (Min-Max scaling)
 - 정규화된 4개의 값 (x_1, x_2, x_3, x_4)을 각각 위의 공식을 사용해 4개의 회전 각도 ($\theta_1, \theta_2, \theta_3, \theta_4$)로 변환함
 - 4개의 큐비트에 각각 해당하는 회전 각도만큼 RY 게이트를 적용하여 인코딩함




Qubit Encoding 2-2

Ancilla Qubit (보조 큐비트):

두 양자 상태(예: 생성된 상태와 기준 상태) 간의 유사도를 측정함 스왑 테스트 (Swap Test)의 보조 큐비트 측정 확률이 판별자의 '결과값'이 됨



QuGAN Generation 1-2



QuGAN Generation 2-2

QuGAN 생성 (QuGAN Generation)

1 Quantum Computer Output (4차원 데이터)

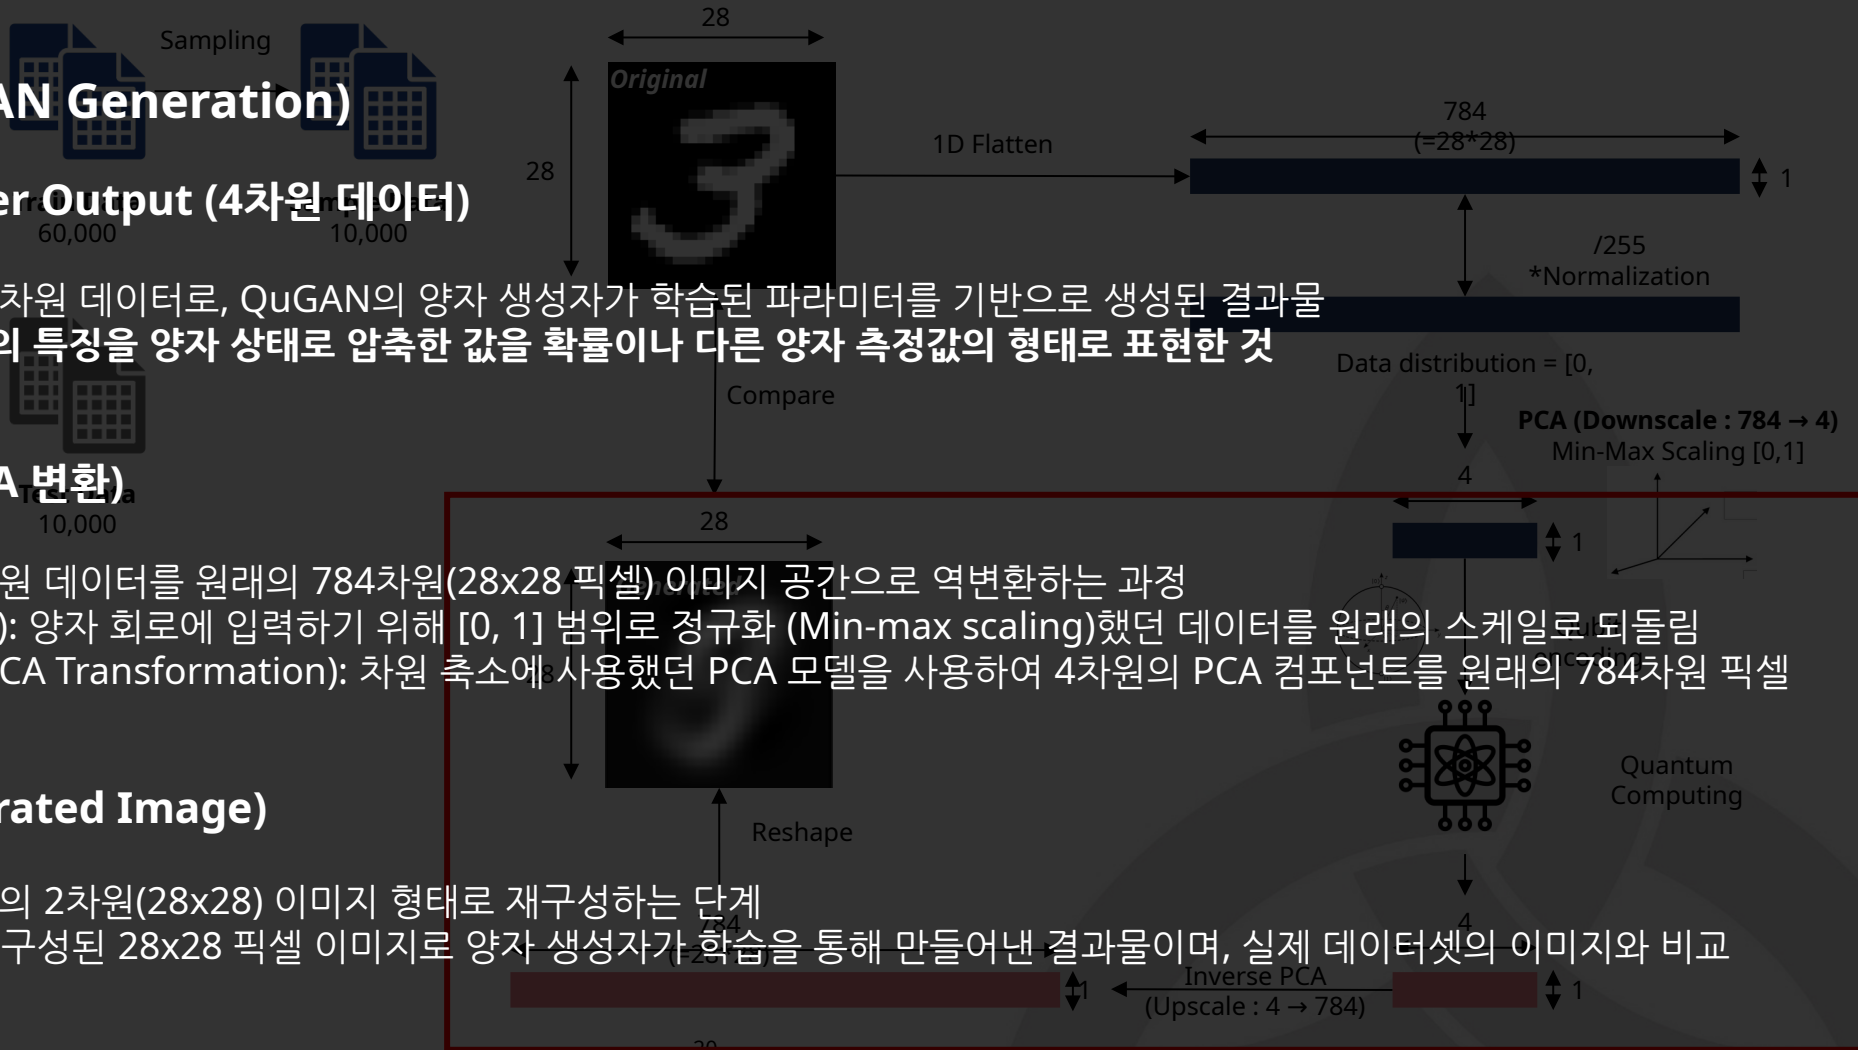
- 양자 컴퓨터에서 나온 4차원 데이터로, QuGAN의 양자 생성자가 학습된 파라미터를 기반으로 생성된 결과물
- 4차원 데이터는 이미지의 특징을 양자 상태로 압축한 값을 확률이나 다른 양자 측정값의 형태로 표현한 것

2 Inverse PCA (역 PCA 변환)

- 양자 생성자가 만든 4차원 데이터를 원래의 784차원(28x28 픽셀) 이미지 공간으로 역변환하는 과정
- 역스케일링 (Descaling): 양자 회로에 입력하기 위해 [0, 1] 범위로 정규화 (Min-max scaling)했던 데이터를 원래의 스케일로 되돌림
- PCA 역변환 (Inverse PCA Transformation): 차원 축소에 사용했던 PCA 모델을 사용하여 4차원의 PCA 컴포넌트를 원래의 784차원 픽셀 공간으로 되돌림

3 생성된 이미지 (Generated Image)

- 1차원 픽셀 배열을 원래의 2차원(28x28) 이미지 형태로 재구성하는 단계
- 최종적으로 복원되고 재구성된 28x28 픽셀 이미지로 양자 생성자가 학습을 통해 만들어낸 결과물이며, 실제 데이터셋의 이미지와 비교 대상이 됨




Data Comparison

원본 vs 생성 데이터


- 양자 생성자가 학습을 통해 만들어낸 결과물 Sample Data 28x28 픽셀 이미지와, 실제 데이터셋의 이미지와 비교하여 모델 훈련 및 성능 평가

Mnist
Dataset


Test
Data
10,000



Final Output 1-2



Final Output 2-2



E.O.D.

Q u a n t u m
Innovation Laboratory

Appendix. GAN Details

Q u a n t u m
Innovation Laboratory

QuGAN 연구 의미 - 양자 효율성 및 잠재력

Architecture	Parameters	¹⁾ Hellinger Distance
QuGAN	10	0.1951
C-GAN	20	0.4448
C-GAN	45	0.3234
C-GAN	96	0.2515
C-GAN	199	0.1945
C-GAN	1299	0.1389

■ 파라미터 규모 효율성

고전적 GAN(C-GAN)이 **199개의 파라미터**를 사용하는 것에 대비하여, QuGAN은 **10개의 파라미터**만으로 파라미터 수를 **94.98% 감소**하며 거의 동일한 성능을 달성함

■ 양자 시뮬레이션 결과 생성 가능

새로운 물질의 양자 상태 (분자 접지 상태, 스핀 배열 등) 등 생성하고 싶은 경우, 고전 컴퓨터는 양자 상태를 표현하는 데 지수적 자원이 필요한 것에 비해, **양자 생성 모델은 선형적 자원만 필요로 함**

1) Hellinger Distance는 0에 가까울수록 두 분포 (정답, 생성 결과)가 유사함을 의미

GAN vs QuGAN

비교 기준	Classical GANs	QuGANs
핵심 구성 요소	생성자와 판별자가 신경망으로 구현됨	생성자와 판별자 모두 양자 상태 충실도(Quantum State Fidelity)를 기반으로 동작하도록 설계된 양자 회로 로 구현됨
데이터 표현 방식	고전적 데이터(예: 이미지 픽셀)가 이진 비트 또는 실수 벡터로 표현됨	고전적 데이터가 정규화 및 변환되어 양자 상태로 인코딩됨
유사도/판별 메커니즘	주로 고전적 신경망의 분류를 통해 진짜/가짜를 판별함	스왑 테스트(Swap Test) 를 활용하여 두 양자 상태 간의 유사도(충실도)를 측정함으로써 판별을 수행함
기울기 계산 방식	주로 역전파 (Backpropagation) 알고리즘을 사용하여 파라미터의 기울기를 계산함	파라미터 이동 규칙(Parameter Shift Rule)¹⁾ 을 포함한 양자 게이트 미분 방식을 사용하여 파라미터 기울기를 추정함
파라미터 수 효율성	QuGAN과 유사한 성능을 위해 상대적으로 많은 수의 파라미터가 필요함	고전적 GAN과 유사한 성능을 달성하면서 파라미터 수를 9498% 감소 시킴 (예: QuGAN 10개 파라미터 vs C-GAN 199개 파라미터로 유사 성능 달성)
수렴 안정성	훈련 시 수렴 실패 문제 및 모드 붕괴(mode collapse)를 흔히 겪는다고 알려져 있음	안정적인 수렴 경향 을 제공하며, 기존 양자 기반 GAN들(Qi-GAN, TFQ-GAN) 대비 향상된 안정성을 보임
다룰 수 있는 데이터 분포	특정 복잡한/고차원 데이터 분포 학습에 한계가 있을 수 있음	양자 역학의 원리를 활용하여 고전적 GAN으로는 다루기 어려운 복잡하고 고차원적인 데이터 분포를 탐색하고 생성할 잠재력 을 가짐
생성 능력	주로 고전적 데이터(이미지, 텍스트 등)를 생성함	양자 데이터를 직접 생성할 수 있는 고유한 능력을 가짐 생성자 출력은 자연스럽게 분포 형태로 나타남
계산 비용	딥 신경망 관련하여 계산 복잡성이 계속 증가함	양자 이점을 통해 계산 복잡성 문제를 부분적으로 완화할 가능성이 있음. 단, 양자 시뮬레이션도 큐비트 수에 따라 비용이 증가함

1) 양의 방향으로 작은 값($\pi/2$)만큼 이동시켜 실행하고, 다른 한 번은 음의 방향으로 같은 값만큼 이동시켜 실행합니다. 이 두 실행 결과의 차이를 통해 기울기를 근사

- **양자 회로(Quantum Circuit) 구현:** 기존 GAN의 생성자와 판별자를 모두 양자 회로로 구현한 모델
- **양자 상태 충실도(Quantum State Fidelity) 기반 손실 함수:** 생성자와 판별자 간의 경쟁과 학습을 위해, 두 양자 상태가 얼마나 유사한지를 측정하는 '양자 상태 충실도'를 사용함 '스왑 테스트(Swap Test)' 양자 알고리즘을 통해 계산됨
- **파라미터 수의 획기적인 감소:** 고전적인 GAN과 거의 동일한 성능을 달성하면서도, 사용하는 파라미터(학습 변수)의 수를 94.98%까지 크게 줄임
- **안정적인 학습:** 기존의 GAN이나 다른 양자 GAN(Qi-GAN, TFQ-GAN)들이 겪는 학습 불안정성, 모델 붕괴, 수렴 실패 등의 문제를 개선하여 더 안정적인 학습 과정을 달성함
- **순수 양자 아키텍처:** 생성자와 판별자 모두 양자 회로로 구성되어 있어, 고전적인 신경망과 양자 회로를 섞어 쓰는 하이브리드 방식보다 양자 시스템에 더 최적화된 구조를 가짐


- **양자 하드웨어의 한계:** 양자 컴퓨터는 큐비트 수가 여전히 제한적이며, 연산 중 양자 상태의 불안정성으로 인해 노이즈가 발생하기 쉬움
- **높은 계산 비용:** 양자 시뮬레이터도 큐비트 수가 증가함에 따라 요구되는 컴퓨팅 자원(메모리, 시간)이 기하급수적으로 증가하며, 실제 장치를 모방한 샷 기반 시뮬레이션은 계산 비용이 매우 높음
- **훈련의 불안정성:** GAN 모델 자체가 훈련 과정에서 불안정성이 높은 것으로 알려져 있으며, 양자 회로의 특성(예: 측정의 확률적 본성, 노이즈)이 이러한 불안정성을 더욱 심화시킬 수 있음
- **확장성 (Scalability):** 더 많은 큐비트와 복잡한 회로로 확장하는 것은 기술적 어려움으로 남아있음

Appendix. Quantum Machine Learning Details

Q u a n t u m
Innovation Laboratory

Quantum K-Nearest Neighbor (QKNN) 1/2


1. **정의:** 새로운 미분류 데이터(입력 벡터)가 주어졌을 때, 훈련 데이터 세트 중 가장 가까운 k개의 이웃을 찾고, 그 이웃들이 가장 많이 속해 있는 클래스로 새로운 데이터를 분류하는 인스턴스 기반 패턴 분류 알고리즘입니다.
2. **목적:** 클래스를 알 수 없는 새로운 입력 데이터의 패턴을 식별하고 분류하는 것입니다. 훈련 데이터와 입력 데이터 간의 '유사도'를 평가하여 가장 가까운 군집의 특성을 추론합니다.
3. **계산:** 양자 KNN의 핵심은 고전적인 거리 계산을 양자 상태의 중첩(Overlap/Fidelity)을 활용해 측정 확률로 변환하는 것입니다.
 - **기본 유사도 (Swap Test 기반 충실도):** 두 양자 상태 $|a\rangle$ 와 $|b\rangle$ 의 내적(유사도)은 보조 큐비트(Ancilla)이 $|0\rangle$ 으로 측정될 확률을 통해 다음과 같이 계산됩니다. $P(|0_{anc}\rangle) = 1/2 + 1/2|\langle a|b\rangle|^2$
 - **유클리디안 거리 (Euclidean Distance):** 두 벡터 $\vec{a}$ 와 $\vec{b}$ 사이의 고전적인 거리는 정교하게 구성된 상태들의 간단한 양자 스왑 테스트를 통해 결과적으로 도출될 수 있습니다. 벡터의 길이를 양자 상태에 인코딩한 두 상태 $|\phi\rangle$ 와 $|\psi\rangle$ 의 스왑 테스트를 거치면 다음 등식이 성립합니다.
$$|\vec{a} - \vec{b}|^2 = Z|\langle\phi|\psi\rangle|^2 \text{ (단, } Z = |\vec{a}|^2 + |\vec{b}|^2\text{)}$$
 - **해밍 거리 (Hamming Distance):** 두 이진 문자열 간의 불일치 개수를 측정합니다. 제어 게이트(XOR 등)를 사용해 거리를 위상에 기록한 후, 진폭으로 변환하여 확률로 측정합니다.



4. **Loss (손실 함수):** KNN 알고리즘은 훈련 과정에서 가중치를 업데이트하는 파라미터 최적화 기반 모델이 아닌 '게으른 학습(Lazy Learning)' 방식을 사용하므로 명시적인 Loss Function이 존재하지 않습니다. 대신, 분류 오차를 최소화하기 위한 목표 함수로서 양자 최솟값 탐색 알고리즘을 결합하여 모든 거리 중 **가장 작은 거리 값을 가진 상태를 탐색**하는 과정을 거칩니다.
5. **양자 회로 구성:** QKNN의 핵심 회로는 거리를 평가하기 위한 Swap Test Routine으로 구성됩니다.
- 초기 상태: 파동함수를 포함하는 데이터 레지스터 두 개($|a\rangle, |b\rangle$)와 0으로 초기화된 보조 레지스터(Ancilla) $|0_{anc}\rangle$.
 - 게이트 연산: 보조 큐비트에 **Hadamard 게이트**를 적용하여 중첩 상태를 만들고, 보조 큐비트가 $|1\rangle$ 일 때만 두 데이터 레지스터를 교환하는 **Controlled-SWAP 게이트**를 적용합니다.
 - 측정: 다시 보조 큐비트에 **Hadamard 게이트**를 적용한 후, 기저 상태 $|0\rangle$ 를 측정하여 앞서 언급한 거리 계산 수식의 확률값을 도출합니다.
6. **Qubit 예상 개수**
- 비교할 두 벡터가 각각 n 개의 특징(차원)을 가진다고 가정할 때:
 - 입력 데이터 레지스터: $\lceil \log_2 N \rceil$ (진폭 인코딩 가정 시) 또는 n 큐비트
 - 비교 대상 데이터 레지스터: $\lceil \log_2 N \rceil$ 또는 n 큐비트
 - 통제 및 측정을 위한 보조 큐비트(Ancilla): 최소 1~2 큐비트
 - 전체 훈련 셋을 병렬로 처리할 경우 훈련 데이터의 개수 N 을 가리키는 인덱스 큐비트 $\lceil \log_2 N \rceil$ 이 추가로 필요합니다.

Quantum Support Vector Machine (QSVM) 1/2

1. **정의:** 패턴 분류의 하위 범주인 **선형 판별**을 수행하기 위한 알고리즘입니다.
2. **목적:** 두 클래스의 데이터 영역을 가장 잘 구분하는 최적의 결정 경계, 초평면(hyperplane)을 찾는 것입니다.
3. **계산:** 분류를 위한 초평면과 이와 가장 가까운 데이터 포인트 사이의 거리, 즉 **최대 마진(Maximum margin)**을 계산하여 구합니다.
 - **마진 계산 수식:** $(\vec{w}\vec{v} + b)/|\vec{w}|$ 를 최대화
 - **제약 조건:** 데이터가 경계선을 침범하지 않도록 $\vec{w}\vec{v}_i + b \geq 1$ (클래스 1), $\vec{w}\vec{v}_i + b \leq -1$ (클래스 -1) 조건을 만족해야 합니다.
4. **Loss (손실 함수) 및 최적화**
 - **라그랑주 승수법의 의미:** '조건이 딸린 최적화 문제'를 풀기 위한 수학적 기법입니다. SVM은 "제약 조건(데이터 오분류 금지)을 지키면서, 목적 함수(마진)를 최대화"해야 합니다. 라그랑주 기법은 이 두 가지를 하나의 방정식으로 묶어 줍니다.
 - **커널 트릭(Kernel Trick)과 양자의 필요성:** 최적화 과정(Dual space)에서 데이터 간의 내적(Inner product) 행렬인 커널 행렬 K를 계산해야 하는데, 고전 컴퓨팅에서는 이 계산 복잡도가 $O((N)^3)$ 으로 데이터가 커질수록 기하급수적으로 자원이 소모됩니다.



5. **양자 회로 구성:** 양자 컴퓨터는 밀도 행렬(Density matrix)과 대각합(Trace) 연산을 통해 고비용의 **내적 및 커널 행렬 계산**을 획기적으로 빠르게 수행합니다.

- **양자 내적 계산:** 두 벡터의 내적을 정규화된 양자 상태의 겹침으로 표현합니다. $\langle x^i | x^j \rangle = \frac{\vec{x}^i \cdot \vec{x}^j}{|\vec{x}^i| |\vec{x}^j|}$.
- **커널 행렬 도출 (Partial Trace):** 데이터 상태를 나타내는 밀도 행렬에 부분 대각합을 취해 커널 행렬 값을 한 번에 추출합니다.
- **분류 수행:** 최적화된 파라미터 벡터 $\text{vec}\{w\}$ 와 새로운 입력 벡터 사이의 내적을 양자 **스왑 테스트(Swap Test)** 루틴을 통해 평가하여 클래스를 결정합니다.


$$\text{tr}_x[|\chi\rangle\langle\chi|] = \frac{1}{N_\chi} \sum_{i,j=1}^{2^n} \underbrace{\langle x^i | x^j \rangle |\vec{x}^i| |\vec{x}^j|}_{\vec{x}^i \cdot \vec{x}^j} |i\rangle\langle j| = \frac{\hat{K}}{\text{tr}[K]} .$$

6. Qubit 예상 개수

- N개의 훈련 벡터가 각각 n차원의 특징(Feature)을 가진다고 가정할 때:
- 훈련 데이터를 중첩으로 담기 위한 인덱스 레지스터 $|i\rangle$: $\lceil \log_2 N \rceil$ 큐비트
- 벡터의 특성을 담기 위한 데이터 레지스터 $|x^i\rangle$: $\lceil \log_2 N \rceil$ 큐비트 (진폭 인코딩 활용 시)
- 내적 평가(Swap Test) 및 측정을 위한 보조 큐비트(Ancilla): 최소 1~2 큐비트
- **결론:** 수백만 개의 파라미터라도 $\log_2$ 스케일로 압축되므로 이론상 수십 개의 큐비트만으로도 방대한 커널 연산이 가능합니다.

Quantum K-Means Clustering (1/2)

1. **정의:** 데이터 세트를 k개의 군집(Cluster)으로 나누는 비지도 학습 알고리즘입니다. 정답이 없는 데이터들을 대상으로 특징 공간 상에서 서로 가까이 있는 데이터들끼리 묶어줍니다.
2. **목적:** 사전 지식이나 훈련 데이터 없이 데이터 세트의 구조적 특징을 추출하여, 몇 가지의 전형적인 패턴(군집)으로 요약하고 압축하는 것입니다.
3. **계산 및 수식:** 군집화는 데이터 벡터와 중심점 간의 **유클리디안 거리 제곱**을 기반으로 수행됩니다.
 - **고전적 거리 수식:** $(\vec{a} - \vec{b})^2$ (단, $\vec{a}, \vec{b} \in \{R\}^N$)
 - **양자 거리 측정:** 두 양자 상태의 거리를 구하기 위해 충실도(Fidelity) $Fid(|\psi\rangle, |\phi\rangle) = |\langle\psi|\phi\rangle|^2$ 를 활용하거나 스왑 테스트 오라클을 이용합니다.
 - **단열 양자 역학적 계산:** 거리를 양자 해밀토니안의 에너지 레벨로 매핑합니다.
 - 초기 해밀토니안: $H_0 = 1 - \frac{1}{k} \sum_{c,c'} |c\rangle\langle c'|$
 - 최종 해밀토니안: $H_1 = \sum_{c',j} |\vec{v}^p - \vec{v}_{c'}|^2 |c'\rangle\langle c'| \otimes |j\rangle\langle j|$
 - 해석: v^p (데이터)와 $v_{c'}$ (중심점) 사이의 거리를 물리적 에너지로 인코딩하여 최저 에너지 상태를 찾습니다.




Quantum K-Means Clustering (2/2)

5. **Loss 및 최적화 과정:** 클러스터 내의 데이터들이 중심점으로부터 가지는 **제곱 오차(거리의 합)**를 최소화하는 것이 목표입니다. 최적화는 다음 두 단계를 반복하여 수행됩니다.
- **Step 1:** 각 데이터를 가장 가까운 중심점에 할당합니다 (양자 최솟값 탐색 서브루틴 활용 가능).
 - **Step 2:** 할당된 군집 내 데이터들의 거리가 최소가 되도록 새로운 중심점을 갱신합니다.
 - **주의점:** 초기 중심점의 위치에 따라 최종 결과가 지역 최솟값에 빠질 수 있으므로, **초기 중심점 선택 전략이 알고리즘의 성패를 좌우합니다.**
6. **양자 회로 구성:** QKNN과 매우 유사하지만, 반복적인 중심점 갱신 과정이 추가됩니다.
- **거리 측정 회로:** 각 데이터 상태와 중심점 상태를 입력으로 받아, 두 양자 상태 사이의 거리를 계산하는 오라클을 구성합니다.
 - **최솟값 탐색:** Dürr와 Høyer의 양자 최솟값 탐색 오라클을 사용하여, 특정 데이터와 k개의 중심점 간의 거리 중 **가장 짧은 거리**를 가진 중심점을 찾아 할당합니다.
7. **Qubit 예상 개수**
- **데이터 레지스터:** $\lceil \log_2 N \rceil$ 큐비트 (진폭 인코딩 사용 시, n은 특징의 차원 수).
 - **중심점(Centroid) 레지스터:** 데이터를 비교하기 위해 동일하게 $\lceil \log_2 N \rceil$ 큐비트 필요.
 - **클러스터 할당 레지스터:** k개의 군집 중 어느 곳에 속하는지 식별하기 위해 $\lceil \log_2 K \rceil$ 큐비트.
 - **보조 큐비트(Ancilla):** 거리를 확률로 변환하고 최솟값을 탐색하기 위한 보조 큐비트들.

Quantum Neural Network (QNN) (1/2)


1. **정의:** 노드(뉴런)와 가중치(시냅스 강도)로 연결된 다차원 그래프 구조의 계산 모델입니다. 양자 신경망(QNN)은 이러한 인공지능망의 정보 처리 구조를 양자 시스템(예: 상호작용하는 양자 점, 매개변수화된 양자 회로 등)으로 구현하거나 양자 역학적 원리를 결합한 모델을 뜻합니다.
1. **목적:** 훈련 데이터를 통해 시냅스 가중치를 학습하여, 입력과 출력 사이의 숨겨진 매핑 관계를 도출하는 것입니다.
1. **계산 및 수식:** 고전 신경망은 각 뉴런이 이전 층의 출력에 가중치를 곱해 더한 후, **비선형 활성화 함수**를 통과시켜 값을 업데이트합니다.
 - **비선형 활성화 함수:** 우측 하단 이미지 참조
 - **양자적 난제:** 양자 동역학은 본질적으로 확률을 보존하는 가역적이고 **선형적인 유니터리 변환(Unitary transformation)**을 따릅니다. 고전 신경망의 핵심인 '비선형 활성화 함수'를 의미 있는 양자 역학적 틀로 번역하는 것이 QNN 설계에서 중요합니다.



Activation Functions


Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



tanh

$$\tanh(x)$$




ReLU

$$\max(0, x)$$



Leaky ReLU

$$\max(0.1x, x)$$




Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



Different Activation Functions and their Graphs

4. **Loss 및 최적화 과정** 훈련 초기에는 무작위로 설정된 가중치로 결과를 예측한 뒤, 실제 정답과의 오차를 계산합니다.

- **최적화 기법:** 오차를 최소화하기 위해 **경사 하강법(Gradient descent)**과 **역전파(Backpropagation)** 알고리즘을 사용하여 네트워크 전체의 가중치를 지속적으로 업데이트합니다.
- **양자 트렌드:** 현재의 하이브리드 QNN은 회로 내부의 양자 게이트 회전각(θ)을 파라미터로 삼고, 기울기 계산(Parameter-Shift Rule 등)과 역전파는 고전 컴퓨터의 Optimizer(Adam 등)에 맡기는 방식을 취합니다.

5. **양자 회로 구성:**

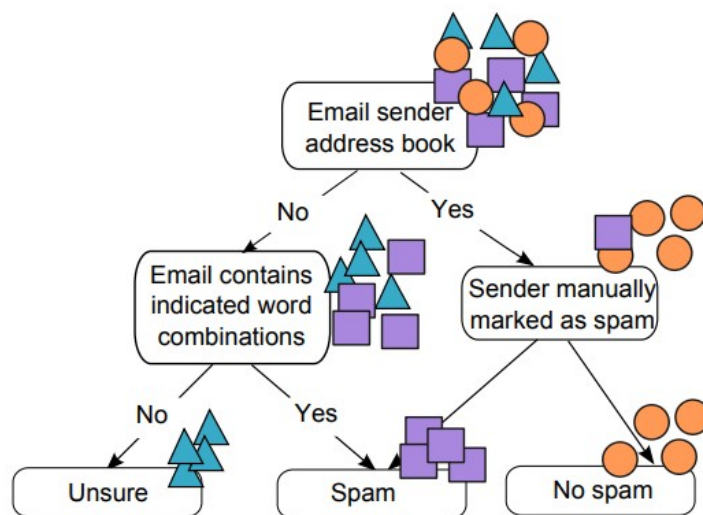
- **과거 QNN 구조:** 상호작용하는 양자 점을 이용한 시뮬레이션, 액체 상태 핵자기공명을 이용한 단일 컴퓨팅 방식 등 다양한 시도가 있었으나, 완전하게 작동하는 효율적인 범용 양자 패턴 분류 회로는 확립되지 않았습니다.
- **현재 하이브리드 VQC 구조:** 데이터 인코딩 계층 → **가중치 역할을 하는 매개변수화된 양자 게이트 계층(Parameterized Quantum Gates, 예: R_x, R_y, R_z)** → 얽힘(Entanglement)을 만드는 CNOT 계층 → 큐비트의 기댓값을 읽어내는 측정 계층으로 구성됩니다.

6. **Qubit 예상 개수**

- 데이터를 $\lceil \log_2 N \rceil$ (진폭 인코딩) 또는 N (앵글 인코딩) 개의 큐비트에 매핑합니다.
- **최신 SOTA 트렌드 기준:** 복잡한 이미지를 고전 CNN으로 먼저 압축한 뒤 양자 회로로 넘기는 하이브리드 구조(CQ-CNN)를 사용할 경우, 단 **4~10개의 큐비트와 극소수의 레이어**로 수백만 개의 파라미터를 가진 고전 딥러닝과 대등한 예측을 수행할 수 있습니다.

Quantum Decision Tree (QDT) (1/2)

1. **정의:** 스무고개처럼 특정 기준(질문)에 따라 데이터를 분기하여 최종 클래스에 도달하는 트리 형태의 분류기입니다. 양자 의사결정 나무(QDT)는 고전적 특징 데이터를 양자 상태로 인코딩하고, 각 노드에서의 분기 결정을 양자 역학적 측정이나 연산으로 수행하는 모델입니다.
1. **목적:** 데이터셋을 '가장 잘 정돈된' 하위 하위 그룹들로 반복적으로 분할하여, 새로운 데이터의 클래스를 예측하는 것입니다. 딥러닝과 달리 모델의 판단 근거를 인간이 직관적으로 이해 (해석 가능성)할 수 있다는 것이 최대 강점입니다.
1. **계산 및 수식:** 트리를 얼마나 '잘' 분할했는지를 평가하기 위해 혼잡도(불확실성)를 측정하는 **엔트로피(Entropy)** 개념을 사용합니다.
 - **고전적 분할 (Shannon Entropy):** 분할된 하위 집합의 확률을 이용하여 정보량을 계산).
 - **양자적 분할 제안 (Lu & Brainstein):** 특징 벡터들을 양자 상태로 인코딩한 뒤, 새 엔트로피 대신 양자 시스템의 혼란도를 측정하는 **폰 노이만 엔트로피(von Neumann entropy)**를 사용하여 그래프 분할 기준을 설계합니다.



4. Loss 및 최적화 과정

- 의사결정 나무는 신경망처럼 미분 가능한 Loss 함수를 역전파하는 방식이 아닙니다. 대신, 각 노드에서 정보 획득량(Information Gain, 분할 전후의 엔트로피 감소량)을 최대화하는 분기 기준을 찾는 **탐욕 알고리즘(Greedy Algorithm)**을 사용합니다.
- **최신 트렌드 (양자 랜덤 포레스트 등):** 고전 컴퓨터가 전체 트리 구조를 관리하되, 가장 불순도가 낮은 최적의 분할 지점을 탐색하는 과정에 양자 중첩과 진폭 증폭을 도입하여 탐색 속도를 높이는 방식이 사용됩니다.

5. 양자 회로 구성:


- **과거 트렌드:** "각 노드에서 양자 세트를 분할하고 측정하는 과정에 대해 명확한 설명을 제공하지 않아 매우 모호하다"고 평가했습니다.
- **현재 하이브리드 VQC 라우팅 (Quantum Routing):** 트리의 각 분기점에 매개변수화된 얽은 양자 회로(VQC)를 '판별기'로 배치합니다. 입력 데이터가 얽힌 상태를 통과한 후 특정 큐비트를 측정했을 때, 확률적으로 기저 상태($|0\rangle$)면 왼쪽 가지, 들뜬 상태($|1\rangle$)면 오른쪽 가지로 보내는 구조(Hybrid Tree)가 최신 SOTA 트렌드입니다.

6. Qubit 예상 개수

- **데이터 레지스터:** n 개의 특징(Feature)을 인코딩하기 위해 $\lceil \log_2 N \rceil$ (진폭 인코딩) 또는 n (앵글 인코딩) 큐비트.
- **트리 라우팅(경로) 큐비트:** 트리의 최대 깊이(Depth)를 d 라고 할 때, 경로를 추적하고 결정하기 위해 최소 d 개의 보조 큐비트가 필요합니다. (예: 깊이가 3인 트리는 8개의 리프(최종 클래스) 노드를 가질 수 있으며, 3큐비트의 중첩 상태로 모든 경로를 표현할 수 있습니다).

Quantum Probability Models (1/2)

1. **정의:** 데이터에 내재된 불확실성과 무작위성을 확률 분포 및 상태 전이로 모델링하는 기법입니다. 대표적으로 베이지안 모델과 은닉 양자 마르코프 모델 (HQMM), 그리고 최근의 양자 생성형 모델 (QGAN, QuDDPM)이 포함됩니다.
1. **목적:** 불확실성이 높은 연속된 관측 데이터(음성, 텍스트, 시계열 등)로부터 숨겨진 최적의 상태를 추론하거나, 훈련 데이터의 확률 분포를 학습하여 새로운 양자 및 고전 데이터를 생성하는 것입니다.
1. **계산 및 수식:** 고전 확률 통계를 양자 역학의 밀도 행렬(Density Matrix)과 측정 이론으로 확장합니다.
 - **베이지안 양자 상태 분류:** 베이즈 정리를 활용하되, 미지의 양자 상태를 구별하기 위해 양자 측정기인 POVM (Positive Operator-Valued Measure)을 분류기로 학습합니다.
 - **은닉 양자 마르코프 모델 (HQMM):** 고전적인 확률 전이 행렬 대신, 크라우스 연산자(Kraus Operators)를 사용하여 밀도 행렬의 변화를 표현합니다.



4. **Loss 및 최적화 과정** : 확률 모델의 훈련은 일반적으로 관측된 데이터 셋이 발생할 확률을 극대화하는 **최대 우도 추정(Maximum Likelihood Estimation)**을 기반으로 합니다.

- **최신 하이브리드 트렌드**: 최근 양자 디퓨전 모델(QuDDPM)이나 양자 생성적 적대 신경망(QGAN) 같은 생성 모델에서는, 데이터 분포의 차이(예: Kullback-Leibler Divergence 등)를 Loss로 삼아 고전적 Optimizer로 양자 회로의 파라미터를 업데이트합니다.

5. **양자 회로 구성**:

- **과거 트렌드**: 당시에는 HMM을 열린 양자 시스템의 수학적 언어로 재구성하여 동역학적 풍부함을 증명하는 이론적 단계였습니다.
- **현재의 생성형 양자 회로**: 고전 컴퓨터로는 시뮬레이션하기 벅찬 복잡한 고차원 확률 분포를 생성하기 위해, 매개변수화된 양자 회로(VQC)와 얽힘 게이트를 활용합니다. 수차례의 측정을 통해 얻은 0과 1의 결과 분포 (Sampling) 자체가 모델이 생성해 낸 복잡한 확률 분포가 됩니다.

6. **Qubit 예상 개수**

- **확률 분포 매핑**: 데이터를 인코딩하고 확률 분포를 매핑하기 위해 $\lceil \log_2 N \rceil$ (차원 또는 상태의 수) 큐비트가 필요합니다.
- **HQMM의 큐비트 효율성**: 고전 HMM은 복잡한 시계열 종속성을 표현하기 위해 방대한 수의 은닉 상태를 필요로 합니다. 하지만 HQMM은 **양자 결맞음** 특성을 활용하므로, 고전적으로 수십 개의 상태가 필요한 문제도 단 2~3개의 큐비트만으로 압축하여 표현할 수 있습니다.

The gateway to all quantum computing technologies
Thanks for Attention

hyunhopart@megazone.com