

빅데이터분석 기본 개념문제

TF-IDF에서 TF와 IDF 각각이 어떤 현상을 보정하기 위해 존재하는지 설명하시오.

IDF에서 로그를 사용하는 이유?

Power Law가 문서 빈도 분포에서 어떻게 나타나는지 기술하시오.

스트리밍 데이터 처리(stream processing)가 필요한 이유를 두 가지 쓰시오.

Poll, push, pull 방식의 차이점

클러스터 컴퓨팅에서 발생하는 세 가지 핵심 문제(Node failure, Network bottleneck, Programming complexity)를 설명하시오.

Spark의 WordCount 구현은 MapReduce와 어떤 두 가지 핵심 차이가 있는가?
(RDD 특성 및 Lazy Evaluation 관점에서 답하시오.)

간단하게 설명하세요

- (1) Mean Imputation
- (2) Model-based Imputation
- (3) PCA의 첫 번째 주성분(PC1)의 의미
- (4) 지니 불순도
- (5) 엔트로피
- (6) WoE(Weight of Evidence)가 필요한 이유
- (7) 단조성(Monotonicity)이 변수 선택에서 중요한 이유

간단하게 설명하세요

- (1) map vs flatMap
- (2) persistence vs cache
- (3) Broadcast Variable의 필요성
- (4) Accumulator가 사용 가능한 상황
- (5) Lazy Evaluation이 성능을 높이는 이유

MLflow의 Tracking, Projects, Models, Registry 네 가지 구성요소를 1-2줄로 요약하시오.

파레토 분석

(1) “해 x_1 이 해 x_2 를 지배한다”의 조건을 두 가지로 쓰시오.

(2) 파레토 최적 집합과 파레토 프론트의 차이를 설명하시오.

MLflow의 Tracking, Projects, Models, Registry 네 가지 구성요소를 1-2줄로 요약하시오.